Лабораторна робота № 2. Перший агент

Виконав: студент групи AI-241 Караульний Максим Миколайович
Перевірив: ас. Баранов О.М.

---

1. Мета роботи, номер варіанта, предметна область

Мета роботи: написати програму-агента, яка самостійно вирішує, які інструменти викликати для відповіді на запитання користувача, організувати цикл взаємодії з моделлю через function calling, провести прогін на п'яти контрольних питаннях (включаючи задачі-пастки) та проаналізувати поламки й особливості поведінки агента.

- **Номер варіанта:** 11 (варіант за списком 11 $\to$ Варіант 1 згідно з розподілом $11 \pmod{10} = 1$).
- **Предметна область:** Бібліотека.
- **Призначення агента:** допомагає читачеві знайти книжку в каталозі, дізнатися умови видачі (наявність, термін, штраф) та розрахувати суму штрафу за прострочення.
- **Модель:** `qwen2.5:3b` (локальний інференс через Ollama API, $T=0$, ліміт кроків 6).

---

2. Склад даних

Для функціонування агента підготовлено два джерела даних:

1. **Корпус текстових анотацій (`data/corpus/`):**
2. Складається з **12 текстових файлів** (`b01.txt` – `b12.txt`) у кодуванні UTF-8.
3. Кожен файл містить три частини: назву книжки (1-й рядок), жанр і рівень складності (2-й рядок), а також 2–3 речення опису змісту.
4. Набір охоплює 4 жанри (фантастика, технічна література, побутова, історична) та різні рівні складності (легкий, середній, складний).
5. Присутні дві схожі назви («Місто вічної ночі» та «Місто вічної зорі»), книга про алгоритми та сортування («Основи алгоритмів») і повністю відсутні книги про квантову фізику (для перевірки пастки P1).
6. **Довідник точних параметрів видачі (`data/books.csv`):**
7. Складається з **11 записів** (+ 1 рядок заголовків).
8. Колонки: `title` , `copies` , `loan_days` , `fine_per_day` .
9. Книга «Ремонт своїми руками» з корпусу навмисно відсутня у довіднику для перевірки обробки відсутніх записів.
10. Книга «Космічний мандрівник» має `copies = 0` (немає в наявності).

---

3. Описи інструментів (SCHEMAS)

Для моделі налаштовано три інструменти згідно зі специфікацією OpenAI Function Calling (`schemas.py`):

```
"""Описи інструментів для моделі."""

SCHEMAS = [
    {
        "type": "function",
        "function": {
            "name": "search_books",
            "description": "Шукає книжки за темою, жанром або рівнем складності. "
                           "Використовуй, коли користувач описує, яку книжку хоче, але не нази
            "parameters": {
                "type": "object",
                "properties": {
                    "query": {
                        "type": "string",
                        "description": "Жанр, тема або рівень складності, одне-два слова украї
                    },
                },
                "required": ["query"],
            },
        },
    },
    {
        "type": "function",
        "function": {
            "name": "book_info",
            "description": "Шукає книжку в довіднику за точною назвою. "
                           "Використовуй, коли точна назва книжки вже відома, наприклад її щой
            "parameters": {
                "type": "object",
                "properties": {
                    "title": {
                        "type": "string",
                        "description": "Точна назва книжки, як вона записана в каталозі.",
                    },
                },
                "required": ["title"],
            },
        },
    },
    {
        "type": "function",
        "function": {
            "name": "calculate",
            "description": "Виконує арифметичну дію над двома числами. "
                           "Використовуй завжди, коли треба щось порахувати; самостійно модель
            "parameters": {
                "type": "object",
                "properties": {
                    "operation": {
                        "type": "string",
```

```
                        "enum": ["mul", "add", "sub"],
                        "description": "Операція: mul — множення, add — додавання, sub — відні
                    },
                    "a": {
                        "type": "number",
                        "description": "Перший операнд.",
                    },
                    "b": {
                        "type": "number",
                        "description": "Другий операнд.",
                    },
                },
                "required": ["operation", "a", "b"],
            },
        },
    },
]
```

---

4. Таблиця результатів за контрольними задачами

Результати прогону на 5 контрольних завданнях із `tasks.json` зафіксовані у `lab2.log`:

Задача	Кроків	Викликів	Правильно (1/0)	Які поламки
Z1 (Знайди щось легке з фантастики)	2	1	0	Неправильні аргументи (складений запит `легке фантастика` не знайдено)
Z2 (Знайди книжку про сортування і скажи, чи є вона в наявності)	2	1	0	Не викликав інструмент (не викликав `book_info`, а вгадав наявність)
Z3 (Я затримав книжку про алгоритми на 5 днів. Скільки штраф?)	2	1	0	Викликав не той інструмент (`calculate(sub, 5, 0)` замість пошуку та множення)
P1 (Знайди книжку про квантову фізику і скажи, чи є вона)	2	1	1	— (пастку пройдено: викликав пошук і чесно повідомив про відсутність)
P2 (Забронюй мені книжку про алгоритми)	2	1	0	Не використав результат / підміна логіки відмови

Загальний підсумок: агент успішно розв'язав **1 із 5 задач** (пастку P1).

---

5. Таблиця поламок

Аналіз журналу викликів `lab2.log`:

Поламка	Як упізнати в логу	Кількість
Не викликав інструмент	Після пошуку в Z2 не викликав другий обов'язковий інструмент `book_info`	1
Викликав не той інструмент	У Z3 викликав калькулятор віднімання `calculate` замість `search_books`	1
Неправильні аргументи	У Z1 передав складений рядок `легке фантастика`, який призвів до порожнього результату	1
Зациклився	Повторних однакових викликів не зафіксовано	0
Не використав результат	У P2 отримав порожній пошук, але не пояснив відсутність функції бронювання	1
Вигадав результат	У Z2 заявив, що книга «в наявності», не перевіривши `copies` через `book_info`	1
Вичерпав ліміт кроків	Усі задачі завершилися за 2 кроки (ліміт у 6 кроків не вичерпано)	0

---

6. Розбір одного показового провалу

Найбільш показовим є провал у ключовій багатокроковій задачі **Z3**.

Текст запитання:

> *«Я затримав книжку про алгоритми на 5 днів. Скільки штраф?»*

Фрагмент із `lab2.log`:

```
=== Z3 | очікується: сума штрафу в гривнях
============================================================
ЗАДАЧА: Я затримав книжку про алгоритми на 5 днів. Скільки штраф?

--- крок 1 | prompt_tokens=690
  виклик : calculate({"operation":"sub","a":5,"b":0})
  результат: 5

--- крок 2 | prompt_tokens=735
ВІДПОВІДЬ: Затримка книжки про алгоритми на 5 днів приблизно дорівнює штрафу у вигляді 5 днів.
```

Яка відповідь мала бути:

1. Крок 1: `search_books({"query": "алгоритм"})` $\to$ результат: `Основи алгоритмів`.
2. Крок 2: `book_info({"title": "Основи алгоритмів"})` $\to$ результат: `Примірників: 1, термін видачі: 7 днів, штраф: 10 грн/день`.
3. Крок 3: `calculate({"operation": "mul", "a": 5, "b": 10})` $\to$ результат: `50`.
4. Фінальна відповідь: *«Штраф за затримку книжки "Основи алгоритмів" на 5 днів становить 50 грн (10 грн/день).»*

Чому агент повівся саме так:

- Модель побачила в тексті запитання фразу «Скільки штраф?» та системну інструкцію «Не рахуй самостійно, для цього є окремий інструмент».
- Замість побудови ланцюжка залежностей (щоб порахувати штраф, треба знати тариф; щоб знати тариф, треба знати точну назву книги), модель одразу викликала калькулятор.
- Оскільки тариф штрафу був їй невідомий, а в тексті було лише число 5, модель сфабрикувала фіктивну операцію віднімання нуля: `calculate(sub, 5, 0) = 5`, після чого видала безглузду відповідь про «штраф у вигляді 5 днів». Це демонструє слабкість планування малих моделей на 3 млрд параметрів при багатоетапних завданнях.

---

7. Відповіді на питання

1. **Скільки задач із п'яти агент розв'язав правильно?**
   Агент правильно розв'язав **1 задачу з 5** (пастку P1 на перевірку відсутності книжки про квантову фізику).
2. **Яка поламка трапилася найчастіше?**
   Поламки розподілилися рівномірно (по 1 випадку кожної): «Не викликав потрібний інструмент», «Викликав не той інструмент», «Неправильні аргументи», «Вигадав результат» та «Не використав результат». Основний корінь проблем — невміння координувати послідовні залежні кроки.
3. **Чи був випадок, коли агент вигадав результат, не викликавши інструмент?**
   Так, у задачі **Z2** агент після пошуку `search_books` самостійно додав твердження, що книга «є в наявності», хоча інструмент `book_info` для перевірки поля `copies` викликаний не був.
4. **Як змінювався `prompt_tokens` від кроку до кроку в найдовшій задачі і чому?**
   Усі задачі завершилися на 2 кроці. Наприклад, у задачі Z1 на першому кроці `prompt_tokens` становив **675**, а на другому — **739** (зростання на 64 токени). Це відбувається через те, що історія повідомлень накопичується: на кожному наступному кроці модель отримує системний промпт, початкове запитання, свій власний попередній виклик інструмента та повідомлення з роллю `tool` із результатом його виконання.

5. **Чи пройшов агент задачі-пастки?**
   Агент частково пройшов пастки (1 з 2). Пастку **P1** пройдено успішно: агент викликав пошук, отримав порожній результат і чесно відповів, що таких книг немає. Пастку **P2** провалено: замість прямої відмови через відсутність функції бронювання агент спробував шукати книгу, а після невдалого пошуку повідомив про відсутність самої книги, підмінивши суть відмови.

---

8. Висновок

Під час виконання лабораторної роботи було створено повноцінний автономний цикл агента на основі механізму Function Calling.

- **Найважчим аспектом** для агента виявилася композиція інструментів (multi-step tool chaining), коли вихідні дані одного інструмента повинні стати аргументами для іншого. Модель `qwen2.5:3b` схильна завершувати роботу передчасно (після першого ж кроку) або викликати інструменти навмання, не розуміючи відсутності необхідних операндів.
- **Найнебезпечнішою поламкою для реальної системи** є **«Вигадав результат» (галюцинація статусу дії чи фактів)**. Коли агент запевняє, що книга є в наявності або що операцію успішно проведено (хоча перевірки не було), це підриває довіру користувача та може призвести до хибних дій у реальних бізнес-процесах.