Лабораторна робота № 5. RAG-агент: пошук по документах як інструмент

Виконав: студент групи AI-241 Караульний Максим Миколайович
Перевірив: ас. Баранов О. М.
Організація: Національний університет «Одеська політехніка»

---

1. Мета роботи та вихідні параметри

Мета роботи:
1. Замінити примітивний пошук підрядком з лабораторної роботи № 2 векторним семантичним пошуком по документах і підключити його до агента як інструмент `search_docs`.
2. Дослідити якість векторного пошуку окремо від агента на різних конфігураціях розбиття тексту на чанки (фіксована довжина та абзаци) і виміряти показник `hit@k`.
3. Калібрувати поріг схожості `MIN_SCORE`, що дозволяє відсікати запити без відповіді («нічого не знайдено»).
4. Оцінити вплив трьох різних текстових описів інструмента (`A`, `B`, `C`) на схильність моделі звертатися до пошуку (по 3 повтори на кожну конфігурацію, разом 90 запусків).
5. Проаналізувати типові збої за логами й трасами (категорії `ok`, `no_search`, `miss`, `ignored`, `refused`, `invented`) та перевірити роботу 5 базових задач із лабораторної роботи № 4 після інтеграції RAG.

Вихідні параметри конфігурації

Параметр	Значення
Варіант	1 (11 mod 10 = 1)
Предметна область	Бібліотека (Науково-просвітницька книгозбірня «Кодекс Оріона»)
Модель чату	`llama32-4k` (на базі Llama 3.2 3B) / `qwen2.5:3b`
Розмір вікна контексту	4096 токенів
Температура генерації	0.0
Модель ембедингів	`bge-m3` (BAAI)
Розмірність векторів	1024

Параметр	Значення
Векторний індекс	FAISS `IndexFlatIP` (скалярний добуток для L2-нормалізованих векторів)
Обраний метод нарізання	`paragraphs` (за абзацами)
Розмір чанка / перекриття	800 символів / 0
Додавання заголовка (`with_title`)	`False`
Параметр видачі `TOP_K`	3 найближчих фрагменти
Поріг схожості `MIN_SCORE`	0.55
Скорочення історії	`COMPRESS = "none"`
Стан та кеш викликів	`USE_STATE = False`, `USE_CACHE = False`

---

2. Корпус документів та зафіксовані контрольні питання

2.1. Документи корпусу

Корпус складається з: 1. 12 коротких анотацій з ЛР2 (`data/corpus/b01.txt` … `b12.txt`) загальним обсягом 4 296 символів. 2. 5 повнотекстових тематичних документів книгозбірні «Кодекс Оріона» (`data/docs/d01.txt` … `d05.txt`) загальним обсягом 19 563 символи: - `d01.txt` : *Положення про правила користування та обслуговування читачів у Науково-просвітницькій книгозбірні Кодекс Оріона* (3 897 символів, 8 абзаців); - `d02.txt` : *Регламент роботи головної читальної зали та доступу до електронних ресурсів у книгозбірні Кодекс Оріона* (3 844 символи, 8 абзаців); - `d03.txt` : *Інструкція про порядок замовлення та отримання видань через службу міжбібліотечного абонемента у книгозбірні Кодекс Оріона* (3 909 символів, 8 абзаців); - `d04.txt` : *Порядок комплектування, обліку надходжень та списання фонду в Науково-просвітницькій книгозбірні Кодекс Оріона* (3 959 символів, 8 абзаців); - `d05.txt` : *Положення про організацію роботи просвітницьких гуртків, клубів та культурних заходів при книгозбірні Кодекс Оріона* (3 954 символи, 8 абзаців).

Загальний обсяг корпусу: 17 документів, 23 859 символів (приблизно 9 544 токени при 2.5 символи/токен).
Оскільки 9 544 токени значно перевищують розмір контекстного вікна моделі (4096 токенів) більш ніж у 2.3 рази, повне завантаження документів у контекст неможливе, що вимагає вибіркового вилучення інформації за допомогою RAG.

Скрипт перевірки `check_cases.py` підтвердив коректність обсягу та відсутність дублювання відповідей:

```
Документів: 17; символів: 23859; приблизно токенів: 9544 (вікно 4096)
Питань: 10 ({'direct': 4, 'paraphrase': 4, 'none': 2})
Усе гаразд
```

2.2. Зафіксовані контрольні питання (`rag_cases.json`)

Зафіксовано 10 питань (4 прямих, 4 перефразованих, 2 без відповіді):

ID	Вид	Текст питання	Фраза `must_contain`	`expected`
D1	`direct`	Яка вартість первинного виготовлення електронного читацького квитка у гривнях?	`читацького квитка становить 145 гривень`	`145`
D2	`direct`	Скільки хвилин становить максимальна тривалість однієї безперервної робочої сесії за стаціонарним комп'ютерним терміналом?	`терміналом становить 135 хвилин`	`135`
D3	`direct`	Який фіксований логістичний збір встановлено за транспортування одного друкованого тому в обидва кінці?	`кінці становить 215 гривень`	`215`
D4	`direct`	Скільки тематичних гуртків і клубів за інтересами діють на постійній основі на базі соціокультурного відділу установи?	`діють 13 тематичних гуртків`	`13`
P1	`paraphrase`	Скільки коштуватиме читачеві доба запізнення зі здачею взятої додому книжки?	`пеню у розмірі 37 гривень`	`37`
P2	`paraphrase`	Скільки коштів треба тимчасово залишити працівникові як гарантію, щоб узяти прилад для збільшення дрібного тексту?	`заставу в розмірі 290 гривень`	`290`
P3	`paraphrase`	Який максимальний часовий ліміт відводиться користувачеві після відправки листа про прибуття тома з іншого міста, перш ніж бронь скасують?	`замовленої книги протягом 76 годин`	`76`
P4	`paraphrase`	Скільки часу книжка мусить пролежати на полиці зовсім незатребуваною	`запиту протягом 49 місяців поспіль`	`49`

ID	Вид	Текст питання	Фраза `must_contain`	`expected`
		серед відвідувачів, щоб її прибрали в далеке сховище?		
N1	`none`	Скільки коштує пільгова передплата на озвучені аудіокниги для незрячих пенсіонерів?	*null*	*null*
N2	`none`	Скільки коштує ламінування обкладинок та зшивання дипломів металевою пружиною?	*null*	*null*

2.3. Перевірка «чи вгадує модель без документів»

Для трьох контрольних питань моделі було поставлено запити напряму без надання інструмента пошуку: 1. *«Яка вартість первинного виготовлення електронного читацького квитка у гривнях?»* Відповідь моделі: *«Зазвичай оформлення читацького квитка в бібліотеках України є безкоштовним або коштує близько 20–50 грн на пластикову картку.»* (Правильне значення `145` не вгадано). 2. *«Скільки коштуватиме читачеві доба запізнення зі здачею взятої додому книжки?»* Відповідь моделі: *«Пеня за кожен день прострочення зазвичай складає від 1 до 5 гривень.»* (Правильне значення `37` не вгадано). 3. *«Скільки тематичних гуртків діють на постійній основі на базі соціокультурного відділу?»*
Відповідь моделі: *«У бібліотеках зазвичай діє від 3 до 5 клубів за інтересами.»* (Правильне значення `13` не вгадано).

Висновок: Усі цільові значення є специфічними та нетиповими, їх неможливо вгадати із загальних знань мовної моделі.

---

3. Перевірка моделі ембедингів (`embed_check.py`)

Скрипт `embed_check.py` перевіряє роботу моделі векторних представлень `bge-m3` : - Довжина вектора: **1024** - L2-норма вектора після розрахунку: **1.000** (вектори нормалізовані) - Схожість «Запит — Тариф на доставку»: **0.784** - Схожість «Запит — Графік роботи кур'єрів»: **0.492**

Семантично споріднена фраза («Тариф на доставку») має значно вищий косинусний коефіцієнт (0.784) порівняно з тематично віддаленою («Графік роботи кур'єрів» — 0.492), що підтверджує коректність роботи ембедера.

---

4. Нарізання документів на чанки (Крок 3)

Скрипт `show_chunks.py` протестовано на документі `data/docs/d01.txt` трьома способами.

Таблиця 1 — Нарізання одного документа (`d01.txt`, 3897 символів)

Спосіб	Чанків	Закінчуються посеред речення	Довжина найбільшого, символів
`fixed`, 200, перекриття 0	20	19	200
`fixed`, 500, перекриття 100	10	9	500
`paragraphs`, 800	8	0	586

Приклад розрізаного факту:

При нарізанні `fixed`, 200, перекриття 0: - **Чанк 4:** *«Для ідентифікації користувачів та автоматизації книговидачі установа використовує іменні пластикові картки з вбудованим безконтактним радіочастотним чіпом. Вартість первинного виготовлення такого електронного чит»* - **Чанк 5:** *«ацького квитка становить 145 гривень, які сплачуються одноразово через термінал у вестибюлі книгозбірні...»*

Слово «читацького» було розірвано на стику («чит» і «ацького»). При пошуку за запитом про *читацький квиток* вектор чанка втрачає семантичну цілісність, а агент може отримати уривок без суб'єкта дії, що призводить до втрати релевантності.

---

5. Перевірка пошуку без агента та поріг схожості (Крок 5)

Таблиця 2 — Пошук при різному нарізанні (скрипт `check_retrieval.py`)

Конфігурація	Чанків	Сер. довжина	hit@1	hit@3	hit@5	hit@3 прямі	hit@3 перефр.	Токенів (k=3)
`fixed-200-0`	134	178	0.62	0.88	1.00	1.00	0.75	214
`fixed-500-0`	55	433	0.75	0.88	1.00	1.00	0.75	520
`fixed-500-100`	68	442	0.75	0.88	1.00	1.00	0.75	530
`fixed-1500-0`	24	994	0.75	0.88	0.88	1.00	0.75	1193
`paragraphs-800`	49	486	0.75	0.88	1.00	1.00	0.75	584

Конфігурація	Чанків	Сер. довжина	hit@1	hit@3	hit@5	hit@3 прямі	hit@3 перефр.	Токенів (k=3)
`paragraphs-800+title`	49	598	0.75	0.88	1.00	1.00	0.75	718

Обґрунтування вибору конфігурації:
Для подальшої роботи обрано конфігурацію `paragraphs-800`: - Вона забезпечує високий `hit@3 = 0.88` та ідеальний `hit@5 = 1.00`. - Зберігає синтаксичну та логічну цілісність абзаців (0 розрізаних речень). - Обсяг 3 чанків складає всього ~584 токени, що залишає понад 3500 токенів для багатокрокового діалогу та міркувань агента.

Таблиця 3 — Схожість першого результату (`check_retrieval.py scores`)

ID	Вид	Схожість	Перший результат містить потрібну фразу
D1	`direct`	0.741	так
D2	`direct`	0.698	так
D3	`direct`	0.712	так
D4	`direct`	0.735	так
P1	`paraphrase`	0.684	так
P2	`paraphrase`	0.667	так
P3	`paraphrase`	0.672	так
P4	`paraphrase`	0.627	HI
N1	`none`	0.523	-
N2	`none`	0.492	-

- Найнижча схожість серед питань з відповіддю: **0.627**
- Найвища схожість серед питань без відповіді: **0.523**

Оскільки $0.523 < 0.627$, діапазони не перекриваються. Поріг було встановлено на рівні `MIN_SCORE = 0.55` (ідеально відсікає питання без відповіді N1/N2, не зачіпаючи легітимні питання).

---

6. Перевірка інструмента через диспетчер без моделі (`try_tool.py`)

Тест через `try_tool.py`: - `python try_tool.py D1`: `ПИТАННЯ: Яка вартість первинного виготовлення електронного читацького квитка у гривнях? рівень: ok [1] Джерело: d01.txt Для ідентифікації користувачів та автоматизації книговидачі установа використовує іменні пластикові картки... Вартість первинного виготовлення такого електронного читацького квитка становить 145 гривень...` - `python try_tool.py N1`: `ПИТАННЯ: Скільки коштує пільгова передплата на озвучені аудіокниги для незрячих пенсіонерів? рівень: ok У документах нічого схожого не знайдено.` - Перевірка валідації короткого запиту `{"query": "a"}`: `Занадто короткий запит -> рівень: schema_error String should have at least 3 characters`

---

7. Дослідження трьох описів інструмента (Крок 7)

Порівняно три описи інструмента `search_docs`: - **Опис A:** старий опис з ЛР2 («Шукає книжки за темою, жанром або рівнем складності...»). - **Опис B:** докладний регламент («ЄДИНЕ джерело даних про роботу бібліотеки. Викликай ЗАВЖДИ...»). - **Опис C:** мінімальний («Шукає інформацію.»).

Для кожного опису проведено по 3 повтори на 10 питаннях (разом 90 запусків).

Таблиця 5 — Агент із трьома описами інструмента (медіани та агреговані дані)

Опис	Правильно (з 24)	Викликав пошук (з 24)	Кроків, медіана	Токенів входу, медіана	Час, с, медіана
`A`	0 / 24	0 / 24	1.0	838	13.8
`B`	21 / 24	24 / 24	2.0	3057	38.4
`C`	3 / 24	3 / 24	1.0	772	14.1

Таблиця 6 — Розподіл результатів і категорій збоїв

Категорія	`A`	`B`	`C`
Правильно (питання з відповіддю, `ok`)	0	21	3
Не шукав і відповів неправильно (`no_search`)	24	0	21
Шукав, але потрібного фрагмента немає (`miss`)	0	3	0
Фрагмент був у результаті, відповідь неправильна (`ignored`)	0	0	0
Питання без відповіді: визнав, що не знає (`refused`)	6	6	6
Питання без відповіді: вигадав відповідь (`invented`)	0	0	0

---

8. Розбір у логах і трасах Langfuse (Крок 8)

1. **Агент не шукав (`no_search`):**
   В описі `A` модель сприймала інструмент як пошук за художніми творами («Шукає книжки за темою...») і не зверталася до нього при адміністративних питаннях: `2026-11-08 10:12:32 - INFO - ЗАДАЧА: Яка вартість первинного виготовлення читацького квитка? --- крок 1 | prompt_tokens=749 ВІДПОВІДЬ: Дані про вартість первинного виготовлення електронного читацького квитка не знайдені в доступних джерелах.`
2. **Який запит генерує модель:**
   У конфігурації `B` агент самостійно адаптував запит, формулюючи його для пошукової системи:
3. Запит користувача: *«Скільки коштів треба тимчасово залишити працівникові як гарантію, щоб узяти прилад для збільшення дрібного тексту?»*
4. Згенерований виклик: `search_docs({"query":"умови видачі приладу для збільшення дрібного тексту, термін видачі, застава як гарантія"})`
   Це дало високу схожість і успішне знаходження фрагмента з відповіддю `290` .
5. **Шукав, але не знайшов (`miss`):**
   Для питання `P4` (*«Скільки часу книжка мусить пролежати на полиці... щоб її прибрали в далеке сховище?»*) агент згенерував запит *«який термін пролежання книжки в бібліотеці перед тим, як вона прибуває в далеке сховище»*.
   У документі `d04.txt` фраза була сформульована суто бюрократичною мовою: *«не мав жодного читацького запиту протягом 49 місяців поспіль, він підлягає переведенню до депозитарію»*. Через різницю в лексиці («далеке сховище» vs «депозитарій») у `top-3` потрапили фрагменти з `d03.txt` , і факт не було вилучено.
6. **Питання без відповіді:**
   Завдяки `MIN_SCORE = 0.55` пошук повертав «У документах нічого схожого не знайдено», і модель чесно відповідала, що інформація відсутня (0 випадків галюцинацій `invented`).
7. **Траси Langfuse:**
   У трасах з міткою `rag-B` чітко простежується повний ланцюжок виклику інструментів: вузол `call_tool` відображає точний згенерований `query` , а його вихід містить перелік відфільтрованих чанків із показниками `score` .

---

9. Перевірка звичайних задач після зміни пошуку (Крок 9)

Після заміни пошуку підрядком на векторний `search_docs` було виконано 5 базових задач із `tasks.json` .

Таблиця 7 — П'ять задач до і після заміни пошуку

Задача	Відповідь у лабораторній № 4	Відповідь тепер (ЛР5)	Чи викликав `search_docs`	Що змінилося
Z1	Знайдено фантастику легкого рівня	«Зоряний садівник» — фантастика, легкий рівень	Так	Відповідь стала більш повною та інформативною завдяки ширшому контексту чанка
Z2	Книга в наявності (2 примірники)	Книга «Мистецтво швидкого сортування» є в наявності	Так	Збережено точність ідентифікації видання
Z3	Штраф 185 грн (37 грн × 5)	Штраф 185 грн (37 грн/день × 5 днів)	Так	Пошук знайшов актуальну ставку штрафу з `d01.txt`, розрахунок точний
P1	Книги про квантову фізику немає	У бібліотеці немає інформації про книги про квантову фізику	Так	Коректне визначення відсутності позиції в каталозі
P2	Відмова: бронювання недоступне	Повідомлено про необхідність уточнення книги для процедури бронювання	Ні	Агент відповів безпосередньо, без зайвих викликів інструментів

---

10. Додаткове завдання: порівняння FAISS та Chroma (`chroma_test.py`)

Скрипт `chroma_test.py` порівнює метрики відстані FAISS та Chroma на питанні `D1`: - **FAISS (IndexFlatIP), косинусна схожість (S):** `0.7412` - **Chroma (`space="cosine"`), косинусна відстань (D_{cos}):** `0.2588` - **Chroma за замовчуванням (квадрат L2 відстані, D_{L2}^2):** `0.5176`

Відповіді на контрольні запитання додаткового завдання:

1. **Зв'язок чисел:**
   Для нормалізованих векторів косинусна відстань дорівнює: $$D_{cos} = 1 - S = 1 - 0.7412 = 0.2588$$ Квадрат евклідової відстані для векторів одиничної довжини становить: $$D_{L2}^2 =

2 \cdot (1 - S) = 2 \cdot 0.2588 = 0.5176$$ Розрахунки демонструють математичну еквівалентність метрик.

2. **Збіг чанків:**
   Усі три конфігурації повернули абсолютно ідентичний перший чанк із файлу `d01.txt`.
3. **Вплив на поріг `MIN_SCORE`:**
   У FAISS ми використовували умову $S \ge 0.55$ (більше — краще). Якщо передати це правило в Chroma без змін, фільтрація за відстанню $D \ge 0.55$ відсікала б найближчі (найкращі) результати і пропускала б випадкові далекі документи. Для Chroma поріг повинен інвертуватися: $D_{cos} \le 0.45$.

---

11. Відповіді на контрольні запитання

1. **Табл. 1: різниця між fixed та paragraphs.**
   Фіксоване розбиття призвело до того, що 19 з 20 чанків закінчувалися посеред речення, розриваючи числові значення та назви (наприклад, слово «читацького»). Розбиття за абзацами зберегло 100% цілісність фраз (0 розрізаних речень), що гарантує наявність повного контексту для моделі.
2. **Табл. 2: вибір конфігурації за hit@3 та ціна більшого чанка.**
   Конфігурація `paragraphs-800` показала високий результат `hit@3 = 0.88` при помірному розмірі (~584 токени). Збільшення чанка до 1500 символів не покращує `hit@3`, але подвоює витрату токенів (~1193 токени), витісняючи історію діалогу.
3. **hit@3 для прямих і перефразованих питань.**
   Для прямих запитань `hit@3 = 1.00`, для перефразованих — `0.75`. На відміну від звичайного пошуку підрядком з ЛР2, який на перефразованих питаннях повертав 0%, векторний пошук розуміє зміст і знаходить необхідні фрагменти навіть без збігу ключових слів.
4. **Табл. 3: калібрування MIN_SCORE.**
   Поріг `0.55` чітко розділив питання з відповіддю (≥ 0.627) та без неї (≤ 0.523). Занадто високий поріг призвів би до відсікання релевантних відповідей, а занадто низький — до спроб моделі вигадувати відповіді на базі невідповідних фрагментів.
5. **Табл. 5 і 6: вплив опису інструмента.**
   Опис `B` забезпечив 21 правильну відповідь із 24 (87.5%), тоді як опис `A` — 0, а опис `C` — 3. Моделі критично потрібні явні інструкції про сферу відповідальності інструмента та заборону відповідати без перевірки.
6. **Табл. 6: типова категорія помилок.**
   У конфігурації `B` єдиною помилкою був пропуск `miss` (3 випадки для питання `P4`). Цю проблему неможливо усунути описом інструмента: необхідно вдосконалювати розбиття або додавати гібридний пошук / розширення запитів (Query Expansion).
7. **Питання без відповіді та захист від галюцинацій.**
   У 100% прогонів питань `N1` та `N2` модель визнала відсутність інформації (`refused`). Спрацювали обидва захисти: поріг `MIN_SCORE` повернув повідомлення про відсутність збігів, а опис `B` зобов'язав модель чесно повідомити користувача.

8. **Оцінка токенів одного виклику search_docs.**
   Виклик інструмента додає близько 600–700 токенів до вхідного контексту. У вікно 4096 токенів гарантовано вміщується до 4–5 повноцінних кроків агента з викликами пошуку без ризику переповнення.
9. **Табл. 7: виконання звичайних задач.**
   Жодна з 5 контрольних задач не зламалася. Векторний індекс успішно працює як з новими повнотекстовими регламентами, так і зі старими короткими анотаціями.
10. **Помилка, яку не лікує опис інструмента.**
    Помилку `miss` (невлучання потрібного чанка в топ-k через специфічну термінологію) опис не виправить. Для її вирішення необхідно використовувати гібридний пошук (BM25 + Dense) або переранжування (Re-ranking) за допомогою крос-енкодера.

---

12. Висновок

У ході лабораторної роботи було створено повноцінного RAG-агента на базі векторного індексу FAISS та ембединг-моделі `bge-m3`. Експериментально доведено, що якість відповідей агента залежить від системного поєднання трьох складових: 1. **Якість нарізання тексту:** розбиття за абзацами усуває розрив семантичних одиниць і чисел. 2. **Фільтрація нерелевантних фрагментів:** калібрування `MIN_SCORE` повністю запобігає галюцинаціям на питаннях без відповіді. 3. **Опис інструмента:** точний системний опис є вирішальним фактором, що підвищує частоту звернення агента до бази знань з 0% до 100%.