

НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ «ОДЕСЬКА ПОЛІТЕХНІКА»
МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
ІНСТИТУТ КОМП'ЮТЕРНИХ СИСТЕМ
КАФЕДРА ІНФОРМАЦІЙНИХ СИСТЕМ

Протокол лабораторної роботи №1
«розгортання середовища та порівняльний аналіз мовних моделей»
з дисципліни: «Обчислювальні методи»

Виконала: студентка групи AI-241
Карвацька Єлизавета
Олегівна

Перевірив: ас. Баранов О.М.

Одеса – 2026

Завдання 1. Ціна роздумів: міркувальна vs інструктивна модель

Виконано запити до двох моделей через ендпоінт `/api/generate`. Спочатку було виконано просте фактичне питання, потім — задачу на міркування у 5 запусках для кожної моделі. Перед серією вимірів було виконано прогрівальний запит. Для порівняння використовувалися моделі `qwen3:4b` та `llama3.2:3b`.

Таблиця 1 – Фактичне питання «Столиця України? Відповідай одним словом.»

Показник	qwen3:4b	llama3.2:3b
response	Київ	Київ
eval_count	190	5
Час, c10,16	24,41	0,56
Токенів/с	7,84	22,39

У наведеному запуску обидві моделі дали правильну відповідь «Київ». Для `qwen3:4b` значення `eval_count` становило 190 токенів, загальний час виконання — 24,41 с, а швидкість генерації — 7,84 ток./с.

Для `llama3.2:3b` отримано 5 токенів, час виконання — 0,56 с та швидкість генерації — 22,39 ток./с. Таким чином, у цьому експерименті `llama3.2:3b` виконала просте фактичне завдання значно швидше, тоді як `qwen3:4b` витратила більше часу та згенерувала значно більше токенів.

Таблиця 2 – Задача на міркування (середнє з 5 запусків)

Ручка і зошит разом коштують 110 грн. Ручка на 100 грн дешевша за зошит. Скільки коштує ручка?»

Показник	qwen3:4b	llama3.2:3b
Правильних із 5	5 / 5	0 / 5
eval_count	1360,6	177,8
Час, с	192,27	11,93

Міркувальна модель qwen3:4b у всіх п'яти запусках отримала правильну відповідь — 5 грн. Середнє значення eval_count становило 1360,6 токена, а середній час виконання — 195,27 с. У відповідях qwen3:4b також спостерігалось поле thinking, що свідчить про використання додаткового процесу міркування перед формуванням кінцевої відповіді. Інструктивна модель llama3.2:3b у жодному з п'яти запусків не отримала правильну відповідь. Модель повертала різні неправильні результати: «10 грн», «110 грн», «no solution», «0 грн» та «100 грн». Середнє значення eval_count для llama3.2:3b становило 177,8 токена, а середній час виконання — 11,93 с. Отже, у проведеному експерименті qwen3:4b витратила значно більше обчислювальних ресурсів, але отримала правильний результат у всіх п'яти запусках. llama3.2:3b працювала значно швидше, проте не розв'язала задачу правильно в жодному запуску.

Відповіді на питання (крок 6)

1. Куди пішли додаткові токени в міркувальній моделі?

Відповідь: Додаткові токени міркувальної моделі витрачаються на внутрішній процес аналізу та послідовного розв'язання задачі перед формуванням кінцевої відповіді. Це видно з експерименту: під час задачі на міркування qwen3:4b у середньому згенерувала 1360,6 токена, тоді як llama3.2:3b — лише 177,8 токена.

2. На яких типах задач міркувальні моделі дають перевагу?

Відповідь: Міркувальні моделі доцільно застосовувати для задач, де необхідне послідовне виконання декількох кроків: математичних і логічних задач, аналізу, планування та інших задач, що потребують багатокрокового опрацювання інформації. У проведеному експерименті qwen3:4b правильно розв'язала задачу про ручку та зошит у всіх п'яти запусках, тоді як llama3.2:3b не отримала правильної відповіді в жодному із запусків.

3. Чим відрізняється процес навчання міркувальної моделі від інструктивної?

Відповідь: Інструктивна модель орієнтована насамперед на виконання інструкцій користувача та формування безпосередньої відповіді. Міркувальна модель додатково оптимізується для виконання багатокрокового міркування, що може

збільшувати кількість згенерованих токенів та час отримання відповіді. У практичному експерименті це проявилось у значно більшому eval_count та часу виконання qwen3:4b під час задачі на міркування.

4. Чи означає більша кількість токенів, що модель «розумніша»?

Відповідь: Ні, сама кількість згенерованих токенів не є показником якості моделі. У цьому експерименті більша кількість токенів у qwen3:4b супроводжувалася правильним виконанням задачі на міркування, але це не означає, що кількість токенів сама по собі визначає якість моделі. Якість необхідно оцінювати за конкретним завданням, правильністю результату, стабільністю та іншими показниками.

5. Як пояснити різницю у швидкості генерації між моделями?

Відповідь: Різниця у швидкості генерації пов'язана з архітектурою та характеристиками моделей, а також з обсягом обчислень, необхідних для формування відповіді. У фактичному запиті Llama3.2:3b показала швидкість 22,39 ток./с проти 7,84 ток./с у qwen3:4b. На задачі міркування різниця була ще більшою за загальним часом виконання: середній час для qwen3:4b становив 195,27 с проти 11,93 с для Llama3.2:3b.

Висновок за завданням 1

Експеримент показав, що швидкість генерації та загальний час відповіді є різними показниками.

На простому фактичному питанні обидві моделі надали правильну відповідь. При цьому Llama3.2:3b виконала запит за 0,56 с, тоді як qwen3:4b — за 24,41 с.

Швидкість генерації становила відповідно 22,39 та 7,84 ток./с. На задачі про ручку та зошит ситуація відрізнялася. qwen3:4b правильно розв'язала задачу у всіх п'яти запусках, використовуючи в середньому 1360,6 токена та 195,27 с на виконання.

Llama3.2:3b була значно швидшою — у середньому 11,93 с, але не дала жодної правильної відповіді з п'яти. Для серії з 8 послідовних викликів, якщо орієнтуватися на середній час задачі на міркування, сумарний час становитиме приблизно 1562,17 с для qwen3:4b проти 95,43 с для Llama3.2:3b, тобто близько 26 хв 02 с проти 1 хв 35 с.

Це показує суттєву різницю в часових витратах при використанні міркувальної моделі. Практичний висновок: тип моделі необхідно обирати відповідно до типу задачі. Для простих фактичних запитів важливими можуть бути швидкість та низька затримка, тоді як для задач, що потребують послідовного міркування, додаткові обчислювальні витрати можуть забезпечувати правильніший результат.

Завдання 2. Аналіз швидкодії моделей

Для додаткового порівняння було проведено benchmark для короткого, середнього та довгого запитів.

Оцінювалися такі показники: TTFT — час до першого токена; загальний час виконання; кількість символів, згенерованих за секунду.

Таблиця 3 – Результати benchmark

Модель	Запит	TTFT, с	Загальний час, с	Символів/с
llama3.2:3b	short	2,170	2,869	9,1
llama3.2:3b	medium	2,179	7,172	42,8
llama3.2:3b	long	2,174	40,124	41,8
qwen3:4b	short	35,146	49,448	5,6
qwen3:4b	medium	219,263	231,498	1,2
qwen3:4b	long	251,669	308,022	4,4

У llama3.2:3b TTFT у всіх трьох тестах залишався приблизно на рівні 2,17 с.

Для qwen3:4b TTFT був значно більшим та зростав зі збільшенням обсягу тестового запиту: від 35,146 с для короткого запиту до 251,669 с для довгого. Загальний час виконання також був більшим у qwen3:4b. Для довгого запиту він становив 308,022 с, тоді як для llama3.2:3b — 40,124 с. Таким чином, у проведеному benchmark-тесті llama3.2:3b мала меншу затримку та менший загальний час виконання.

Завдання 3. Перевірка якості виконання різнотипних завдань

Для перевірки якості моделей було виконано шість різнотипних завдань:

1. фактологічне питання;
2. формування JSON;
3. стиснення тексту;
4. написання Python-функції;
5. математична задача;
6. пояснення предметної області.

Таблиця 4 – Результати тестування якості

Завдання	llama3.2:3b	qwen3:4b
Task 1	Правильно: 1960	Неправильно: 1984
Task 2	Невалідний JSON	Валідний JSON, але значення неточні
Task 3	Числові значення збережено, є мовні помилки	Числові значення збережено
Task 4	Коректна функція, але є додатковий текст	Коректна функція, але є додатковий текст
Task 5	Неправильно: 1 рейс	Request timed out

Task 6	Відповідь отримано, але є змістові та мовні помилки	Request timed out
--------	---	-------------------

У першому завданні Llama3.2:3b надала правильний результат — 1960, тоді як qwen3:4b повернула 1984.

У другому завданні перевірялося дотримання формату JSON. Llama3.2:3b сформуvala невалідний JSON. qwen3:4b сформуvala синтаксично валідний JSON, але значення у ньому були неточними. У третьому завданні обидві моделі зберегли основні числові значення вихідного тексту. У відповіді Llama3.2:3b при цьому спостерігалися мовні помилки.

У четвертому завданні обидві моделі правильно реалізували функцію підсумовування значень weight, але додали пояснення та приклад використання. У п'ятому завданні правильна маса вантажу становить:

$$45 \times 8 + 75 \times 12 = 1260 \text{ кг.}$$

Оскільки вантажівка може перевозити максимум 1200 кг, необхідно виконати 2 рейси. Llama3.2:3b дала неправильну відповідь — 1 рейс, а qwen3:4b завершити запит не змогла через тайм-аут. У шостому завданні Llama3.2:3b сформуvala відповідь, але вона містила змістові та мовні неточності. qwen3:4b також не завершила запит через тайм-аут. Отже, тест якості показав, що отримання відповіді від моделі ще не означає її фактичної правильності. Для використання результатів у програмних системах необхідна додаткова перевірка.

Завдання 4. Вплив параметрів temperature та top_p

Було досліджено вплив параметрів семплінгу на варіативність відповідей моделі Llama3.2:3b.

Таблиця 5 – Вплив параметра temperature

Temperature	Кількість запусків	Унікальних відповідей
0,0	5	1

0,7	5	5
1,5	5	5

При temperature = 0.0 всі п'ять відповідей були однаковими.

При temperature = 0.7 та temperature = 1.5 кожен із п'яти запусків дав різну відповідь.

Отже, у проведеному експерименті збільшення значення temperature призвело до збільшення варіативності генерації.

Таблиця 6 – Вплив параметра top_p

top_p	Кількість запусків	Унікальних відповідей
0,1	5	1
0,5	5	5
1,0	5	5

При top_p = 0.1 всі п'ять відповідей були однаковими.

При top_p = 0.5 та top_p = 1.0 було отримано по п'ять різних відповідей.

Таким чином, зміна параметра top_p також впливала на варіативність результатів.

Завдання 5. Перевірка відтворюваності

Для перевірки відтворюваності було виконано 10 послідовних запусків одного запиту.

Результат:

- кількість відповідей — 10;
- кількість унікальних відповідей — 1;
- усі відповіді однакові — так.

Таким чином, у межах використаної конфігурації було отримано однаковий результат у всіх десяти запусках.

Цей експеримент разом із тестуванням temperature та top_p показує, що відтворюваність залежить від параметрів генерації та конкретної конфігурації запуску.

Загальні висновки

1) Локальні мовні моделі можуть використовувати єдиний програмний інтерфейс для взаємодії з програмою. У роботі обидві моделі запускалися через API, що дозволило використовувати однаковий підхід до надсилання запитів та отримання результатів.

2) Затримка відповіді та швидкість генерації є різними показниками. У проведеному експерименті llama3.2:3b мала значно менший TTFT і загальний час виконання порівняно з qwen3:4b.

3) Режим міркування є інструментом із певною областю застосування. У проведеному експерименті qwen3:4b використала значно більше токенів і часу, але правильно розв'язала задачу на міркування у всіх п'яти запусках. Для простого фактичного питання така кількість додаткових обчислень не була необхідною.

4) Більша кількість токенів сама по собі не означає вищу якість моделі. Якість необхідно оцінювати за правильністю відповіді та відповідністю конкретному завданню.

5) Промпт не гарантує повного контролю над форматом і змістом відповіді мовної моделі. Під час тестування одна модель сформувала невалідний JSON, а інша — синтаксично правильний JSON із неточними значеннями. Тому в програмних системах необхідно використовувати додаткову валідацію результатів.

6) Параметри семплінгу впливають на варіативність відповідей. У проведеному експерименті низькі значення temperature та top_p давали однакові відповіді, тоді як збільшення цих параметрів призводило до появи різних результатів.

7) Повторні запуски є важливими для оцінювання мовних моделей. П'ять повторів задачі на міркування продемонстрували різну поведінку моделей, а окремий десятиразовий тест показав повну повторюваність результату в конкретній конфігурації.

8) Проведене дослідження показало, що вибір мовної моделі повинен залежати від типу задачі. При оцінюванні необхідно враховувати не тільки

правильність відповіді, але й час виконання, кількість токенів, TTFT, варіативність та здатність дотримуватися заданого формату.

9) За результатами лабораторної роботи було отримано практичний досвід розгортання локальних мовних моделей, роботи з API, автоматичного збору метрик та порівняльного тестування моделей на різних типах задач.