

НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ «ОДЕСЬКА ПОЛІТЕХНІКА»
МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
ІНСТИТУТ КОМП'ЮТЕРНИХ СИСТЕМ
КАФЕДРА ІНФОРМАЦІЙНИХ СИСТЕМ

Протокол лабораторної роботи №1
«розгортання середовища та порівняльний аналіз мовних моделей»
з дисципліни: «Обчислювальні методи»
Варіант №4

Виконав(-ла): студент групи AI-244
Паламарчук Б. О.

Перевірив: ас. Баранов О.М.

Мета роботи: запустити мовні моделі локально й через хмару, порівняти їхню швидкість і якість та перевірити, як temperature і top_p впливають на відповіді.

Конфігурація середовища: робота виконана на Windows 11. Використано Ollama 0.35.1, Python 3.14.6 і віртуальне середовище venv. Комп'ютер: AMD Ryzen 7 PRO 5750G, 31,8 ГБ оперативної пам'яті, відеокарта NVIDIA GeForce RTX 3060. За командою ollama ps обидві локальні моделі працюють на GPU. Локальні моделі: llama3.2:3b і qwen3:4b, хмарна модель: gemini-3.5-flash.

Завдання 1. Ціна роздумів: міркувальна vs інструктивна модель

Запити до qwen3:4b і llama3.2:3b надсилались на ендпойнт /api/generate. Спочатку просте питання, потім задача на міркування (5 запусків). Перед вимірами зроблено прогрівальний запит. Запити йшли з короткого скрипта на Python, бо curl у PowerShell працює інакше, ніж у cmd.

Таблиця 1 - Фактичне питання «Столиця України? Відповідай одним словом.»

Показник	qwen3:4b	llama3.2:3b
response	Київ	Київ.
eval_count	206	5
Час, с	2,43	0,06
Токенів/с	89,22	132,17

Як видно з таблиці 1, обидві моделі відповіли правильно, але qwen3:4b витратила у 41 раз більше токенів (206 проти 5).

Таблиця 2 - Задача на міркування (середнє з 5 запусків)

Показник	qwen3:4b	llama3.2:3b
Правильних із 5	5 / 5	1 / 5
eval_count	1309	152
Час, с	15,45	1,46

Як видно з таблиці 2, qwen3:4b відповіла правильно 5 разів із 5, а Llama3.2:3b лише один раз. Правильна відповідь - 5 грн. У Llama були відповіді 100 грн (двічі), 105 грн і одна відмова.

Відповіді на питання (крок 6)

1. Куди пішли додаткові токени в міркувальній моделі?

Відповідь: Вони пішли в «хід думок» qwen3:4b. Користувач бачить лише слово «Київ», але токени чернетки входять в eval_count.

2. На яких типах задач міркувальні моделі дають перевагу?

Відповідь: На задачах з кількома кроками: математика, логіка, код. На простих питаннях вони лише витрачають час і токени.

3. Чим відрізняється навчання міркувальної моделі від інструктивної?

Відповідь: Інструктивну модель вчать виконувати команди й одразу відповідати. Міркувальну додатково вчать будувати проміжні міркування та перевіряти себе.

4. Чи означає більша кількість токенів, що модель «розумніша»?

Відповідь: Ні, це лише обсяг роботи. На задачі про ручку токени допомогли, а на питанні про столицю нічого не дали.

5. Як пояснити різницю у швидкості генерації між моделями?

Відповідь: У qwen3:4b більше параметрів, тому вона генерує повільніше (89 проти 132 токенів за секунду). Загальний час відрізняється сильніше, бо вона створює набагато більше токенів.

Висновок за завданням 1

Швидкість генерації та загальний час відповіді - різні речі. На простому питанні режим міркування був зайвою витратою: відповідь та сама, а токенів у 41 раз більше. На задачі про ручку qwen3:4b дала 5 правильних відповідей із 5, а Llama3.2:3b лише одну. Тому модель треба вибирати під тип задачі. Для агента з 8 послідовними викликами різниця складе 19,4 с проти 0,5 с.

Завдання 2. Роль system-повідомлення: керування поведінкою моделі

Запит варіанта 4: «Поясни різницю між оперативною пам'яттю і жорстким диском.» Його виконано для двох моделей з двома system-повідомленнями (temperature 0,7, по одному запуску). Кількість речень порахована вручну.

Таблиця 3 - Вплив system-повідомлення

Модель	System	Довжина, симв.	Мова відповіді	Речень	Інструкцію виконано?
llama3.2:3b	лаконічний асистент	112	українська, але з арабськими літерами в слові «Оперативна»	3	частково, зміст безглуздий
llama3.2:3b	українською, 2 речення	176	українська з англійськими словами	1	частково, мова зіпсована
qwen3:4b	лаконічний асистент	219	українська	2	так
qwen3:4b	українською, 2 речення	189	українська	2	так

Як видно з таблиці 3, qwen3:4b виконала обидві інструкції, а відповіді llama3.2:3b мають безглуздий зміст і сторонні слова.

Таблиця 4 - Витрати токенів

Модель	System	prompt_tokens	completion_tokens	total_tokens
llama3.2:3b	лаконічний асистент	59	50	109
llama3.2:3b	українською, 2 речення	63	55	118
qwen3:4b	лаконічний асистент	65	2186	2251
qwen3:4b	українською, 2 речення	74	745	819

Як видно з таблиці 4, qwen3:4b витратила 2186 токенів на відповідь у 219 символів. Майже всі вони пішли на приховане міркування.

Відповіді на питання (крок 6)

1. Яка модель точніше дотрималась обмеження «максимум двома реченнями»?

Відповідь: Обидві вклалися в два речення, але в Llama зміст безглуздий. Тому точніше відповіла qwen3:4b.

2. Чи були випадки, коли модель відповіла не українською?

Відповідь: Так. Llama3.2:3b вставила англійські слова («temporary Storage», «programas»), а в слові «Оперативна» з'явилися арабські літери.

3. Як змінився prompt_tokens при зміні system-повідомлення і чому?

Відповідь: Він зріс (59 до 63 у Llama, 65 до 74 у qwen), бо друге повідомлення довше, а воно теж входить у вхідні токени.

4. Чому в qwen3:4b completion_tokens значно більше?

Відповідь: У completion_tokens входять приховані токени міркування. У Llama3.2:3b такої чернетки немає.

Відповіді на питання (крок 7)

1. Чому моделі по-різному дотримуються інструкцій?

Відповідь: qwen3:4b спочатку планує відповідь і перевіряє обмеження, а Llama3.2:3b пише одразу. Також у Llama менше україномовних даних.

2. Чим system відрізняється від user і чи має більший пріоритет?

Відповідь: Для моделі це лише різні ролі в шаблоні чату. Перевага system з'являється через навчання, тому в малих моделях вона слабша.

3. Чому міркувальна модель витрачає більше вихідних tokenів?

Відповідь: Бо в completion_tokens входять і приховане міркування, і видима відповідь. Видимий текст - це лише мала частина.

4. Що станеться при суперечливих інструкціях у system і user?

Відповідь: Частіше модель слухає system, але гарантії немає. Мала модель може виконати суміш обох або останню інструкцію.

5. Чому малі моделі гірше тримають мову відповіді?

Відповідь: У них менше параметрів, а українська мова в навчальних даних представлена слабо. Тому вони зриваються на англійську, особливо на технічних термінах.

Висновок за завданням 2

System-повідомленням можна керувати поведінкою моделі, але воно працює ненадійно. qwen3:4b виконала обидві інструкції, а llama3.2:3b вставила англійські слова. Самої інструкції замало, особливо для малих моделей. Якщо модель її ігнорує, варто повторити вимогу в user-повідомленні, додати приклад, перевірити формат програмою або взяти більшу модель.

Завдання 3. Локальна vs хмарна модель: єдиний інтерфейс

Один і той самий код запущено для локальної llama3.2:3b і хмарної gemini-3.5-flash. Питання варіанта 4: «Поясни різницю між оперативною пам'яттю і жорстким диском. Коротко.» Спочатку я пробував gemini-3.8-flash, але вона давала помилку 503, тому залишив gemini-3.5-flash.

Таблиця 5 - Порівняння локальної та хмарної моделі

Показник	Локальна	Хмарна
Назва моделі	llama3.2:3b	gemini-3.5-flash
Час відповіді, с	3,04	5,21
completion_tokens	78	242
Довжина відповіді, символів	239	686
Мова відповіді	українська	українська
Фактичних помилок	1	0

Як видно з таблиці 5, локальна модель назвала оперативну пам'ять «постійною» і не пояснила різницю. Хмарна відповіла правильно й навела приклад зі столом і шафою.

Відповіді на питання (крок 5)

1. Скільки рядків коду довелося змінити?

Відповідь: У логіці програми жодного. Змінюється лише словник PROVIDERS (адреса, ключ і назва моделі).

2. Яка відповідь повніша й точніша?

Відповідь: Хмарна. Вона пояснила, що оперативна пам'ять тимчасова й очищується при вимкненні, а диск зберігає дані.

3. Чи були в локальній моделі помилки?

Відповідь: Так. Вона назвала RAM постійною пам'яттю, а в інших запусках вставляла англійські слова й навіть китайські ієрогліфи.

4. Чому хмарна модель відповіла швидше?

Відповідь: У моєму запуску вона була повільнішою (5,21 проти 3,04 с), бо відповідь утричі довша. За токен хмара швидша (близько 46 проти 26 за секунду), бо працює на потужному сервері.

Відповіді на питання (крок 6)

1. Чому формат OpenAI став стандартом?

Відповідь: OpenAI першою масово випустила такий API, і навколо нього з'явилися бібліотеки. Іншим провайдерам вигідно його підтримувати, бо розробник змінює лише адресу, ключ і модель.

2. Наскільки розмір моделі впливає на якість?

Відповідь: Сильно впливає на точність фактів: мала модель знає менше. Але важливі також дані навчання та донавчання.

3. Чому хмарні моделі генерують швидше?

Відповідь: Вони працюють на потужних GPU/TPU з швидкою пам'яттю, а саме пам'ять обмежує швидкість генерації. Затримка мережі додає лише частки секунди.

4. Які ризики приватності?

Відповідь: Запити потрапляють на чужі сервери, де можуть зберігатись. У компаніях укладають договори, вибирають регіон обробки, приховують чутливі дані, а найважливіше віддають локальним моделям.

5. Що таке rate limit?

Відповідь: Це обмеження кількості запитів за певний час. Його обходять через повтор запиту з затримкою, кешування, коротші промпти або платний тариф.

Висновок за завданням 3

Щоб перейти з локальної моделі на хмарну, достатньо змінити три значення в словнику провайдерів. Хмарна модель відповіла точніше, а локальна помилилась у факті. Локальну модель я б обрав, коли дані не можна відправляти назовні, немає інтернету або задача проста. Хмарну - коли потрібні точність і добра українська, але з ризиками: залежність від мережі, ліміти, збої (я сам отримав помилку 503) і передача даних на сервери.

Завдання 4. Вимірювання швидкості: TTFT і залежність від довжини запиту

Заміри робились у потоковому режимі. Для кожного пром프트 зроблено три запуски й взято медіану, перед серією був прогрів. Промпти варіанта 4: короткий «Столиця Бразилії?», середній «Поясни в одному абзаці, що таке рекурсія.», довгий «Напиши інструкцію з 10 пунктів, як підготуватися до технічної співбесіди.»

Таблиця 6 - Результати вимірювання швидкості

Розміщення	Модель	Промпт	TTFT, с	Всього, с	Симв./с
локальна	llama3.2:3b	короткий	2,093	2,387	23,9
локальна	llama3.2:3b	середній	2,101	2,865	97,0
локальна	llama3.2:3b	довгий	2,100	6,875	245,0
хмарна	gemini-3.5-flash	короткий	2,594	2,800	34,9
хмарна	gemini-3.5-flash	середній	4,550	5,167	111,1
хмарна	gemini-3.5-flash	довгий	22,377	29,062	147,4
локальна	qwen3:4b	короткий	12,204	12,289	2,8
локальна	qwen3:4b	середній	28,010	29,066	6,7
локальна	qwen3:4b	довгий	45,548	51,445	20,2

Як видно з таблиці 6, TTFT у llama3.2:3b майже не залежить від промπτу (близько 2,1 с), а в хмарної він росте до 22,4 с. У qwen3:4b TTFT найбільший (12-46 с), бо вона спочатку міркує приховано. Тому її швидкість у символах за секунду мала.

Таблиця 7 - Холодний і теплий старт локальної моделі (llama3.2:3b)

Показник	Холодний старт	Теплий старт
TTFT, с	4,823	2,075
Всього, с	5,108	2,261

Як видно з таблиці 7, холодний старт за TTFT у 2,3 раза довший. Різниця близько 2,7 с - це завантаження моделі з диска в пам'ять.




Рисунок 1 - Швидкість генерації: локальна та хмарна модель (символів за секунду)

На діаграмі лише llama3.2:3b і gemini-3.5-flash. Значення qwen3:4b на порядок нижчі, тому на діаграму не винесені.

Відповіді на питання (крок 6)

1. У якій моделі кращий TTFT і чому?

Відповідь: У локальній llama3.2:3b (близько 2,1 с проти 2,6, 4,6 і 22,4 с у хмарній). Запит не йде через мережу. У хмарній TTFT росте з довжиною промпту.

2. Чи збігається «найшвидша за TTFT» з «найшвидшою за символами/с»?

Відповідь: Не завжди. На короткому і середньому промптах Ллама виграє за TTFT, а хмарна - за швидкістю (34,9 проти 23,9 і 111,1 проти 97,0). На довгому промпті Ллама виграє за обома (245,0 проти 147,4).

3. Як змінилось співвідношення при переході від короткого промπτу до довгого?

Відповідь: Перевага хмарної за швидкістю зникла: відношення хмарна до локальної впало з 1,46 до 1,15 і 0,60. За загальним часом хмарна на довгому промπτі повільніша у 4,2 рази.

4. Наскільки різняться три повтори?

Відповідь: TTFT майже однаковий (різниця до 0,03 с), загальний час коливається до 19%, а швидкість у символах за секунду майже вдвічі. Одного запуску недостатньо.

5. Чому холодний старт повільніший?

Відповідь: Ollama спочатку завантажує модель з диска в пам'ять. У мене це дало TTFT 4,823 с проти 2,075 с.

Відповіді на питання (крок 7)

1. Що відбувається під час TTFT і чому його вимірюють окремо?

Відповідь: Запит доходить до моделі, обробляється весь промπτ і видається перший токен. Окремо його міряють, бо він показує, як швидко користувач побачить відповідь.

2. Чому хмарна модель може мати гірший TTFT, але кращу швидкість генерації?

Відповідь: До TTFT додаються мережа й черга на сервері. Після старту токени йдуть швидко на потужному обладнанні, але в мене це було видно лише на короткому й середньому промптах.

3. Чому перший запуск локальної моделі повільніший?

Відповідь: Це холодний старт: модель завантажується в пам'ять. Далі вона лишається там, поки її не вивантажить простій.

4. Чому беруть медіану кількох запусків?

Відповідь: Один вимір може мати випадковий шум (фонові процеси, мережа, навантаження сервера). Медіана стійка до поодиноких викидів.

5. Чому обробка запиту йде швидше, ніж генерація?

Відповідь: Токени запиту відомі наперед, тому їх обробляють паралельно.

Відповідь генерується по одному токenu, і для кожного читається вся модель з пам'яті.

Висновок за завданням 4

Для чат-бота важливіший TTFT, бо користувач дивиться на порожній екран: різниця між 2 і 22 с помітна одразу. Для фонові обробки великих текстів важливіші швидкість генерації та загальний час. Заміри мають шум, тому беруть медіану кількох запусків.

Завдання 5. Оцінювання якості моделей за рубрикою

Використано шість завдань: факт, формат JSON, стиснення тексту, код, логіка та українська мова. Кожне завдання виконано двічі для llama3.2:3b, qwen3:4b і gemini-3.5-flash (temperature 0,7), відповіді збережено в quality.json. Набір завдань складено до перегляду відповідей. У таблиці беремо гірший з двох прогонів.

Правильна відповідь для завдання 1: 1896 рік, перші сучасні Ігри пройшли в Афінах з 6 по 15 квітня [1][2]. Для завдання 3 я склав текст за даними статті [1]. У ньому є числа 6, 15, 1896, 241, 14, 43, 9, 108 і 2004. Формат у завданні 2 перевірено функцією json.loads(), код у завданні 4 запущено на чотирьох тестових списках.

«Перші сучасні Олімпійські ігри відбулися в Афінах і тривали з 6 по 15 квітня 1896 року. Вони проходили під егідою Міжнародного олімпійського комітету. У змаганнях узяв участь 241 спортсмен із 14 країн. Розіграли 43 комплекти медалей у 9 видах спорту. Ігри пройшли з великим успіхом, і після них лунали заклики проводити всі наступні Олімпіади саме в Афінах. Проте наступні змагання вже були заплановані в Парижі, тож до Греції Олімпійські ігри повернулися лише через 108 років, у 2004 році.»

Таблиця 8 - Оцінка якості за рубрикою

Завдання	llama3.2:3b	qwen3:4b	gemini-3.5-flash
1. Факт	2	2	2
2. Формат	0	2	2
3. Стиснення	0	2	1
4. Код	2	2	2
5. Логіка	0	1	2
6. Українська	0	0	2
Разом /12	4	9	11

Як видно з таблиці 8, найбільше балів набрала gemini-3.5-flash (11 із 12), далі qwen3:4b (9) і llama3.2:3b (4). У завданні 3 gemini втратила бал, бо додала «лише в Греції», чого в тексті не було. У завданні 5 qwen3:4b у другому прогоні назвала задачу «комбінаціями з повтореннями», хоча повторень немає. Результат правильний (28 і 7), але хід розв'язання не без помилки, тому 1 бал.

Таблиця 9 - Розбіжність оцінок між двома прогонами (так / ні)

Завдання	llama3.2:3b	qwen3:4b	gemini-3.5-flash
1. Факт	ні	ні	ні
2. Формат	так (0 і 2)	ні	ні
3. Стиснення	ні	ні	ні
4. Код	ні	ні	ні
5. Логіка	ні	так (2 і 1)	ні
6. Українська	ні	ні	ні

Як видно з таблиці 9, оцінки розійшлися у двох випадках: у llama3.2:3b у завданні 2 (0 і 2) і в qwen3:4b у завданні 5 (2 і 1).

Відповіді на питання (крок 6)

1. Яка модель набрала найбільше балів і де основна різниця?

Відповідь: Найбільше набрала gemini-3.5-flash (11 із 12). Основна різниця у завданнях 2, 3, 5 і 6: Llama провалила формат, стиснення, логіку й мову, а qwen втратила бали в логіці (1 бал) і в мові (0).

2. На яких завданнях оцінки двох прогонів розійшлися?

Відповідь: У двох випадках. У Llama на завданні 2 один JSON правильний, другий - купа вигаданих об'єктів, тож формат у малої моделі нестабільний. У qwen на завданні 5 один хід розв'язання без помилок, а в другому є неточний термін.

3. Чи виконала хоч одна модель вимогу «без markdown» у завданні 2?

Відповідь: Так, жодна модель не обгорнула JSON у markdown. Але перший JSON від qwen3:4b мав хибний рік (1900 замість 1896).

4. Чи були проблеми з українською мовою?

Відповідь: Так. Llama вставляла латиницю всередину слів («м'якеур»), а qwen вигадала «стеганський біг» і сказала, що слова «стаєрський» немає. gemini писала стабільно.

Крок 7. Приклад провалу

Обрано завдання 5 для Llama3.2:3b, перший прогін.

Повний текст запиту:

8 команд грають турнір, кожна з кожною по одному разу. Скільки всього матчів? Якщо грати по 4 матчі на день, скільки днів триватиме турнір? Покажи хід розв'язання.

Повний текст відповіді Llama3.2:3b:

Погляньмо на турнір, який складається з 8 команд. Кожна з команд гратиме по одному матчу з кожною з інших 7 команд.

Матчів за день: 8 команд x по 1 матч на команду - 8 матчів.

Турнір триває 8 команд x по 1 матч на команду - 8 матчів / 4 матчі на день = 2 дні.

Окончательный ответ - 2.

Правильна відповідь: 28 матчів ($8 \cdot 7 / 2 = 28$) і 7 днів ($28 / 4$).

Модель порахувала «по одному матчу на команду» і отримала 8 матчів. Вона забула, що в матчі грають дві команди, і не порахувала пари. Далі помилка пішла по ланцюжку: $8 \text{ матчів} / 4 = 2 \text{ дні}$. Хід розв'язання виглядає логічним, але правильності не дає. Також у кінці з'явилась російська фраза. Другий прогін llama взагалі закінчився відмовою.

Відповіді на питання (крок 8)

1. Які ще підходи до оцінювання якості моделей існують?

Відповідь: Бенчмарки з готовими відповідями (MMLU, GSM8K, HumanEval), порівняння людьми (Chatbot Arena) і оцінювання іншою сильною моделлю. У кожного є слабкі місця: дорого, суб'єктивно або тести потрапляють в навчання.

2. Чому моделі ігнорують заборону markdown при генерації JSON?

Відповідь: У навчальних текстах JSON майже завжди стоїть у блоках коду, тому така обгортка стала звичкою. Надійніше вмикати режим JSON і прибирати обгортку програмою.

3. Чому малі моделі гірше пишуть українською?

Відповідь: Українських текстів у навчанні мало, а в малої моделі небагато параметрів для граматики рідкісної мови. Звідси русизми, вигадані слова й англійські вкраплення.

4. Чому модель на однаковий запит дає різну якість?

Відповідь: Токени вибираються з розподілу ймовірностей. Одна невдала вибірка на початку змінює весь хід відповіді, тому роблять кілька запусків.

5. Що таке галюцинація і чому модель вигадує факти?

Відповідь: Це впевнена, але хибна відповідь. Модель пише найправдоподібніше продовження, а не перевіряє факти, і в навчанні майже немає зразків «я не знаю».

Висновок за завданням 5

Оцінка за рубрикою надійна там, де є об'єктивна перевірка: `json.loads()`, числа, запуск коду. Менш надійна вона для мови й спірних випадків (бал gemini за «лише в Греції» інший оцінювач міг би не знімати). Найпоказовіші завдання 2, 5 і 6,

бо саме вони розвели моделі. Для українського тексту я б обрав gemini-3.5-flash, бо тільки вона дала 2 бали за мову в обох прогонах.

Завдання 6. Керування випадковістю: temperature і top_p

Експерименти виконано на llama3.2:3b, кожне значення - 5 запусків. Творче завдання: «Придумай назву сервісу доставки домашньої їжі. Відповідай лише назвою.» Фактичне питання: «У якому році відбулися перші сучасні Олімпійські ігри? Відповідай лише роком.» Правильна відповідь: 1896 [1].

Таблиця 10 - Вплив параметрів на різноманітність відповідей

Параметр	Значення	Унікальних із 5 (творче)	Правильних із 5 (фактичне)
temperature	0,0	1	5
temperature	0,7	5	-
temperature	1,5	5	3
top_p	0,1	1	-
top_p	0,5	2	-
top_p	1,0	5	-

Як видно з таблиці 10, при temperature 0,0 модель п'ять разів видала «DomDom», а при 1,5 з'явилися безглузді слова («Коверхна дистамція»). У фактичному питанні при 1,5 були відповіді 1936 і 1952, тому правильних лише 3 з 5. top_p для творчого завдання запускався при temperature 0,7.

Таблиця 11 - Перевірка відтворюваності

Показник	Значення
Кількість запусків	10
temperature	0,0
Унікальних відповідей	1
Усі відповіді однакові (так / ні)	так

Як видно з таблиці 11, усі 10 відповідей були однаковими («1896.»).

Відповіді на питання (крок 7)

1. Яке значення температури для агента, що повертає JSON?

Відповідь: Близьке до 0, бо потрібна передбачуваність: при 0,0 усі 10 запусків дали одну відповідь.

2. Яке для генератора заголовків?

Відповідь: Приблизно 0,7-1,0. При 0,7 було 5 різних назв, при 1,5 вже безглузді.

3. Чим вплив `top_r` відрізняється від `temperature` за характером?

Відповідь: `top_r` відсікає малоймовірні варіанти (при 0,1 була одна назва), а `temperature` змінює самі ймовірності, і при високому значенні з'являються випадкові слова.

4. Чи означає `temperature=0` повну відтворюваність?

Відповідь: У моєму експерименті так: 10 з 10 однакових відповідей. Але гарантії немає, бо на результат можуть впливати обчислення з плаваючою комою.

5. Яка відповідь при `temperature=1,5` найбезглуздіша?

Відповідь: «Коверхна дистамція». Імовірно, обрався малоймовірний токен, і наступні слова будувались на ньому.

Відповіді на питання (крок 8)

1. Що `temperature` робить із розподілом ймовірностей?

Відповідь: Логіти діляться на `T` перед `softmax`. При `T` менше 1 лідер домінує сильніше, при `T` більше 1 розподіл вирівнюється.

2. Чим `top_r` відрізняється від `temperature`?

Відповідь: `temperature` змінює форму розподілу, а `top_r` відсікає хвіст і лишає токени із сумарною ймовірністю `p`.

3. Чи варто змінювати обидва параметри?

Відповідь: Зазвичай краще змінювати один, бо вони частково дублюють одне одного.

4. Чому при `temperature=0` відповідь не гарантовано однакова?

Відповідь: Через особливості обчислень на GPU мізерні відмінності можуть змінити вибір між двома майже рівними токенами.

5. Які значення використовують на практиці?

Відповідь: Для JSON, коду й фактів 0-0,3, для творчих завдань 0,7-1,0.

Висновок за завданням 6

temperature регулює випадковість, а не розумність. При 0,0 модель п'ять разів дала правильний рік, а при 1,5 лише три рази. Для лабораторних, де модель повертає структуровані дані, я поставлю temperature близько 0 (до 0,2), щоб JSON щоразу парсився. Значення за замовчуванням може не підійти, бо воно часто близьке до 0,7-1,0, і модель може зламати формат.

Крок 8. Підсумкове порівняння моделей

Таблиця 12 - Підсумкове порівняння моделей

Критерій	Локальна мала (3B) llama3.2:3b	Локальна більша (4B) qwen3:4b	Хмарна gemini-3.5-flash
Швидкість генерації, симв./с (довгий промпт)	245,0	20,2	147,4
TTFT, с (короткий / довгий промпт)	2,09 / 2,10	12,2 / 45,5	2,59 / 22,4
Якість, балів /12	4	9	11
Стабільність формату (завдання 2)	нестабільна (0 і 2)	стабільна (2 і 2)	стабільна (2 і 2)
Потрібні ресурси	2,0 ГБ на диску, GPU	2,5 ГБ на диску, GPU	інтернет і ключ API
Вартість	безкоштовно	безкоштовно	безкоштовний тариф, 20 запитів на добу
Куди йдуть дані	лишаються на ПК	лишаються на ПК	на сервери Google
Працює без інтернету	так	так	ні
Коли обирати саме її	дані не можна відправляти назовні, задача проста: короткі факти, чернетка коду	потрібні розрахунки й логіка локально, а затримка не важлива (12- 51 с)	потрібні якість, українська мова та стабільний формат, а дані не секретні

Швидкість qwen3:4b занижена через приховане міркування, а не через обладнання. Правило вибору просте: локальну модель беру, коли дані не можна віддавати назовні або немає інтернету, а задача проста й легко перевіряється.

Хмарну беру, коли важливі якість, українська мова й стабільний формат, і я готовий до залежності від мережі, лімітів та передачі даних.

Загальні висновки

- 1) Локальна й хмарна моделі працюють через один інтерфейс, тому перехід між ними потребує зміни лише трьох значень у словнику провайдерів;
- 2) Затримка складається з TTFT і швидкості генерації. На довгому промпті Llama мала TTFT 2,1 с, а хмарна 22,4 с, але на короткому хмарна була швидшою за символами за секунду, тому «яка модель швидша» без розділення цих показників сказати не можна;
- 3) Режим міркування корисний на багатокрокових задачах (qwen3:4b: 5 із 5 проти 1 із 5 у Llama) і зайвий на простих питаннях (206 токенів проти 5);
- 4) Інструкція в промпті ненадійно керує форматом і мовою: Llama вставляла англійські слова й видала 3334 символи сміттевого JSON, тому формат треба перевіряти програмою;
- 5) Відповіді моделей недетерміновані, тому потрібні повтори: швидкість локальної моделі між запусками відрізнялась майже вдвічі, а оцінки якості двох прогонів розійшлися в двох завданнях (у Llama на 2 бали, у qwen на 1);
- 6) При temperature 0,0 модель п'ять разів дала правильний рік, а при 1,5 лише три рази з п'яти, тому для фактів і JSON temperature має бути низькою;
- 7) За рубрикою gemini-3.5-flash набрала 11 балів із 12, qwen3:4b - 9, Llama3.2:3b - 4, але локальні моделі безкоштовні й не віддають дані назовні, тому вибір залежить від задачі.

Список використаних джерел

1. Вікіпедія. Літні Олімпійські ігри 1896.
https://uk.wikipedia.org/wiki/Літні_Олімпійські_ігри_1896
2. Енциклопедія сучасної України. Олімпійські ігри.
<https://esu.com.ua/article-76528>