НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ «ОДЕСЬКА ПОЛІТЕХНІКА»
МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
ІНСТИТУТ КОМП’ЮТЕРНИХ СИСТЕМ
КАФЕДРА ІНФОРМАЦІЙНИХ СИСТЕМ

Протокол лабораторної роботи №1
«розгортання середовища та порівняльний аналіз мовних моделей»
з дисципліни: «Обчислювальні методи»

Виконав(-ла): студент(-ка) групи АІ-244
Русаков Яків

Перевірив: ас. Баранов О.М.

Одеса – 2026

Конфігурація

- ОС / GPU: Google Colab (Linux, віртуальна машина з GPU NVIDIA T4); CPU/RAM окремо не знімалися
- Ollama: остання версія, встановлена скриптом `install.sh` у Colab; моделі: `llama3.2:3b`, `qwen3:4b`
- Хмарний провайдер: Groq (`https://api.groq.com/openai/v1`), модель `openai/gpt-oss-120b`
- Python: 3.x (середовище Google Colab)

Завдання 1. Міркувальна vs інструктивна модель

Дані — з реального запуску в Google Colab (GPU T4, Ollama). Сирі дані — у `task1_results.json`. Першому запиту до моделі передує її завантаження, тому час першого запиту може бути більшим.

Фактичне питання («Столиця України? Відповідай одним словом.»)

Таблиця 1 – Фактичне питання «Столиця України? Відповідай одним словом.»

Показник	qwen3:4b	llama3.2:3b
`response`	«Київ»	«Київ.»
`eval_count`	723	5
Час, с	16.3	2.2
Токенів/с	55.9	86.1

Задача на міркування (середнє з 5 запусків; правильна відповідь — 5 грн)

Таблиця 2 – Задача на міркування (середнє з 5 запусків)

Показник	qwen3:4b	llama3.2:3b
Правильних із 5	5	0
`eval_count`	1184	201
Час, с	24.6	3.4

Окремі запуски. qwen3:4b: eval_count 1180 / 1116 / 1427 / 1162 / 1037, час 23.6 / 24.9 / 29.3 / 23.6 / 21.5 с — у всіх п'яти відповідь «5 грн» через систему рівнянь і перевірку. llama3.2:3b: відповіді 50, 90, 100, 100, 100 грн — жодної правильної; у всіх п'яти відповідь написана російською й суржиком («Давайте проанализируем ситуацию…»), хоча питання українською. Прапорець `correct_auto` у JSON хибний для всіх запусків qwen3:4b: автоперевірка шукала «5 грн», а модель записує відповідь як `\boxed{5}`. Тому кількість правильних визначено вручну, прочитавши відповіді.

Спостереження. (1) На простому питанні qwen3:4b згенерував у 145 разів більше токенів (723 проти 5) за ту саму відповідь «Київ». Швидкість генерації близька (56 і 86 токенів/с), а загальний час на задачі міркування різниться в ~7 разів (24.6 проти 3.4 с) — через обсяг роботи. (2) У першому запуску цього завдання qwen3:4b на те саме питання відповів «Киев» (російською), у другому — «Київ»: відповідь моделі недетермінована. (3) Саме на задачі з пасткою (інтуїтивно «10 грн») перевагу міркувальної моделі видно найкраще: 5/5 проти 0/5.

Відповіді чат-бота на 5 питань (стисло)

1. *Куди пішли токени?* У прихований ланцюжок міркувань («thinking»): модель спершу розписує варіанти, перевіряє себе й лише потім видає коротку відповідь. Ці токени генеруються й рахуються в `eval_count`, хоча користувач їх не бачить (у нас 723 токени проти 5 за однакове «Київ»).

2. *Де міркувальні моделі виграють?* На задачах із кількома кроками, пастками й перевіркою (арифметика, логіка, код, планування); у нас 5/5 проти 0/5 на задачі про ручку й зошит. На простих фактах, форматуванні й перефразуванні вони невиправдані: дорожче й повільніше без виграшу в якості.
3. *Чим відрізняється навчання?* Інструктивна модель донавчається на парах «інструкція — відповідь» і за оцінками людей. Міркувальну додатково навчають з підкріпленням на задачах із перевірною відповіддю, заохочуючи довгі ланцюжки міркувань, що ведуть до правильного результату.
4. *Чи означає більше токенів «розумніша»?* Ні: кількість токенів — це витрати, а не якість. На простому питанні вони були зайвими; користь залежить від типу задачі.
5. *Чому різна швидкість (токенів/с)?* Розмір і архітектура моделі (4B проти 3B), довжина контексту, який росте під час довгого міркування, квантизація та навантаження GPU. У нас 56 проти 86 токенів/с; різниця в загальному часі (24.6 проти 3.4 с) переважно від кількості токенів.

Висновок за завданням 1

Міркувальну модель варто вмикати лише там, де інтуїтивна відповідь може бути хибною (задачі з пасткою), і не використовувати для простих фактів. Інструктивна мала модель швидка, але на логіці дає впевнено хибні відповіді й до того ж відповіла російською на україномовне питання. Автоперевірку відповіді (`correct_auto`) треба ретельно налаштовувати: вона не розпізнала правильні відповіді у форматі `\boxed{5}`.

Завдання 2. Роль system-повідомлення

Питання варіанта: «Поясни різницю між реляційною і документоорієнтованою базою даних.» (`temperature=0.7`). Кількість речень — оцінка скрипта за розділовими знаками.

Таблиця 3 – Вплив system-повідомлення

Модель	System	Довжина відповіді, символів	Мова відповіді	Кількість речень	Інструкцію виконано?
llama3.2:3b	лаконічний асистент	2126	українська, але з вкрапленнями чужих слів («tabela», «dokumentів», «różниці», «Each», «flexibility»)	≈18	ні: відповідь розгорнута, а не лаконічна
llama3.2:3b	українською, 2 речення	308	українська з одним чужим словом («liênками», «Documentoорієнтованої»)	2	так (довжина й кількість речень), мова з дефектами
qwen3:4b	лаконічний асистент	141	українська	3	так
qwen3:4b	українською, 2 речення	298	українська	2	так

Таблиця 4 – Витрати токенів

Модель	System	`prompt_tokens`	`completion_tokens`	`total_tokens`
llama3.2:3b	лаконічний асистент	60	641	701
llama3.2:3b	українською, 2 речення	64	91	155
qwen3:4b	лаконічний асистент	69	3107	3176
qwen3:4b	українською, 2 речення	78	638	716

Відповіді на питання

1. *Яка модель точніше дотрималась обмеження «максимум двома реченнями»?* Обидві вклалися у 2 речення з другим system-повідомленням. Але з першим («лаконічний асистент») llama3.2:3b видала ≈18 речень, а qwen3:4b — стислі 141 символ. Тому інструкціям щодо довжини надійніше слідує qwen3:4b.
2. *Чи були випадки, коли модель відповіла не українською?* Повністю російською чи англійською — ні, але llama3.2:3b в обох відповідях вставляла слова іншими мовами й алфавітами («tabela», «różниці», «Each», «liênками»). У qwen3:4b таких дефектів не було (проте на простому питанні в завданні 1 він відповів «Киев» російською).
3. *Як змінився* `prompt_tokens`*?* Він зріс на 4 (llama: 60 → 64) і на 9 (qwen: 69 → 78), бо друге system-повідомлення довше: токени системного тексту входять у запит. Різниця між моделями — через різні токенізатори й службову розмітку шаблону чату.
4. *Чому в qwen3:4b* `completion_tokens` *значно більший?* Токени прихованого міркування (`thinking`) теж рахуються як згенеровані: 3107 токенів при 141 символі видимого тексту.

Відповіді чат-бота на 5 питань (стисло)

1. *Чому по-різному дотримуються інструкцій?* Модель не «виконує команди», а продовжує текст за найімовірнішим сценарієм, сформованим навчанням. Інструкції про довжину й мову конкурують зі звичками моделі (детальні відповіді на питання про бази даних), і слабша модель частіше виграє на користь звички.
2. *Чи має system більший пріоритет?* Формально це лише інша роль у шаблоні чату; пріоритет вчать під час донавчання, тому він не абсолютний і залежить від моделі. Тому system-повідомленню довіряють більше, ніж user, але без гарантій.
3. *Чому міркувальна модель витрачає більше токенів?* Бо приховане міркування рахується як вихідні токени, навіть коли видима відповідь коротка (у нас 3107 токенів при 141 символі).
4. *Що буде при суперечливих інструкціях?* Зазвичай модель надає перевагу system, але результат нестабільний: може виконати user-інструкцію, змішати обидві або відповісти невпевнено. Тому суперечностей у промптах краще уникати.
5. *Чому малі моделі гірше дотримуються мови?* Менше параметрів і менше україномовних даних у навчанні; модель легко «зісковзує» на домінуючу мову (англійську, російську), а в довгій відповіді помилки накопичуються (у нас чужі слова й алфавіти в llama3.2:3b).

Висновок за завданням 2

System-повідомленням можна керувати поведінкою, але не надійно: llama3.2:3b проігнорувала «лаконічність» (≈18 речень), хоча з жорсткішою інструкцією («2 речення») впоралася. Тому інструкцію треба формулювати конкретно (кількість речень, мова), а критичні вимоги перевіряти кодом і за потреби повторювати запит або міняти модель.

Завдання 3. Локальна vs хмарна модель

Питання варіанта: «Поясни різницю між реляційною і документоорієнтованою базою даних. Коротко.» (`temperature=0.7`; локально — Ollama на GPU Google Colab).

Таблиця 5 – Локальна та хмарна модель

Показник	Локальна	Хмарна
Назва моделі	llama3.2:3b	openai/gpt-oss-120b (Groq)
Час відповіді, с	12.97 (у першому запуску — 43.28: модель завантажувалась у пам'ять)	1.45
`completion_tokens`		

	215	537 (з них 51 — `reasoning_tokens`)
Довжина відповіді, символів	765	1449
Мова відповіді	українська з дефектами: арабська літера в слові («ʒakhистовуються»), «tabel», русизм «ключей», нісенітниця «Наглянувши ці відрізи»	українська, природна; термінологія (ACID, JOIN, шардинг) коректна
Фактичних помилок у відповіді	≈2–3 (оцінка): CSV названо форматом документів; «SEARCH» подано як запит документних БД; таблиці описано як «множество даних»	0 (оцінка)

Оцінка кількості помилок суб'єктивна: перевірте її самі, перечитавши відповіді вище.

Відповіді на питання

1. *Скільки рядків коду довелося змінити?* У програмі — жодного: `compare.py` однаковий для обох провайдерів. Відмінності винесено в словник `PROVIDERS` у `providers.py` — три значення: `base_url`, `api_key`, `model`.
2. *Яка відповідь повніша й точніша?* Хмарна. Вона називає транзакції ACID, різницю в масштабуванні (вертикальне проти горизонтального), роль JOIN і приклади СУБД (PostgreSQL, MongoDB). Локальна вигадує «SEARCH» як запит і плутає формати.
3. *Чи були в локальної моделі помилки або проблеми з українською?* Так: чужі символи й слова (арабська літера, «tabel»), русизм «ключей», кострубаті фрази.
4. *Чому хмарна відповіла швидше, попри мережу?* Хмарна модель працює на спеціалізованому серверному обладнанні й завжди завантажена, а її відповідь пішла зі швидкістю в сотні токенів за секунду. У локальній відповіді час 12.97 с включає повторне завантаження моделі в пам'ять (`cached_tokens=0`), тому порівняння не зовсім рівне; мережева затримка (десятки мілісекунд) на тлі секунд генерації майже не впливає.

Додатково. Хмарна модель проігнорувала слово «Коротко»: видала довгу структуровану відповідь із markdown (537 токенів проти 215), тобто більша модель не гарантує виконання інструкції про довжину.

Відповіді чат-бота на 5 питань (стисло)

1. *Чому формат OpenAI став стандартом?* OpenAI першою масово зробила API чат-моделей, і навколо нього з'явилися бібліотеки й інструменти. Провайдери (Groq, Ollama та інші) підтримують сумісний інтерфейс, щоб користувачі переходили без переписування коду.
2. *Наскільки розмір впливає на якість?* Сильно для знань, міркування й мовної якості, але не єдиний фактор: важливі дані навчання, донавчання, квантизація, промпт і параметри. У нашому прикладі різниця велика: 3B вигадує факти, 120B відповідає точно.
3. *Чому хмарна швидша попри мережу?* Потужні серверні GPU, відсутність завантаження моделі (вона вже в пам'яті) й оптимізований інференс дають сотні токенів/с; мережева затримка (десятки мс) мала порівняно з виграшем.
4. *Ризики приватності?* Дані покидають вашу інфраструктуру: можливі зберігання, логування, навчання на запитах, витоки. У комерційних проєктах використовують угоди про обробку даних (DPA), режим без збереження, маскування персональних даних, приватні розгортання або локальні моделі.
5. *Що таке rate limit?* Обмеження на кількість запитів і токенів за період на безкоштовному тарифі. Його «обходять» легально: кешують відповіді, групують запити, повторюють із затримкою (backoff), чергують моделі або переходять на платний тариф.

Висновок за завданням 3

Локальну модель обираю, коли дані конфіденційні, потрібна робота без мережі або завдання просте й формальне (форматування, витяг даних із наданого тексту). Хмарну — коли потрібні знання, міркування й гарна українська, а передача даних назовні допустима. Різниця в якості між llama3.2:3b і gpt-oss-120b на нашому питанні така велика, що для змістовних відповідей локальна 3B-модель недостатня.

Завдання 4. Швидкість: TTFT

Промпти варіанта: короткий — «Столиця Мексики?»; середній — «Поясни в одному абзаці, що таке рекурсія.»; довгий — «Напиши інструкцію з 10 пунктів, як задокументувати проєкт.» Медіана з 3 повторів після прогріву; значення — з другого (теплого) запуску `benchmark.py`.

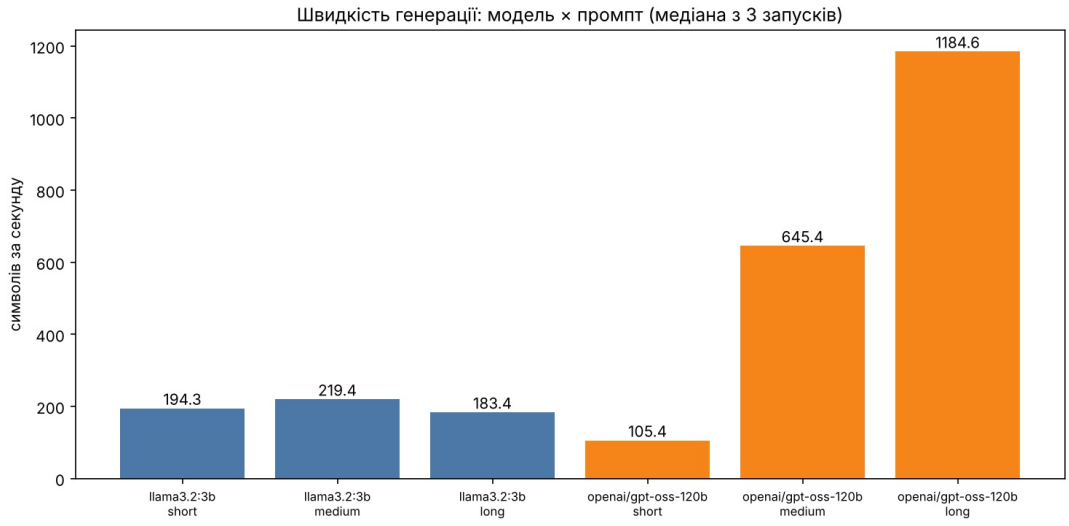
Таблиця 6 – Результати вимірювання швидкості

Розміщення	Модель	Промпт	TTFT, с	Всього, с	Симв./с
локальна	llama3.2:3b	короткий	0.029	0.502	194.3
локальна	llama3.2:3b	середній	0.033	1.430	219.4
локальна	llama3.2:3b	довгий	0.073	8.303	183.4
хмарна	openai/gpt-oss-120b	короткий	0.375	0.414	105.4
хмарна	openai/gpt-oss-120b	середній	0.350	0.618	645.4
хмарна	openai/gpt-oss-120b	довгий	0.353	2.285	1184.6

Холодний і теплий старт локальної моделі. Холодний — перший запит (прогрів «розігрів») одразу після `ollama stop llama3.2:3b`; теплий — перший запит наступного запуску, коли модель вже в пам'яті. Порівнювати варто TTFT: повний час залежить від довжини відповіді.

Таблиця 7 – Холодний і теплий старт локальної моделі

Показник	Холодний старт	Теплий старт
TTFT, с	4.484	0.446
Всього, с	8.731	6.534



Відповіді на питання

1. *У якої моделі кращий TTFT і чому?* У локальної: 0.03–0.07 с проти 0.35–0.38 с у хмарної. Запит не

йде мережею, модель мала й уже в пам'яті GPU; у хмарної в TTFT входять мережева дорога, TLS, черга на сервері й обробка запиту великою моделлю.

2. *Чи збігається «найшвидша за TTFT» з «найшвидшою за символами/с»?* Ні. За TTFT виграє локальна, а за швидкістю генерації на середньому й довгому промптах — хмарна (645 і 1185 симв./с проти 219 і 183). На короткому промпті локальна швидша й за символами/с (194 проти 105), бо відповідь коротка й домінує накладна затримка хмари.
3. *Як змінилося співвідношення при переході від короткого до довгого?* На короткому загальний час майже однаковий (0.50 с локальна проти 0.41 с хмарна). На довгому хмарна швидша приблизно в 3.6 раза за загальним часом (2.3 проти 8.3 с) і в 6.5 раза за симв./с: початкова затримка поступається швидкості генерації.
4. *Наскільки різняться три повтори? Чи достатньо одного запуску?* TTFT повторів коливається в межах десятків відсотків (хмара довгий: 0.298–0.412 с; локальна довгий: 0.040–0.077 с). Показові й два запуски скрипта: медіана `total_s` довгого промпту локальної моделі була 4.5 с в одному запуску і 8.3 с у другому (різна довжина відповіді). Одного вимірювання недостатньо.
5. *Чому холодний старт повільніший?* Під час холодного старту ваги моделі читаються з диска й завантажуються в пам'ять GPU, і лише потім починається обробка запиту: TTFT 4.48 с проти 0.45 с.

Відповіді чат-бота на 5 питань (стисло)

1. *Що відбувається під час TTFT?* Модель обробляє весь вхідний запит (prefill), будує кеш уваги й генерує перший токен; для хмари додаються мережа, TLS і черга. Його вимірюють окремо, бо він визначає відчуття «чат відповідає одразу», а швидкість генерації — як швидко відповідь дописується.
2. *Чому хмара може мати гірший TTFT, але кращу швидкість?* Мережева дорога й черга додають десятки-сотні мс до першого токена, а потужне обладнання потім генерує токени набагато швидше (у нас 0.35 с TTFT, але 1185 симв./с на довгому промпті проти 183 локально).
3. *Що таке холодний старт?* Перший запит після простою вимагає завантажити ваги з диска в пам'ять (GPU); у нас TTFT 4.48 с проти 0.45 с у теплому режимі.
4. *Чому медіана?* Окремі запуски дають викиди через завантаження системи, мережу, кеші; медіана стійка до викидів, одне значення — ні.
5. *Чому вхід обробляється швидше за генерацію?* Вхідні токени обробляються паралельно одним проходом, а вихідні генеруються по одному, кожен залежить від попереднього.

Висновок за завданням 4

Для інтерактивного чат-бота важливіший TTFT (відчуття миттєвої реакції) і стабільність, для фонової обробки великих обсягів тексту — пропускна здатність (токени або символи за секунду) і ціна. У наших вимірах локальна модель виграє за TTFT, а хмарна — за швидкістю на довгих відповідях.

Завдання 5. Якість за рубрикою

Завдання варіанта 8 (тема «Туризм»):

1. Факт: рік відкриття нинішньої будівлі Одеського оперного театру. **Правильна відповідь: 1887** (відкрито 13 жовтня 1887 р.). Джерело: Вікіпедія — Одеський театр опери та балету.
2. Формат: JSON `landmark`, `city`, `year`.
3. Стиснення тексту про Одеський оперний театр до двох речень зі збереженням чисел (1810, 800, 1873, 1884, 1887, 2007; текст — у `quality.py`).
4. Код: `trip_cost(days, daily_cost, transport)` = `days * daily_cost + transport`.

5. Логіка: поїздка 6 днів, житло 900/добу, їжа 500/день, дорога 2400, троє, житло й дорога порівну. Прийнято трактування «їжа 500/день — на людину»: (6·900 + 2400)/3 + 6·500 = 2600 + 3000 = **5600 грн**. Альтернативне трактування (їжа 500/день — спільний бюджет групи) дає 2600 + 1000 = 3600 грн; нижче вказано, як змінилися б оцінки.
6. Українська мова: «Чим хостел відрізняється від готелю».

Оцінки виставлено за рубрикою з методички; для кожної моделі враховано обидва прогони (оцінки двох прогонів збіглися в усіх 18 випадках, тому розбіжностей між оцінками немає). Оцінки — мої; перевірте їх, перечитавши `quality.json`, і за потреби виправте.

Таблиця 8 – Бали за рубрикою

Завдання	llama3.2:3b	qwen3:4b	openai/gpt-oss-120b
1. Факт	0	0	2
2. Формат	2	2	2
3. Стиснення	0	2	2
4. Код	2	2	2
5. Логіка	0	0 (2 при трактуванні 3600)	2
6. Українська	0	1	2
Разом /12	**4**	**7** (9 при трактуванні 3600)	**12**

Обґрунтування оцінок:

- **1. Факт.** llama: «1867», «1867» — однакові, але хибні (стабільна галюцинація) → 0. qwen: «1931» і «1870» — різні й обидві хибні → 0. gpt-oss: «1887», «1887» → 2.
- **2. Формат.** `check_format.py`: усі 6 відповідей парсяться `json.loads()` без правок, markdown немає → 2 бали всім. (Зміст полів не оцінюється: llama видала «Одесяновський оперний театр», роки 1907 і 1892; qwen — 1861 і 1893; gpt-oss — 1887, 1887.)
- **3. Стиснення.** llama: обидва прогони втратили числа (1873, 1884, у другому ще й 2007); у першому ще й вступна фраза → 0. qwen: у обох прогонах усі числа збережені, 2 речення → 2. gpt-oss: так само → 2 (граматична помилка «відкритою» мову не впливає на оцінку цього завдання).
- **4. Код.** У всіх одна й та сама коректна функція. У gpt-oss код обгорнуто в markdown-блок «```python» попри «Лише код» — код працює, тому 2, але це та сама слабкість формату.
- **5. Логіка.** llama: 1800 і 1266,67 грн — хибно, хід розв'язання містить помилки → 0. qwen: 3600 грн (їжа розподілена між трьома) — хибно за основним трактуванням, правильно за альтернативним; хід розв'язання послідовний. gpt-oss: 5600 грн із ходом і перевіркою → 2; у другому прогоні вказано й альтернативу 3600, але фінальна відповідь 5600.
- **6. Українська.** llama: перший прогін — марковані списки замість двох абзаців, нісенітниця («Готельна робота: готельці працюють в режимі повного працівництва»), англійські слова «reception, concierge»; другий — безглуздий (кваліфікація персоналу) → 0. qwen: два абзаци по суті, але русизми й помилки («гость», «їду» замість «їжа», «довгий перебування», «відкриті відділи») → 1. gpt-oss: природна українська, два змістовні абзаци (дрібниці: «дормі», «майстер-класси») → 2.

Розбіжність оцінок між двома прогонами (так / ні)

Таблиця 9 – Розбіжність оцінок між двома прогонами

Завдання	llama3.2:3b	qwen3:4b	openai/gpt-oss-120b
1. Факт	ні (обидва 0; відповіді однакові)	ні (обидва 0; **відповіді різні**: 1931 і 1870)	ні

2. Формат	ні	ні	ні
3. Стиснення	ні	ні	ні
4. Код	ні	ні	ні
5. Логіка	ні (0 і 0; відповіді різні: 1800 і 1266,67)	ні (3600 і 3600)	ні
6. Українська	ні	ні	ні

Відповіді на питання

1. *Яка модель набрала найбільше балів і на яких завданнях основна різниця?* openai/gpt-oss-120b — 12 із 12; qwen3:4b — 7; llama3.2:3b — 4. Різниця у фактах (1), логіці (5) і мові (6): там, де потрібні знання, багатокрокове міркування чи гарна українська, мала модель провалюється.
2. *На яких завданнях оцінки двох прогонів розійшлися?* Оцінки не розійшлися ніде. Але самі відповіді розійшлися: qwen3:4b на питання про рік назвав 1931 і 1870, llama на логіці — 1800 і 1266,67. Оцінки збіглися, бо в слабких моделей провал системний, а не випадковий; розбіжність відповідей при хибності обох показує, що факт моделлю вигадується.
3. *Чи виконала хоч одна модель вимогу «без markdown» у завданні 2?* Так, усі три: усі 6 відповідей парсяться без правок. Очікуваного «обгортання в `json`» не сталося. Але вимогу «лише код» у завданні 4 gpt-oss-120b порушив (обгортка python), тобто розмір моделі не гарантує дотримання формату.
4. *Чи були проблеми з українською мовою?* Так. llama3.2:3b: чужі слова й алфавіти, російська замість української (у задачі міркування), безглузді конструкції. qwen3:4b: русизми й помилки роду («гость», «їду», «довгий перебування»). gpt-oss-120b: лише дрібні огріхи.

Крок 7. Приклад провалу — завдання 1 (факт), обидві малі моделі.

- *Запит (повністю):* «Рік відкриття нинішньої будівлі Одеського оперного театру. Відповідай лише роком.»
- *Відповіді (повністю):* llama3.2:3b — «1867.» і «1867.»; qwen3:4b — «1931» і «1870».
- *Правильна відповідь:* 1887 (відкриття 13 жовтня 1887 р.).
- *Чому так сталося:* це галюцинація. Модель не має бази даних, а генерує найправдоподібніший рік у такому форматі. Факт про регіональну споруду був у навчанні слабко представлений, тому модель замість «не знаю» видає впевнене число. Показово, що qwen3:4b дав два різні роки: стабільність відповіді була б ознакою знання, а розкид — ознака вигадки. llama двічі видала той самий хибний рік, тобто послідовність теж не гарантує правильності. Тому для фактів потрібні RAG або інструменти, а не пам'ять моделі.

Відповіді чат-бота на 5 питань (стисло)

1. *Інші підходи до оцінювання?* Стандартизовані бенчмарки (MMLU, GSM8K, HumanEval), порівняння «наосліп» людьми (арени), оцінка іншою моделлю як суддею (LLM-as-a-judge), автоматичні метрики (ROUGE, exact match), тести на безпеку та власні набори завдань для конкретного продукту.
2. *Чому ігнорують «без markdown»?* У навчанні JSON дуже часто зустрічається в блоках коду, тому модель відтворює звичну форму; інструкція лише одна з сигналів. Надійніше вмикати режим structured output або чистити відповідь кодом.
3. *Чому гірше українською?* Україномовних даних у навчанні менше, ніж англомовних, токенізація менш ефективна, звідси русизми, чужі слова, помилки роду.
4. *Чому відповіді різної якості?* Вибірка токенів випадкова (temperature > 0), мікророзбіжності обчислень і стан сервера змінюють розподіл; навіть при 0 повна відтворюваність не гарантована.

5. *Що таке галюцинація?* Правдоподібна, але хибна відповідь. Модель навчена продовжувати текст правдоподібно, а не перевіряти істинність; визнання незнання рідкісне в даних і не завжди закріплене донавчанням.

Висновок за завданням 5

Рубрика достатньо надійна для грубого порівняння (4 / 7 / 12 з 12), але оцінки суб'єктивні, особливо логіка (5600 чи 3600) і мовна якість; тому оцінювали два прогони. Найпоказовіші завдання — факт (галюцинація), логіка й українська мова; формат (завдання 2) і код не розрізнили моделі. Для україномовного тексту я обрав би хмарну gpt-oss-120b; із локальних — qwen3:4b, бо вона краща за llama3.2:3b, хоча й допускає русизми.

Завдання 6. temperature і top_p

Локальна модель `llama3.2:3b`. Творче завдання: «Придумай назву сервісу обміну речами. Відповідай лише однією назвою.» Фактичне: «Рік першого польоту людини в космос. Відповідай лише роком.» Правильна відповідь — **1961** (Ю. Гагарін, «Восток-1», 12 квітня 1961 р.). Джерело: Вікіпедія — Восток-1.

Таблиця 10 – Вплив temperature і top_p

Параметр	Значення	Унікальних із 5 (творче)	Правильних із 5 (фактичне)
temperature	0.0	1	5
temperature	0.7	4	—
temperature	1.5	5	5
top_p	0.1	1	—
top_p	0.5	4	—
top_p	1.0	5	—

Творчі відповіді: при `temperature=0.0` — «Реча в обмен» ×5; при 1.5 — «Fonet», «Гласом», «Vozlyku», «TALKBOXER», «Речбажем»; при `top_p=1.0` — «Реча в обмену», «Реча в обмен», «SpeechHub», «Вокальна Піраміда», «VoiceSwap». Фактичне питання при `temperature=1.5`: «1961 рік.», «1961 рік», «1961.», «1961.», «1961» — усі п'ять правильні, відрізняється лише оформлення.

Таблиця 11 – Повторюваність при temperature = 0

Показник	Значення
Кількість запусків	10
temperature	0.0
Унікальних відповідей	1
Усі відповіді однакові (так / ні)	так

Відповіді на питання

1. *Температура для агента з JSON:* 0 (або близько 0.1): потрібна передбачуваність, а не різноманітність.
2. *Для генератора варіантів заголовків:* 0.7–1.0: достатньо різноманітності, але ще без безглуздих слів, які з'явилися при 1.5.
3. *Чим top_p відрізняється за характером?* Він відсікає «хвіст» малоймовірних токенів, тому при 0.1 відповіді однакові, а при 0.5 лишаються варіації одного кореня («Реча в обмен/обмін/на місці»). Температура ж розплющує весь розподіл і при 1.5 випускає в текст зовсім сторонні слова та

алфавіти.

4. *Чи означає temperature=0 повну відтворюваність?* У нашому експерименті 10 запусків дали 1 унікальну відповідь, тобто так, але це лише спостереження для цієї моделі й цього запиту. Гарантії немає (обчислення з плаваючою комою, паралелізація), у наступних лабораторних частина різниці між версіями агента може бути шумом.
5. *Найбезглуздіша відповідь при 1.5:* «Gласом» (латинська G усередині кириличного слова) і «Vozlyku». Модель вибрала токени з «хвоста» розподілу, у якому є слова інших мов і скриптів; при плоскому розподілі такі токени мають помітний шанс.

Додаткові спостереження. (а) Навіть при `temperature=0` «Реча в обмен» — це неграмотна назва: мала модель слабка в українській незалежно від температури. (б) Очікувалося, що при `temperature=1.5` модель вигадуватиме різні роки, але в 5 запусках усі відповіді були правильні: факт про Гагаріна модель знає «міцно», тож температура зіпсувала форму, а не зміст.

Відповіді чат-бота на 5 питань (стисло)

1. *Що робить temperature?* Ділить логіти (оцінки токенів) на T перед softmax: при T<1 розподіл «гострішає» і домінує найімовірніший токен, при T>1 вирівнюється і зростає шанс рідкісних токенів; $T \to 0$ дає жадібний вибір.
2. *Чим top_p відрізняється?* Це відсікання: з токенів, відсортованих за ймовірністю, лишають найменшу множину з сумою ≥ p і вибирають лише з неї. Temperature змінює форму розподілу, top_p обрізає хвіст.
3. *Змінювати обидва чи один?* Зазвичай один: їх ефекти перетинаються й важко розрізнити внесок кожного. Практична порада — змінювати temperature, залишаючи top_p за замовчуванням, або навпаки.
4. *Чому при T=0 відповіді можуть різнитися?* Через нестабільність обчислень з плаваючою комою на GPU, порядок паралельних операцій, пакетування запитів і оновлення моделі на стороні сервера; у нашому локальному експерименті відповіді збігалися, але гарантій немає.
5. *Типові значення?* Для витягу структурованих даних 0–0.2, для відповідей на питання 0.3–0.7, для творчого тексту 0.7–1.0 (інколи вище).

Висновок за завданням 6

Для наступних лабораторних, де модель має повертати структуровані дані (аргументи інструментів, JSON), використовую `temperature = 0`: потрібні відтворюваність і передбачуваність (у лабораторній 2 й 3 так і зроблено). Налаштування «за замовчуванням» (≈0.7–1.0) може виявитися непридатним: повторні запуски дають різні відповіді, що псує тести й ускладнює налагодження; при 1.5 модель узагалі видає слова з чужих мов.

Підсумок

Таблиця 12 – Підсумкове порівняння моделей

Критерій	Локальна мала (3B): llama3.2:3b	Локальна більша (4B): qwen3:4b	Хмарна: openai/gpt-oss-120b
Швидкість генерації	183–219 симв./с; 86 токенів/с	≈50–56 токенів/с (+ приховане міркування: тисячі токенів)	645–1185 симв./с на середньому й довгому промптах
TTFT	0.03–0.07 с (теплий); 4.5 с (холодний)	не вимірювався (benchmark лише для llama3.2:3b)	0.35–0.38 с
Якість,	4	7	12

балів /12			
Стабільність формату (завдання 2)	2/2	2/2	2/2 (але порушив «лише код» у завданні 4)
Потрібні ресурси	кілька ГБ пам'яті на диску й у RAM/VRAM, бажано GPU	те саме, трохи більше; довга генерація через міркування	лише мережа й API-ключ
Вартість	безкоштовно (своє обладнання)	безкоштовно (своє обладнання)	безкоштовний тариф з лімітами на запити
Куди йдуть ваші дані	залишаються на комп'ютері	залишаються на комп'ютері	надсилаються провайдеру (Groq)
Працює без інтернету	так	так	ні
Коли обирати саме її	конфіденційні дані, робота без мережі, прості формальні задачі (формат, витяг із наданого тексту, простий код); не для фактів і логіки	потрібна точність у логіці й задачах із пасткою, час і приватність важливі менше; не для простих фактів	потрібні знання, міркування й якісна українська, і дані можна передавати назовні