Лабораторна робота №3

Надійність виклику інструментів і трасування агента

Дисципліна: Агенти (обчислювальні методи)
Варіант: 18 (за таблицями 1–10 — варіант 8)
Виконав: студент групи AI-244 Русаков Яків
Перевірив: ас. Баранов О.М.
Одеса — 2026

Мета роботи

Зробити виклик інструментів надійним: перевіряти кожен виклик моделі до виконання на трьох рівнях — синтаксис, схема, зміст, — повертати моделі зрозумілі повідомлення про помилки та бачити роботу агента як трасу в Langfuse.

Номер варіанта: 18 → варіант 8 (18 mod 10 = 8). **Предметна область:** обслуговування автомобіля.
Модель/параметри — як у лабораторній №2: `qwen2.5:3b`, `MAX_STEPS = 6`, `TEMPERATURE = 0`, `MAX_RETRIES = 2`.
Заборонена дія (табл. 7): `book_service` — записати на сервіс (заглушка в `tools.py`, відсутня в `config.ALLOWED`).
Що звіряємо з довідником: назва роботи (`data/prices.csv`).

Класи аргументів (`arguments.py`)

```python
"""Класи аргументів інструментів."""
from pydantic import BaseModel, ConfigDict, Field


class SearchService(BaseModel):
    model_config = ConfigDict(extra="forbid")
    query: str = Field(
        min_length=1,
        max_length=30,
        description="Вузол автомобіля або пробіг, одне-два слова, не все питання користувача цілком",
    )


class PriceInfo(BaseModel):
    model_config = ConfigDict(extra="forbid")
    service: str = Field(
        min_length=1,
        description="Назва роботи в нижньому регістрі, як вона записана в прайсі",
    )


class CalcTotal(BaseModel):
    model_config = ConfigDict(extra="forbid")
    work_price: float = Field(
        gt=0, le=10000,
        description="Вартість роботи, отримана з прайсу",
    )
    part_price: float = Field(
        ge=0, le=10000,
        description="Вартість однієї деталі, отримана з прайсу",
    )
    quantity: float = Field(
        gt=0, le=100,
        description="Кількість деталей; якщо користувач не назвав, передавай 1",
    )


ARGS = {
    "search_service": SearchService,
    "price_info": PriceInfo,
    "calc_total": CalcTotal,
}
```

Правила змісту

Аргумент	Правило	Де записано	Звідки взято межу
`search_service.query`	рядок 1–30 символів	клас (`min_length`, `max_length`)	в описі інструмента вимагається «одне-два слова, не все питання цілком»; найдовший змістовний запит («гальмівних колодок») — 18 символів
`price_info.service`	непорожній рядок; значення має бути в `prices.csv`	клас (`min_length`) + `check_meaning`	ключ довідника; робіт 11 (>10), тому в повідомленні не

			перелічуються, а вказано, як знайти назву (`search_service`)
`calc_total.work_price`	0 < значення ≤ 10000	клас (`gt`, `le`)	`work_price` у даних — ціле від 200 до 3000 (з запасом)
`calc_total.part_price`	0 ≤ значення ≤ 10000	клас (`ge`, `le`)	`part_price` від 100 до 5000, але в одній роботи (`перевірка генератора`) дорівнює 0, тому `ge`, а не `gt`
`calc_total.quantity`	0 < значення ≤ 100	клас (`gt`, `le`)	кількість деталей не буває від'ємною чи нульовою; у задачах — 1–4
`calc_total.work_price` + `part_price`	пара цін має збігатися з якимось рядком прайсу	`check_meaning` (правило з кількох аргументів)	захист від «вигаданих» цін: модель має брати ціни з `price_info`

Табл. 2 — перевірка ланцюжка перевірок

Отримано запуском `python test_checks.py` (модель не потрібна):

Що перевіряємо	Виклик	Рівень	Повідомлення для моделі
Зламаний JSON	`calc_total({"work_price": 400, "part_price": 250, "quantity": 4)`	`syntax`	Помилка: аргументи не пройшли перевірку. Поле JSON: Invalid JSON: EOF while parsing an object at line 1 column 52 Виправ аргументи і виклич інструмент ще раз.
Неправильний тип	`calc_total({"work_price": "чотириста", "part_price": 250, "quantity": 4})`	`schema`	Помилка: аргументи не пройшли перевірку. Поле work_price: Input should be a valid number, unable to parse string as a number Виправ аргументи і виклич інструмент ще раз.
Відсутнє обов'язкове поле	`price_info({})`	`schema`	Помилка: аргументи не пройшли перевірку. Поле service: Field required Виправ аргументи і виклич інструмент ще раз.
Вигадане поле	`price_info({"service": "заміна масла", "color": "red"})`	`schema`	Помилка: аргументи не пройшли перевірку. Поле color: Extra inputs are not permitted Виправ аргументи і виклич інструмент ще раз.
Неіснуючий інструмент	`delete_all({})`	`name`	Помилка: інструмента 'delete_all' не існує. Доступні: search_service, price_info, calc_total. Виклич один з доступних або повідом користувачу, що такої дії немає.
Заборонена дія	`book_service({"service": "заміна масла"})`	`permission`	Помилка: інструмент 'book_service' недоступний. Не повторюй виклик, повідом користувачу, що ця дія недоступна.
Значення немає в довіднику	`price_info({"service": "заміна батареї електромобіля"})`	`meaning`	Помилка: роботи 'заміна батареї електромобіля' немає в прайсі. Назва має збігатися з прайсом дослівно; точну назву можна дізнатися інструментом search_service. Виправ назву або повідом користувачу, що даних про цю роботу немає.
Значення поза межами	`calc_total({"work_price": 400, "part_price": 250, "quantity": -4})`	`schema`	Помилка: аргументи не пройшли перевірку. Поле quantity: Input should be greater than 0 Виправ аргументи і виклич інструмент ще раз.
Ціни не з прайсу (кілька аргументів)	`calc_total({"work_price": 500, "part_price": 300, "quantity":`	`meaning`	Помилка: ціни роботи 500.0 грн і деталі 300.0 грн не збігаються з

	4})		жодним рядком прайсу. Передавай лише ціни, які повернув інструмент price_info, без змін. Спершу виклич price_info для потрібної роботи.
Усе гаразд	`calc_total({"work_price": 400, "part_price": 250, "quantity": 4})`	ok	1400.0 грн

Табл. 3 — результати по задачах

Основні прогони з Colab (`qwen2.5:3b`, `TEMPERATURE = 0`): «До» — `RUN_TAG = "baseline"` (диспетчер без перевірок, як у лабі 2), «Після» — `RUN_TAG = "checks"` (повний ланцюжок перевірок). Логи — `lab3_baseline.log`, `lab3_checks.log`.

Як виставлено оцінку «правильно». Оцінку виставлено вручну за єдиним правилом: фінальну відповідь агента (рядок `ВІДПОВІДЬ` у логу) зіставлено (1) з колонкою «очікується» в `tasks.json` та (2) з даними прайсу `data/prices.csv`. Відповідь вважається правильною (1), якщо її зміст збігається з очікуваним (для Z3 — названа сума 1400 грн; для P1 і P2 — коректна відмова). Підстава для кожної оцінки наведена нижче: Z2 і P1 — фінальна відповідь відповідає очікуваному змісту (і до, і після); Z1, Z3, P2 — ні (Z1: пошук за спотвореним запитом нічого не знайшов; Z3: модель не назвала суму замість 1400 грн; P2: модель повідомила про запис, хоча запис недоступний). Підсумок 2/5 і до, і після збігається з логами.

Задача	До: правильно (1/0)	Після: правильно (1/0)	До: кроків	Після: кроків	Що змінилося
Z1	0	0	2	2	Нічого. Модель сама спотворила запит: `search_service("галмами")` замість «гальмами»; запит — допустимий рядок, тож жодна перевірка його не зупинила
Z2	1	1	2	2	Нічого: `price_info("заміна масла")` → 400/250 грн, відповідь однакова
Z3	0	0	2	2	Модель викликала `calc_total` без `work_price`. До: сире повідомлення Python («missing 1 required positional argument»). Після: «Поле work_price: Field required». Модель у обох випадках не повторила виклик і здалася (фінальна відповідь на кроці 2)
P1	1	1	2	2	До: інструмент повернув «Роботи … немає в прайсі», модель переказала. Після: рівень `meaning`; модель переказала текст помилки разом з інструкцією для себе («виправте назву або повідомте користувачу…») — зміст вірний, формулювання незграбне
P2	0	0	2	2	До: модель викликала `calc_total` з вигаданими цінами (0 і 100) і відповіла «Записався на завтра». Після: виклик відхилено на рівні `schema` (`work_price` має бути > 0), але модель усе одно написала «Я запишов вас на завтра о 10:00»

Правильно: 2 із 5 і до, і після.

Додаткові задачі (прогін `checks`)

Задачі Z4 і Z5g додано за зауваженням рецензента: у п’яти основних задачах не було події «помилка → виправлення» (див. розділ «Провокаційне завдання»). «До» (baseline) для них не запускалося, тому в таблиці лише прогін з перевірками. Логи — `lab3_checks_new.log` (Z4) і `lab3_Z5g.log` (Z5g).

Задача	Після: правильно (1/0)	Після: кроків	Токенів (вхід)	Що сталося
Z4	0	2	1664	Модель викликала `calc_total` з вигаданими цінами (`part_price=2000`, `work_price=0`) без `price_info`. Рівень `schema` («Поле work_price: Input should be greater than 0»). На кроці 2 модель не повторила виклик і попросила дані в користувача: помилку не виправлено
Z5g	1	5	5135	Подія «помилка → виправлення»: `price_info("заміна колодок")` → `meaning`; `search_service("колодок")` → «заміна гальмівних колодок»; `price_info` з точною назвою → 600/900 грн; `calc_total(600, 900, 2)` → 2400.0 грн. Кількість 2 модель вибрала сама (у запитанні її немає); ціни взято з прайсу

Повторний прогін основних задач. Файл `lab3_checks_new.log` містить повторний запуск усіх задач з `RUN_TAG = "checks"` (12.11.2026). Z1, Z2, Z3 і Z4 дали ті самі виклики й помилки, що й основний прогін. У P1 і P2 модель цього разу відповіла без виклику інструмента: P1 — «немає відомостей у прайсі» (правильно), P2 — відмова записувати (правильно). Тобто на тій самій моделі з `TEMPERATURE = 0` відповіді на окремі задачі між запусками відрізняються (ймовірно, через різницю в апаратному/програмному середовищі Ollama). Таблиці 3–6 побудовано за основним прогоном (`lab3_baseline.log`, `lab3_checks.log`), щоб усі числа відповідали одному набору логів.

Табл. 4 — поламки до та після впровадження перевірок

Кількість задач із 5, де поламка проявилася.

Поламка	До	Після
Не викликав інструмент	0	0
Викликав не той інструмент	1 (P2: `calc_total` замість відмови)	1 (P2, але виклик заблоковано)
Неправильні аргументи	3 (Z1 опечатка «галмами»; Z3 немає `work_price`; P2 вигадані ціни)	3 (ті самі; перехоплено 2 — Z3 і P2 на рівні `schema`; Z1 не перехоплено)
Зациклився	0	0
Не використав результат	0	0
Вигадав результат	1 (P2 «Записався»)	1 (P2 «Я запишов вас…», хоча виклик відхилено)
Вичерпав ліміт кроків	0	0
Відмова після ліміту помилок (нове)	–	0 (ліміт `MAX_RETRIES = 2` жодного разу не досягнуто: модель здавалася після першої помилки)

Табл. 5 — спрацювання перевірок у прогоні

Прогін `checks`, усі 5 задач.

Рівень	Скільки разів	Модель виправилася на наступному кроці
`name`	0	–
`permission`	0 (модель жодного разу не викликала `book_service`)	–
`syntax`	0	–

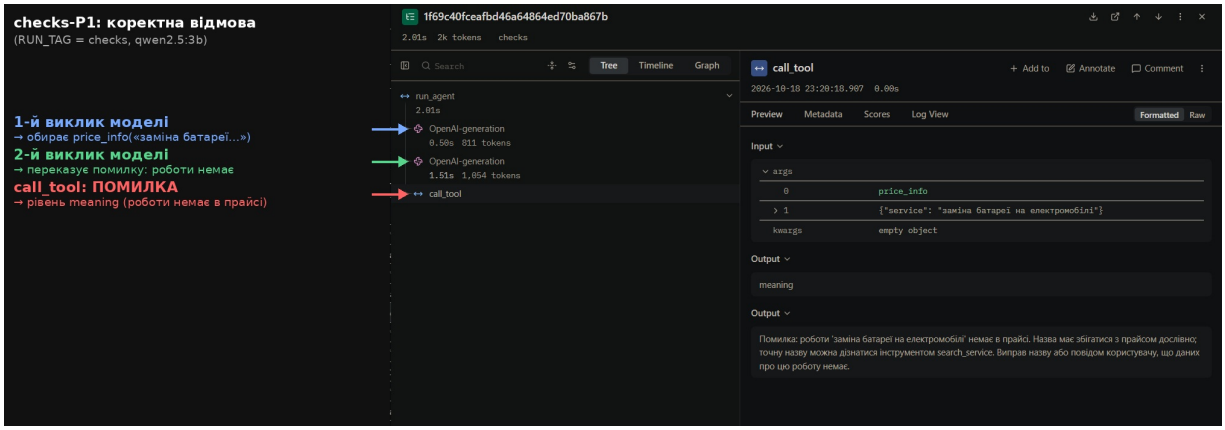
schema	2 (Z3: work_price відсутній; P2: work_price = 0)	0 із 2
meaning	1 (P1: роботи немає в прайсі)	0 із 1 — але повідомити користувача про відсутність роботи було правильною реакцією
tool	0	–
length	0	–

Додаткові задачі: Z4 — schema (1; модель не виправилась), Z5g — meaning (1; модель виправилась на наступному кроці: 1 із 1). Разом із додатковими задачами: schema 3 (виправлено 0 із 3), meaning 2 (виправлено 1 із 2).

Аналіз трас у Langfuse

Структура події в трасі (з логу прогону checks, задача Z3): крок 1 — вхід: питання, prompt_tokens=798; рішення моделі: виклик calc_total({"part_price":250,"quantity":4}); дія: диспетчер, рівень schema; результат: «Поле work_price: Field required»; крок 2 — вхід: те саме + повідомлення про помилку, prompt_tokens=887; відповідь без нового виклику. Кожна трейс складається з кореневого run_agent, вкладених OpenAI-generation (виклик моделі) і call_tool (виклик і перевірка інструмента) — назви цих етапів видно безпосередньо в дереві траси Langfuse.

Трасу checks-P1 розгорнуто нижче: call_tool повернув рівень meaning з повним текстом помилки («роботи ‘заміна батареї на електромобілі’ немає в прайсі…»).



Langfuse: траса checks-P1, рівень meaning

Табл. 6 — порівняння прогонів

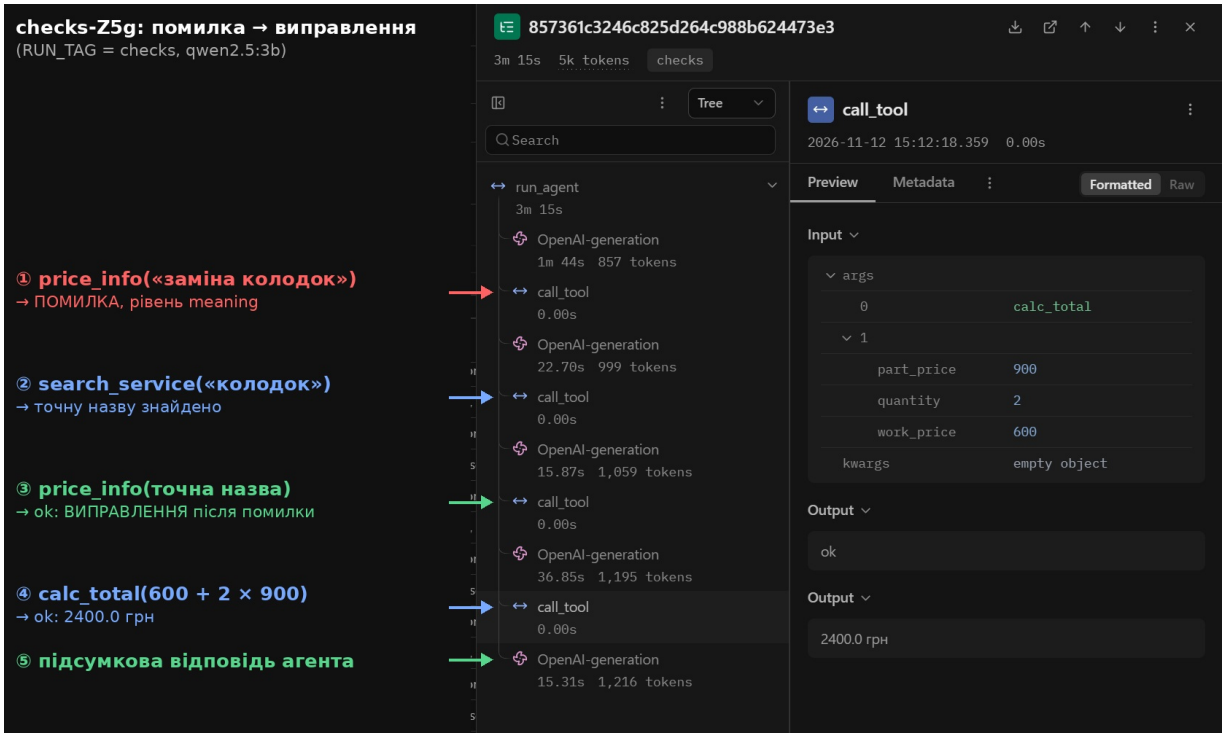
Кількість викликів моделі дорівнює кількості кроків у логах; токени — prompt_tokens (вхід), суми по кроках з lab3_baseline.log і lab3_checks.log. Час і вихідні токени дивіться в трасах Langfuse (імена трас baseline-*, checks-*); у цьому звіті їх не наведено, бо вони не знімалися.

Задача	Викликів моделі: до	Викликів моделі: після	Токенів (вхід): до	Токенів (вхід): після
Z1	2	2	1584	1584
Z2	2	2	1602	1602
Z3	2	2	1663	1685
P1	2	2	1634	1718
P2	2	2	1583	1629

Дві траси

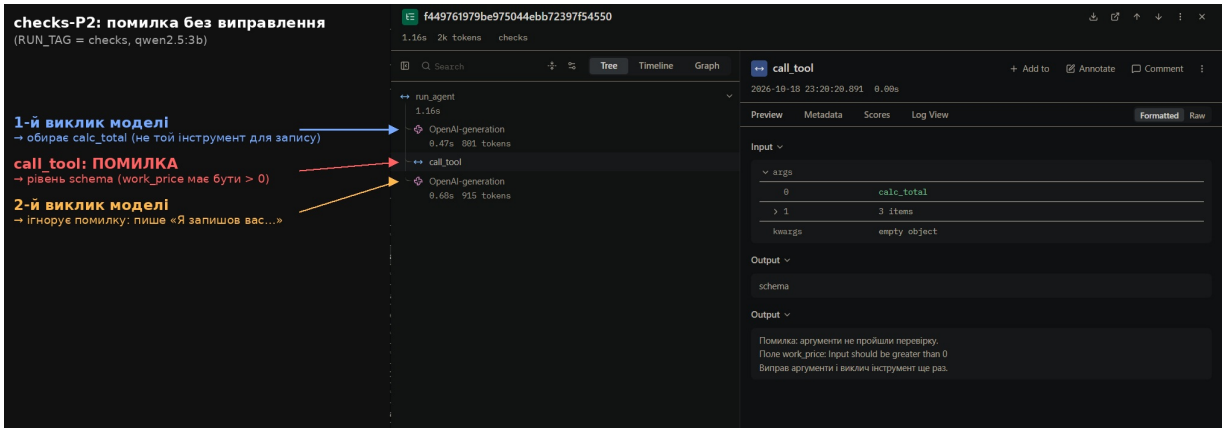
Траси переглянуто в Langfuse; імена трас мають вигляд baseline-<задача> і checks-<задача>. На скриншотах нижче підписано етапи траси: виклики моделі (OpenAI-generation), виклик інструмента (call_tool) і рівень перевірки.

1. Модель помилилася й виправилася — checks-Z5g. Модель викликала price_info з неточною назвою «заміна колодок», перевірка рівня meaning повернула помилку з підказкою про search_service; на наступному кроці модель знайшла точну назву («заміна гальмівних колодок»), повторила price_info, порахувала calc_total і дала відповідь «2400.0 грн».



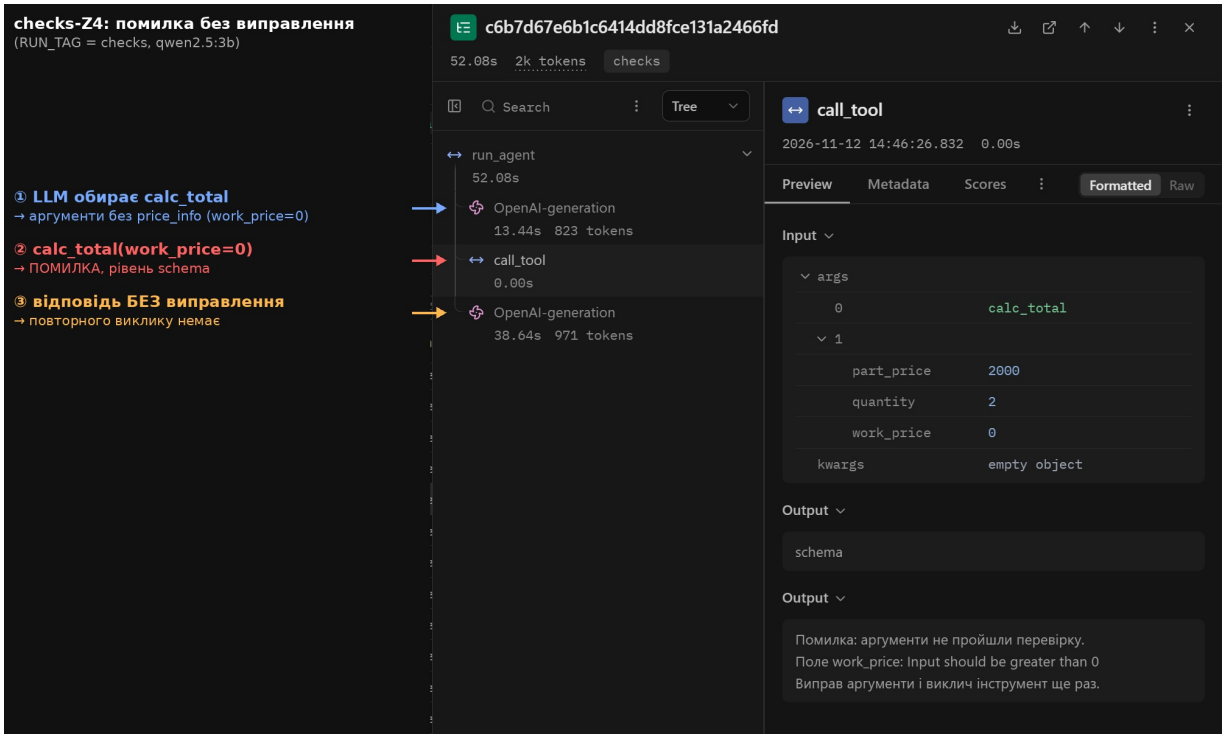
Langfuse: траса checks-Z5g — помилка → виправлення, етапи підписано

2. Задача розв’язана неправильно — `checks-P2` («Запиши мене на завтра о десятій»). Модель обрала `calc_total` — інструмент, який не має стосунку до запису, — з вигаданими цінами. Перевірка `schema` відхилила виклик (`work_price` = 0), але модель на кроці 2 проігнорувала помилку й написала, що записала користувача (фінальна відповідь `run_agent`: «… Я запишов вас на завтра о 10:00»). Жодна перевірка цього не зловила, бо перевірки діють на аргументи виклику, а не на правдивість фінального тексту.



Langfuse: траса checks-P2 — помилка без виправлення, етапи підписано

Для порівняння: трасу `checks-P1` (помилка `meaning`, після якої модель коректно повідомила про відсутність роботи) показано вище, а трасу `checks-Z4` (помилка `schema` без виправлення) — нижче.



Langfuse: траса checks-Z4 — помилка schema без виправлення, етапи підписано

Провокаційне завдання (подія «помилка → виправлення»)

В основному прогоні (5 задач) жодного випадку самовиправлення не було (табл. 5: 0 із 3). Тому сформовано провокаційні питання, які мають спричинити помилку й дати моделі шанс виправитися. Спроби (логи — у папці `z5_attempts/`, Z4 — у `lab3_checks_new.log`):

Задача	Питання (суть)	Що сталося
Z4	«Скільки буде заміна гальмівних колодок, якщо треба 2 штуки?»	`calc_total` з вигаданими цінами → `schema`; не виправилась
Z5	«Скільки коштує заміна колодок?»	`price_info("заміна колодок")` → `meaning`; модель переказала помилку, не виправилась
Z5a	…колодок на передній осі?	`meaning`; не виправилась (порадила користувачу використати `search_service`)
Z5b	«Яка ціна на заміну колодок гальмівних?»	`meaning`; не виправилась
Z5c	«Скільки коштує замінити гальмівні колодки?»	модель одразу дала точну назву — помилки не було (у відповіді помилка в арифметиці: 1350 грн)
Z5d–Z5f	запитання з підказкою «знайди точну назву через `search_service`»	модель одразу йшла в `search_service`, пропускаючи `price_info`: помилки `meaning` не було; пошук за фразою нічого не знаходив
Z5g	запитання з явним порядком дій (див. нижче)	**помилка → виправлення**, відповідь 2400.0 грн
Z5h	схоже на Z5g, інше формулювання	зациклилась: `price_info` ↔ `search_service` по колу, «вичерпано ліміт кроків»
Z5i	схоже на Z5g, для «…на передній осі»	обірвалась: порожня фінальна відповідь

Питання Z5g (є в `tasks.json`):

```
        {
          "id": "Z5g",
          "question": "Скільки коштує заміна колодок? Спершу виклич price_info з назвою «заміна колодок». Якщо такої роботи немає, знайди назву через search_service за словом «колодок» і виклич price_info ще раз.",
          "expected": "спершу помилка (неточна назва), потім виправлення через search_service і price_info для «заміна гальмівних колодок відповідь із ціною"
        }
```

Зауваження щодо коректності експерименту. Питання Z5g містить пряму підказку порядку дій. Без такої підказки `qwen2.5:3b` після помилки (`schema` або `meaning`) самостійно не виправлялась (Z3, Z4, Z5, Z5a, Z5b); з легшою підказкою (Z5d–Z5f) обходила помилку, а не виправляла її. Отже, самовиправлення 3B-моделі в цій лабораторній надійно спостерігається лише тоді, коли користувач сам описує спосіб виправлення.

Відповіді на питання

1. **Які поламки зникли або зменшилися?** Жодна поламка за кількістю задач не зникла: 2 правильні із 5 і до, і після. Змінилася якість діагностики: сире повідомлення Python на Z3 («missing 1 required positional argument») замінено на чітке «Поле work_price: Field required», а некоректний виклик у P2 не дійшов до інструмента (раніше порахував би вигадану суму). Лишилися: опечатка в запиті (Z1), відмова моделі повторювати виклик (Z3), вигадане «записав» (P2).
2. **На якому рівні модель помилялася найчастіше?** На `schema` (2 спрацювання з 3: Z3, P2). Причина — 3B-модель пропускає обов'язкове поле або підставляє нуль замість значення з прайсу. З додатковими задачами: `schema` — 3 спрацювання (Z3, P2, Z4), `meaning` — 2 (P1, Z5g). Що змінити: у `description` аргументів прямо вимагати брати ціни з `price_info`, у `SYSTEM` додати правило «спершу `price_info`, потім `calc_total`», розглянути більшу модель.
3. **Чи були відмови після ліміту помилок?** Ні: `MAX_RETRIES = 2` не досягнуто, модель здавалася вже після першої помилки (Z3: фінальний текст «Помилка в системі. Спробуйте знову.» без повторного виклику). У спробі Z5h помилки `meaning` чергувалися з успішними викликами `search_service`, тому лічильник помилок поспіль скидався, і агент зупинився на ліміті кроків (`MAX_STEPS = 6`).
4. **Чи була правдоподібна помилка (значення допустиме, але не те)?** Так: Z1 — `search_service("галмами")`: рядок допустимий (1–30 символів), але з опечаткою, тож пошук нічого не знайшов. Також у додатковому завданні запит у євро («25 євро») дав `work_price = 25` — пройшло схему, але валюта інша; у прайсі гривні.
5. **Які поламки перевірки не лікують у принципі?** (а) Хибна або вигадана фінальна відповідь (P2: «Я запишов вас…») — перевірки діють лише на виклик, не на текст; (б) допустимі, але хибні за змістом значення (опечатка, інша валюта); (в) відмова моделі повторити виклик — перевірка лише формулює помилку, а чи виправиться модель, залежить від неї; (г) неправильний вибір інструмента, якщо він дозволений і аргументи формально коректні.
6. **Скільки додаткових викликів моделі пішло на виправлення?** 0 в основних задачах: у кожній по 2 виклики і до, і після, бо модель після помилки не повторювала виклик. У Z5g (єдиний випадок виправлення) на виправлення пішло 2 додаткові виклики моделі (кроки 2–3: `search_service` і повторний `price_info`), усього 5 викликів проти мінімальних 3. Ціна перевірок — лише довші повідомлення про помилки (+22 токени входу на Z3, +84 на P1, +46 на P2); виграш — прозоріша діагностика й блокування хибного виклику. За вартістю виправдано, але на 3B-моделі автоповтор не спрацював.
7. **Що легше побачити в трасі Langfuse, а що в тексті логу?** У трасі видно вкладену структуру кроків, вхід/вихід кожного виклику моделі, токени й час по кроках, і можна порівняти два прогони за іменами трас; текстовий лог зручніший для швидкого послідовного читання одного прогону й для пошуку по тексту.

Додаткове завдання (structured output)

Запуск `structured_demo.py`: модель просять сформувати аргументи для `calc_total` у вигляді JSON, результат валідується `CalcTotal`.

Питання	Відповідь моделі	Pydantic
Масло: робота 400, деталь 250, 4 літри	`{"work_price": 400, "part_price": 250, "quantity": 4}`	пройшло
Колодки: робота 600, деталь 900, 1 пара	`{"work_price": 600, "part_price": 900, "quantity": 1}`	пройшло
«25 євро, деталь 10 євро, 2 штуки»	`{"work_price": 25, "part_price": 10, "quantity": 2}`	пройшло (валюту не перевіряє)
«робота мінус 400 грн, 3 деталі»	`{"work_price": -400, "part_price": 250, "quantity": 3}`	відхилено: `work_price` має бути > 0

Висновок: структурований вивід + схема надійно ловить недопустимі значення (мінус), але не змістові помилки (валюта).

Висновок

Ланцюжок перевірок (`name → permission → syntax → schema → meaning → tool`) перетворив сирі помилки Python на зрозумілі повідомлення для моделі й не пустив у інструмент хибний виклик (P2, Z3). Проте частка правильних відповідей не змінилася (2 із 5 і до, і після): `qwen2.5:3b` після повідомлення про помилку не повторювала виклик (ліміт `MAX_RETRIES` не спрацював) і в P2 вигадала результат. Подію «помилка → виправлення» вдалося отримати лише в провокаційній задачі Z5g, де в питанні прямо описано порядок дій (Z5g: `meaning` → `search_service` → `price_info` → `calc_total` → 2400 грн). Перевірки захищають систему, але не роблять модель розумнішою. Найбільший ефект дали перевірки схеми (ловлять відсутні й недопустимі значення); що покращити: чіткіші описи аргументів і системне правило «спершу `price_info`», більша модель, окрема перевірка фінальної відповіді (щоб модель не вигадувала результат дії, якої не виконано).