Міністерство освіти і науки України
Національний університет «Одеська політехніка»
Навчально-науковий інститут комп’ютерних систем
Кафедра інформаційних систем

Лабораторна робота № 1
З дисципліни: «Методи обчислення»
Тема: «Розгортання середовища та порівняльний аналіз мовних моделей»

Виконав:
Студент групи AI-244
Ткачук С. С.
Перевіряє:
Баранов О. М.

Одеса 2026

Мета роботи

Навчитися керувати локальними й хмарною мовними моделями через єдиний API, порівняти їхню продуктивність і якість відповідей та дослідити вплив temperature і top_p на стабільність результатів.

Індивідуальне завдання

Варіант 10. Порівняти синхронне й асинхронне виконання коду; виміряти відповіді на промпти про столицю Австралії, рекурсію та розгортання вебзастосунку; оцінити шість завдань теми «Техніка» й дослідити семплювання назв застосунку пішохідних екскурсій.

Статус виконання

Виконано всі 124 передбачені основні спроби. Штатно завершено 122; обривів за лімітом токенів - 2; транспортних помилок у підсумковому наборі - 0. Прогріви не враховано. Обірвані відповіді Qwen оцінено як невиконання відповідних завдань за встановлених умов.

Усі числові результати отримано з первинних відповідей API. Для оцінювання застосовано рубрику 0-2, перевірки JSON і коду та змістовий аналіз відповідей; пояснення кожного бала збережено у quality_review.json. Автоматичні перевірки та остаточні оцінки збережено окремо.

1 Конфігурація й відтворення

Параметр	Значення
Система локальних вимірів	Windows-11-10.0.26300-SP0
Python	3.15.0
CPU	AMD64 Family 23 Model 8 Stepping 2, AuthenticAMD
Логічні процесори	16
Локальна інструктивна	llama3.2:3b
Локальна міркувальна	qwen3:4b
Хмарна модель (налаштування)	openai/gpt-oss-120b

Команди підготовки й запуску наведено в README.md. Залежності: openai, python-dotenv, matplotlib, reportlab, python-docx; файл .env виключено з Git. Повні версії середовища зберігаються в environment.json.

Методика: для швидкості - окремий прогрів кожного провайдера, три послідовні повтори кожного промпту, медіана; для якості - два прогони шести умов на трьох моделях; для семплювання - по п'ять повторів і додаткові десять при temperature=0.

Локальні результати зібрано на ПК студента з Windows 11 і Python 3.15.0. Хмарні результати дозібрано 20.10.2026 у допоміжному середовищі Linux/Python 3.12.14 через той самий OpenAI SDK. Через різні клієнтські середовища й мережеві маршрути пряме порівняння затримок має обмеження: таблиця описує ці конкретні виміри й не доводить загальної переваги обладнання чи провайдера.

Початкові хмарні запити до llama-3.3-70b-versatile повертали HTTP 404. Після перевірки доступних моделей використано openai/gpt-oss-120b; повторено лише 22 хмарні запити, локальні результати збережено. Початковий набір і журнал відновлення містяться у provenance. Джерело зміни доступності моделей: https://console.groq.com/docs/deprecations.

TTFT фіксується після першого непорожнього фрагмента видимого тексту, а не після заголовків чи службового пакета. Символи/с = len(text)/total_s - наскрізна швидкість, що включає TTFT; вона відрізняється від чистої швидкості декодування токенів/с.

Завдання 1. Ціна роздумів

Модель	Відповідь на факт	eval_count	Час, с	Токенів/с
qwen3:4b	Киев	175	2.964	62.798
llama3.2:3b	Київ.	5	0.463	113.859

Модель	Правильних / 5	Середнє eval_count	Середній час, с
qwen3:4b	5/5	1304.600	23.040
llama3.2:3b	0/5	181.800	2.035

Для задачі про ручку: x + (x + 100) = 110; 2x = 10; x = 5 грн. Повні відповіді перевірено за змістом: Qwen дала правильний результат у 5 із 5 спроб, Llama - у 0 із 5. Шаблон correct_hint не розпізнає LaTeX-оформлення числа, тому остаточні позначки правильності зберігаються в reasoning_review.json.

На фактичному запиті Qwen згенерувала 175 токенів проти 5 у Llama - у 35 разів більше. У Qwen поле thinking має 517 символів, а фінальна відповідь «Киев» подана російською; у Llama відповідь «Київ.». На задачі про ручку середній час Qwen становив 23,040 с проти 2,035 с у Llama, але додатковий час супроводжувався суттєво вищою точністю саме цього тесту.

Завдання 2. Вплив system-повідомлення

Запит: «Поясни різницю між синхронним і асинхронним виконанням коду». concise - лаконічний технічний асистент; uk_two - лише українською, максимум двома реченнями.

Модель	System	Символи	Мова	Речень	Виконання інструкції
llama3.2:3b	concise	803	змішана	6	ні
llama3.2:3b	uk_two	277	змішана	2	ні
qwen3:4b	concise	264	українська	2	так
qwen3:4b	uk_two	238	українська	2	так

Модель	System	prompt_ tokens	completion_ tokens	total_ tokens
llama3.2:3b	concise	59	241	300
llama3.2:3b	uk_two	63	77	140
qwen3:4b	concise	65	2118	2183
qwen3:4b	uk_two	74	886	960

Еталон змісту: синхронні операції в одному потоці виконуються послідовно, і блокувальне очікування зупиняє подальше виконання цього потоку. Асинхронність дозволяє передавати керування під час очікування, наприклад мережевого вводу-виводу; це не означає автоматичного паралельного виконання на кількох ядрах.

Завдання 3. Локальна та хмарна моделі

Показник	Локальна	Хмарна
Модель	llama3.2:3b	openai/gpt-oss-120b
Час, с	1.007	6.831
completion_tokens	78	226
Символи	267	631
Мова	змішана	українська
Фактичні помилки	1	0

У compare.py не змінюється жоден рядок циклу або chat-виклику. Для іншого джерела задаються base_url, api_key і назва model у providers.py/.env; однаковий формат не гарантує підтримки всіх додаткових параметрів кожним сервером.

У локальній відповіді асинхронність помилково ототожнено з паралельним виконанням; є англомовна вставка Conversely. Хмарна відповідь точніше пояснює очікування I/O й використання одного потоку для багатьох конкурентних задач. У цьому прогоні хмара була повільнішою: 6,831 с проти 1,007 с.

Завдання 4. Вимірювання швидкості

Провайдер	Модель	Промпт	TTFT, с	Всього, с	Симв./с	Повторів
local	llama3.2:3b	short	0.037	0.204	168.363	3
local	llama3.2:3b	medium	0.053	1.163	295.873	3
local	llama3.2:3b	long	0.076	9.103	278.537	3
cloud	openai/gpt-oss-120b	short	6.777	6.802	4.263	3
cloud	openai/gpt-oss-120b	medium	15.633	15.863	21.118	3
cloud	openai/gpt-oss-120b	long	16.620	19.592	237.398	3

Старт	TTFT, с	Всього, с
Холодний	8.307	8.462
Теплий	0.034	0.197

Для холодного старту спочатку виконується явне вивантаження Ollama через keep_alive=0, потім негайний запит без прогріву. Наступний запит до тієї самої моделі є теплим стартом. Попередній прогрів приховав би час завантаження ваг, тому його перед холодним виміром не виконували.

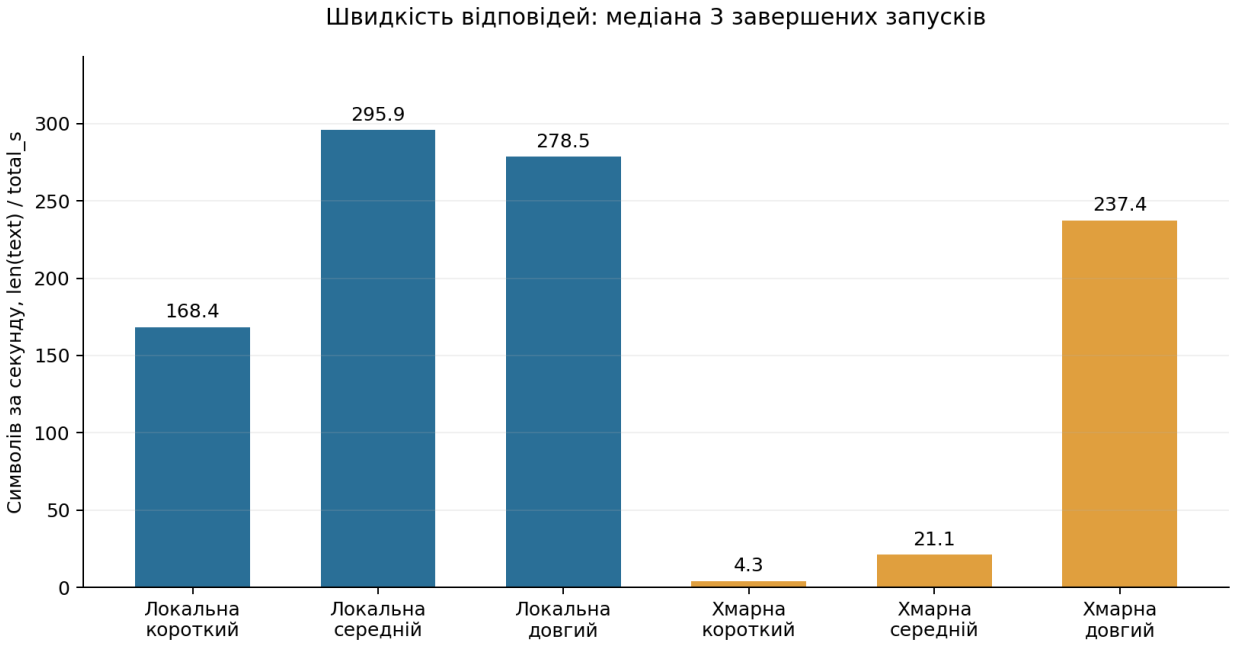


Рисунок 1 Порівняння швидкості відповідей

Провайдер	Промпт	TTFT min	TTFT max	Час min	Час max
local	short	0.032	0.113	0.190	0.242
local	medium	0.044	0.129	1.044	1.320
local	long	0.071	0.153	8.412	10.536
cloud	short	6.416	12.381	6.417	12.414
cloud	medium	12.141	24.035	12.414	24.272
cloud	long	13.677	18.113	16.721	21.036

Завдання 5. Якість за рубрикою

Кожна з трьох моделей отримує однакові шість запитів двічі. 0 - не виконано, 1 - частково, 2 - повністю; максимум 12 балів за один прогін. Автоматичні перевірки не підміняють оцінювання змісту та природності мови.

Вхідний текст для стискання

Компанія Apple представила перший iPhone у 2007 році. Його сенсорний дисплей мав діагональ 3,5 дюйма. Вбудована камера мала роздільну здатність 2 мегапікселі. Початкову версію пропонували з 4 ГБ пам'яті. Інша версія мала 8 ГБ пам'яті. Пристрій поєднував функції мобільного телефона, музичного програвача й інтернет-комунікатора.

Результати двох прогонів

Прогін 1

Завдання	llama3.2:3b	qwen3:4b	openai/gpt-oss-120b
1_fact	1	2	2
2_format	2	2	2
3_summary	0	2	2
4_code	1	0	1
5_logic	2	2	1
6_language	0	0	1
Сума /12	6	8	9

Прогін 2

Завдання	llama3.2:3b	qwen3:4b	openai/gpt-oss-120b
1_fact	1	2	2
2_format	2	2	2
3_summary	0	2	2
4_code	0	2	1
5_logic	2	2	2
6_language	0	1	1
Сума /12	5	11	10

Еталони варіанта 10

Факт: 2007; JSON: product=iPhone, year=2007, company=Apple. Джерело факту і чисел: офіційний пресреліз Apple - https://www.apple.com/newsroom/2007/01/09Apple-Reinvents-the-Phone-with-iPhone/.

Приклад правильного стискання: Представлений Apple у 2007 році перший iPhone мав дисплей 3,5 дюйма й камеру 2 мегапікселі, поєднуючи телефон, музичний програвач та інтернет-комунікатор. Пристрій пропонували у версіях із 4 ГБ та 8 ГБ пам'яті.

```
def average_grade(grades):
    if len(grades) < 2:
        raise ValueError('Потрібні щонайменше дві оцінки')
    return (sum(grades) - min(grades)) / (len(grades) - 1)
```

Функція вилучає рівно один мінімум без зміни вхідного списку; дублікати мінімуму враховуються. Контрольні приклади: [12,10,8,6] -> 10; [1,1,5] -> 3; [7,7,7] -> 7; [] і [5] -> ValueError.

За хвилину помилки мають 1200 * 0,15 = 180 запитів. Після повторної спроби успішні 180 * 0,40 = 72 запити. Втрачено 180 - 72 = 108 запитів за хвилину, або 108 * 60 = 6480 за годину.

Оперативна пам'ять (RAM) тимчасово зберігає дані та інструкції програм, з якими працює процесор. Вона забезпечує швидкий доступ, але після вимкнення живлення її вміст зазвичай втрачається.

Жорсткий диск (HDD) зберігає файли тривалий час, зокрема без живлення. Він використовує магнітні пластини й механічні головки, тому має більшу затримку доступу, ніж RAM; SSD також є постійним сховищем, але механічних рухомих частин не має.

Приклад провалу моделі

Модель llama3.2:3b, завдання 3_summary, прогін 1, оцінка 0.

Повний запит:

```
Стисни до двох речень, збережи всі числа:

Компанія Apple представила перший iPhone у 2007 році. Його сенсорний
дисплей мав діагональ 3,5 дюйма. Вбудована камера мала роздільну
здатність 2 мегапікселі. Початкову версію пропонували з 4 ГБ пам'яті.
Інша версія мала 8 ГБ пам'яті. Пристрій поєднував функції мобільного
телефона, музичного програвача й інтернет-комунікатора.
```

Повна відповідь:

```
Компанія Apple представила перший iPhone у 2007 році. Його сенсорний
дисплей мав діагональ 3,5 дюйма.
```

Правильний результат: два речення зі збереженням чисел 2007, 3,5, 2, 4, 8; приклад коректного резюме наведено вище. Пояснення: Два речення, але втрачено числа 2, 4 і 8 та відповідні характеристики.

Завдання 6. Temperature і top_p

Творчий промпт: назва застосунку пішохідних екскурсій. Фактичний: рік відкриття нинішньої будівлі Одеського оперного театру; еталон 1887 за офіційною історією театру - https://operahouse.od.ua/en/about/history/.

Параметр	Значення	Унікальних /5	Правильних фактів /5
temperature	0.000	1	0
temperature	0.700	4	-
temperature	1.500	5	0
top_p	0.100	1	-
top_p	0.500	5	-
top_p	1.000	5	-

Показник	Значення
Запусків	10
temperature	0.000
Унікальних	1
Усі однакові	так

Творчі відповіді порівнюються як повні рядки після strip(); це лексична різноманітність, а не доказ змістової новизни. Немає гарантії, що при високій температурі модель помилиться з роком: відсутність помилок також є коректним результатом.

При temperature=0 отримано одну творчу назву з п'яти спроб; при 0,7 - чотири, при 1,5 - п'ять. Фактична відповідь була неправильною в усіх перевірених спробах: при temperature=0 модель стабільно називала 1867 замість 1887. У десяти повторних запусках цей неправильний рік повторився десять разів; стабільність не означає достовірності.

8 Підсумкове порівняння

Критерій	Локальна 3B	Локальна 4B	Хмарна
Швидкість, симв./с	168,363-295,873	окремий streaming-тест не виконувався	4,263-237,398
TTFT, с	0,037-0,076	окремий streaming-тест не виконувався	6,777-16,620
Якість /12, прогони 1/2	6 / 5	8 / 11	9 / 10
JSON без виправлень	2 із 2	2 із 2	2 із 2

Критерій	Локальна 3B	Локальна 4B	Хмарна
Ресурси	локальна RAM/CPU/GPU	більші локальні RAM/CPU/GPU	мережа та API-ліміт
Вартість	обчислення й електроенергія	обчислення й електроенергія	за умовами тарифу; тут не виміряно
Рух даних	Ollama на своєму пристрої	Ollama на своєму пристрої	зовнішній сервер провайдера
Без інтернету	так, після завантаження ваг	так, після завантаження ваг	ні
Правило вибору	низька затримка; український текст і факти потребують ретельної перевірки	локальна обробка й краща якість; потрібен контроль ліміту міркувань та завершення відповіді	якісніші відповіді без локальних ваг; прийнятні передавання даних і виміряна затримка

Для інтерактивного асистента важливі час до видимого тексту, коректність і загальна тривалість відповіді. Для фонової обробки важливі наскрізна пропускна здатність, частка правильних результатів і вартість; назву переможця можна визначати лише з отриманих вимірів.

Відповіді на питання методички

Відповіді спираються на збережені результати запусків, перевірки за рубрикою та теоретичне пояснення роботи моделей. Часові порівняння враховують обмеження різних клієнтських середовищ.

Завдання 1. Міркувальна та інструктивна модель

1. Куди витрачаються додаткові токени?

На простому запиті Qwen згенерувала 175 токенів, Llama - 5; відношення становить 35. Додатковий обсяг у Qwen пов’язаний із thinking: це поле має 517 символів, тоді як фінальна відповідь коротка; до того ж Qwen написала «Киев», а Llama - «Київ.».

2. Для яких задач міркування корисне?

У задачі про ручку Qwen дала 5 правильних відповідей із 5, Llama - 0 із 5, тому додаткове міркування було корисним саме на цьому прикладі. На фактичному запиті обидві назвали правильне місто, але Qwen витратила більше часу й токенів без додаткової змістової користі.

3. Як відрізняється навчання?

Інструктивні моделі донавчають виконувати запити й обрані формати відповідей. Міркувальні моделі додатково можуть навчатися на прикладах розв'язання та через reinforcement learning з винагородою за правильність; для Qwen3 розробник описує поєднання цих підходів і режимів thinking/non-thinking.

4. Більше токенів означає вищий інтелект?

Кількість токенів показує витрачений обчислювальний бюджет, а не правильність. Довге пояснення може містити помилку або повторення; якість визначається перевіркою відповіді за умовою задачі.

5. Від чого залежить різниця токенів/с?

У фактичному запиті виміряно 113,859 токена/с для Llama та 62,798 для Qwen. Швидкість залежить від моделі й виконання обчислень, а загальний час - також від обсягу генерації; точні характеристики RAM/GPU цим запуском не зафіксовано, тому приписувати різницю конкретній відеокарті не можна.

Власна позиція: на простому факті додаткові міркування лише збільшили витрати, а на задачі про ручку точність Qwen зросла до 5/5 проти 0/5 у Llama. Тому режим thinking слід обирати за перевіреною точністю конкретної задачі та прийнятним часом.

Завдання 2. System-повідомлення

1. Яка модель точніше виконала обмеження двох речень?

Обидві моделі в режимі uk_two повернули по два речення, але лише Qwen дотрималася також української мови. Отже, Qwen краще виконала повну інструкцію; сама кількість речень не показує коректності змісту.

2. Чи були відповіді не українською?

У Llama навіть після прямої вказівки української залишилися «temps», «одновременно» і «threads». В обох відповідях Qwen на system-експеримент основний текст український; окреме російське «Киев» з’явилося в іншому, фактичному експерименті без цієї system-інструкції.

3. Чому змінюється prompt_tokens?

У Llama prompt_tokens зросло з 59 до 63, тобто на 4; у Qwen - з 65 до 74, на 9. Змінився текст system-повідомлення, а різні токенізатори й службові шаблони дали різний приріст.

4. Чому completion_tokens можуть бути більшими при однаковій видимій довжині?

Для uk_two Qwen витратила 886 completion_tokens на 238 видимих символів, Llama - 77 токенів на 277 символів. Це узгоджується з додатковим обсягом міркування Qwen, а не з більшою довжиною її фінальної відповіді.

5. Чому моделі по-різному слухаються system?

Вони мають різні дані й процедури донавчання на інструкціях, мовні можливості та шаблони повідомлень. Обмеження довжини або мови є завданням для моделі, а не детермінованим правилом форматування.

6. Чим system відрізняється від user?

Ролі передаються до моделі через спеціальний шаблон; system задає загальні правила, user містить поточний запит. Підтримка ієрархії залежить від навчання та реалізації сервера, тому сама роль не є гарантією безпомилкового виконання.

7. Чому thinking збільшує витрати?

Модель генерує додатковий проміжний текст, перш ніж сформувати коротку остаточну відповідь. Це збільшує кількість кроків декодування і часто загальний час, навіть коли фінальний content не подовжується.

8. Що буде при суперечності system і user?

За задумом інструкції system мають визначати поведінку, але конкретна модель може виконати суперечливу user-інструкцію. Такі випадки потрібно перевіряти окремими тестами, а критичні правила додатково забезпечувати програмно.

9. Чому мала модель може гірше виконувати мовні вимоги?

Обмежена місткість і відмінності багатомовного навчання можуть ускладнювати одночасне дотримання змісту, мови та формату. Водночас добре донавчена мала модель може перевершити більшу в конкретному вузькому завданні; сам розмір не дає остаточної відповіді.

Власна позиція: system-повідомлення допомогло скоротити Llama до двох речень, але не забезпечило української мови та правильного змісту. Для обов’язкового формату потрібні окремі перевірки, а для українського тексту - змістове й мовне оцінювання.

Завдання 3. Локальний і хмарний API

1. Скільки рядків змінюється при перемиканні?

У циклі compare.py та виклику chat змін не потрібно. Під час відновлення хмарної частини змінено конфігурацію model на openai/gpt-oss-120b замість недоступної llama-3.3-70b-versatile; base_url та ключ задаються окремо від коду.

2. Яка відповідь повніша й точніша?

Хмарна відповідь точніша: вона пояснює очікування I/O, звільнення потоку й конкурентне обслуговування задач одним потоком. Llama помилково назвала асинхронність паралельним виконанням і додала фрагмент Conversely.

3. Чи були локальні фактичні або мовні помилки?

У локальній відповіді зафіксовано одну суттєву змістову помилку - ототожнення асинхронності з паралельністю. Є також іншомовна вставка й невдалі українські форми; у збереженій хмарній відповіді суттєвих фактичних помилок не виявлено.

4. Як хмара може бути швидшою через інтернет?

У цьому прогоні хмарна відповідь була повільнішою: 6,831 с проти 1,007 с локально, тому припущення про перевагу хмари не підтвердилося. В інших умовах серверне прискорення може компенсувати мережевий шлях, але наші клієнтські середовища й маршрути також різні.

5. Чому поширився OpenAI-сумісний формат?

Спільна форма messages, model і відповіді дозволяє повторно використовувати клієнтський код та екосистему інструментів. Це практична сумісність API, а не формальна гарантія однакових можливостей, параметрів чи поведінки всіх провайдерів.

6. Як впливають 3B проти 70B?

У методичці наведено приклад порівняння 3B і 70B, але фактично в цій роботі хмарною заміною стала GPT-OSS 120B. Розмір - лише один чинник: різняться також сімейства моделей, навчання, режими генерації та обладнання, тому вплив однієї кількості параметрів цим тестом не ізольовано.

7. Чому іноді швидкість хмари вища?

Після початкової мережевої затримки сервер може генерувати текст значно швидше за локальний CPU. На довгій відповіді це здатне переважити виграш локального запиту за часом встановлення з'єднання.

8. Які ризики приватності?

У хмарний API передається вміст запиту, який обробляється за умовами провайдера. На практиці визначають допустимі категорії даних, мінімізують або знеособлюють текст, обирають відповідні умови обробки чи локальне розгортання.

9. Що таке rate limit і як із ним працюють?

Це обмеження на запити, токени або іншу активність за інтервал часу; перевищення часто повертає HTTP 429. Застосунок поважає Retry-After, використовує чергу, кешування та паузи з backoff або переходить на відповідний тариф; обходити правила через множинні акаунти не потрібно.

Власна позиція: у цій парі хмара точніше пояснила асинхронність, але відповідала довше. Для приватної локальної обробки обрав би Qwen за достатнього ліміту токенів, а хмару - коли передавання даних допустиме й потрібна якість підтверджена перевірками.

Завдання 4. Затримки й продуктивність

1. У кого найкращий TTFT?

У всіх трьох промптах менший TTFT мала локальна Llama: медіани 0,037; 0,053; 0,076 с проти 6,777; 15,633; 16,620 с у хмари. Це результат наших точок вимірювання, а не доказ загальної переваги локального сервера: хмарний клієнт і мережевий маршрут були іншими.

2. Чи збігаються лідери TTFT та символів/с?

У цьому наборі лідер збігся: локальна модель мала і менший TTFT, і більше символів за секунду для всіх трьох промптів. Наскрізна метрика символів/с включає очікування першого видимого тексту, тому великий TTFT суттєво зменшує результат хмари.

3. Що змінюється між коротким і довгим промптом?

За символами/с перевага локальної моделі зменшилася приблизно з 39,5 раза на короткій відповіді до 1,17 раза на довгій. Водночас «довгий промпт» просить довшу відповідь, тому одночасно змінено вхід і вихід; це не чистий тест лише довжини вхідного контексту.

4. Чи достатньо одного повтору?

Повтори істотно різнилися: для короткого хмарного промпту загальний час був 6,417-12,414 с, для короткого локального - 0,190-0,242 с. Одного запуску недостатньо; наведено медіани трьох повторів і діапазони, але для надійного оцінювання p95 потрібна більша вибірка.

5. Чому холодний старт повільніший?

Холодний TTFT становив 8,307 с, теплий - 0,034 с; загальний час - 8,462 і 0,197 с відповідно. Це відповідає додатковій підготовці моделі після вивантаження, зокрема завантаженню ваг у пам’ять.

6. Що відбувається до першого токена?

Запит передається, потрапляє в чергу, токенізується й обробляється моделлю, після чого генерується початок відповіді. Для thinking-моделі до першого видимого тексту можуть також генеруватися міркування; TTFT видимого content не дорівнює часу першого внутрішнього токена.

7. Як поєднуються більший TTFT і вища швидкість?

Початкова затримка та подальша пропускна здатність описують різні фази роботи. Сервер може довше починати відповідь, але після початку генерувати більше тексту за секунду завдяки швидшому обладнанню.

8. Що таке холодний старт?

Це запуск, коли потрібна модель ще не готова в оперативній або відеопам'яті сервісу. Теплий запит використовує вже підготовлену модель, але кеші контексту й інші оптимізації також можуть впливати на час.

9. Навіщо медіана?

Вона менше залежить від одного аномально повільного повтору, ніж середнє невеликої вибірки. При цьому самі первинні виміри теж зберігаються: медіана не показує всі коливання й не замінює аналіз розподілу.

10. Чому prefill часто швидший за decode?

Багато позицій вхідного тексту можна обробляти паралельно в межах обчислень моделі. Нові вихідні токени в авторегресійній генерації залежать від попередніх і зазвичай обчислюються послідовно, хоча реалізації можуть використовувати додаткові прискорення.

Власна позиція: для чату важливий короткий час до видимого змісту, а для фонових задач - правильні результати за одиницю часу. У наших вимірах локальна Llama швидша, однак різні мережеві маршрути не дозволяють приписати всю різницю лише обчислювальній швидкості моделей.

Завдання 5. Оцінювання якості

1. Хто набрав найбільше балів?

Оцінки за двома прогонами: Llama - 6 і 5, Qwen - 8 і 11, GPT-OSS - 9 і 10 з 12; найкращий окремий прогін має Qwen - 11/12. Середнє Qwen та хмарної моделі однакове - 9,5/12; Qwen втратила бали через два обриви, хмара - через markdown у коді, мовні дефекти й помилкову примітку в одному розв’язанні.

2. Чи розійшлися оцінки прогонів?

У Llama розійшлися оцінки коду (1 і 0), у Qwen - коду (0 і 2) та української (0 і 1), у хмари - логіки (1 і 2). Це показує нестабільність окремих відповідей; двох повторів недостатньо для висновку про загальну частоту помилок.

3. Чи повернула модель JSON без markdown?

Усі три моделі обидва рази повернули JSON, який json.loads() приймає без виправлень: по 2 із 2. Значення iPhone (1st generation) у першій хмарній відповіді також коректно позначає потрібний продукт.

4. Чи були проблеми української мови?

Найбільші мовні проблеми були в Llama: іншомовні вставки всередині слів і вигадані терміни. У завершеній відповіді Qwen є конструкція «якщо комп’ютер вимкне», у хмарній - «інструкції, які процесор потребує»; це конкретні підстави знизити мовні оцінки, а не вважати великий розмір гарантією природної мови.

5. Які інші методи оцінювання використовують?

Застосовують набори з перевіреними еталонами, автоматичні тести коду, перевірки схем, сліпе порівняння людьми й оцінювання моделлю за явно заданими критеріями. Для практичного застосунку найкорисніший окремий набір прикладів, що відтворює його реальні задачі й типові помилки.

6. Чому з'являються markdown-обгортки JSON?

Модель може відтворювати поширений стиль відповідей із навчання, у якому код подається в блоках. Пряма заборона зменшує ризик, але для машинного обміну краще поєднати відповідний режим структурованого виводу з валідацією.

7. Чому якість мов нерівномірна?

Вона залежить від кількості та якості даних конкретною мовою, токенізації й донавчання. Погана українська відповідь певної моделі не доводить, що всі малі моделі мають однаковий дефект.

8. Чому змінюється якість повторної відповіді?

За ненульової температури вибір наступних токенів випадковий, тому текст і навіть підхід до задачі можуть відрізнятися. Також впливають версія моделі, параметри сервера, зміни контексту й числова недетермінованість.

9. Що таке галюцинація?

Це правдоподібна, але фактично неправильна або не підтверджена відповідь. Генерація ймовірного продовження не є перевіркою джерела, тому впевнена форма висловлювання не доводить правильності факту.

Власна позиція: рубрика виявила різні типи дефектів і показала однакове середнє Qwen та GPT-OSS, але різну стабільність. Для українського тексту обидві придатніші за перевірену Llama; потрібні перевірка завершення, мови й фактів, бо жодна модель не виконала всі завдання без дефектів у двох прогонах.

Завдання 6. Семплювання та відтворюваність

1. Яку температуру поставити для JSON?

Для структурованого виводу початково обрав би temperature=0 і top_p=1 разом із перевіркою JSON-схеми. Наш факт при temperature=0 був стабільно неправильним, тому низька температура не замінює перевірку джерела.

2. А для варіантів заголовків?

У творчому експерименті temperature=0 дала 1 унікальну назву з 5, 0,7 - 4, 1,5 - 5. Для заголовків почав би з 0,7 і перевіряв зміст: різноманітність при 1,5 зросла, але частина назв мовно невдала.

3. Чим якісно відрізняється top_p?

Temperature перерозподіляє ймовірності, top_p відсікає малоймовірний хвіст. За фіксованої temperature=0,7 кількість унікальних назв для top_p=0,1/0,5/1,0 дорівнювала 1/5/5; однакові налаштування в різних серіях теж можуть дати різні невеликі вибірки.

4. Чи гарантує temperature=0 повторюваність?

Усі 10 відповідей при temperature=0 збіглися: «1867.», тобто одна унікальна відповідь. Вони водночас неправильні, бо еталон - 1887; експеримент підтвердив повторюваність цієї серії, а не правильність факту чи абсолютну гарантію детермінованості.

5. Яка відповідь при 1,5 була найбезглуздішою?

При temperature=1,5 з’явилася назва «Холдлап-екскурсіи». Вона має неясне значення й невдалу мовну форму; підвищена випадковість дозволила вибрати менш імовірні поєднання, але не забезпечила придатності назви.

6. Що temperature робить математично?

Для T>0 скоригована ймовірність токена і дорівнює exp(z_i/T), поділеному на суму exp(z_j/T), де z - логіти. Менше T концентрує масу на найкращих кандидатах; T=0 реалізують як граничний випадок greedy-вибору, а не як ділення на нуль.

7. Як математично працює top_p?

Кандидатів сортують за ймовірністю та залишають найменший префікс, накопичена ймовірність якого не менша p. Після відсікання решти ймовірності нормалізують і вибирають токен із цього набору.

8. Чи варто змінювати обидва параметри?

Для дослідження зручніше змінювати один параметр, фіксуючи інший: інакше складно пояснити причину змін. У реальному застосунку поєднання можливе, але його слід перевіряти на цільових прикладах; тут у temperature-досліді top_p=1,0, а в top_p-досліді temperature=0,7.

9. Чому greedy іноді недетермінований?

Округлення чисел, порядок паралельних операцій і різні обчислювальні ядра можуть змінити дуже близькі оцінки. Зміна серверної версії або ваг - окрема причина відмінностей, навіть якщо параметри клієнта не змінилися.

10. Які значення придатні для практики?

Для витягання фактів і структурованих даних починають з низької температури й жорсткої перевірки результатів; для творчого пошуку - з помірно вищої. Числові діапазони є початковими налаштуваннями, а не універсальним стандартом: потрібен власний тест якості.

Власна позиція: для структурованих даних почну з temperature=0, top_p=1 і валідації, а творчим задачам задам окремі налаштування. Десять повторів хибного 1867 року наочно показали, що стабільна відповідь може бути стабільною помилкою.

Висновок

Реалізовано всі шість експериментів варіанта 10, збереження первинних відповідей, розрахунок медіан, контроль завершення генерації, перевірки JSON і коду, дослідження відтворюваності та формування звіту. Умови порівняння потрібно контролювати: прогрів, відсутність паралельних запитів, однакові промпти та повтори.

На цьому наборі Llama мала найменшу виміряну затримку, але припускалася помилок у змісті та українській мові. Qwen правильно розв'язала всі п'ять задач про ручку, однак двічі не завершила відповідь за ліміту 4096 токенів. Середня оцінка Qwen і хмарної GPT-OSS однакова - 9,5/12; хмарна модель також допустила форматні, мовні й одну пояснювальну помилку. Це невеликий набір задач, тому висновки стосуються саме цих запусків.

Параметри семплювання вплинули на різноманітність, але temperature=0 не забезпечила правильного факту: модель стабільно повторювала хибний рік. Для практичного застосування потрібні перевірка фактів, структури та завершення генерації. Часові показники локальної й хмарної частин не є чистим порівнянням одного клієнта через різні середовища вимірювання.