МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ «ОДЕСЬКА ПОЛІТЕХНІКА»
ІНСТИТУТ КОМП’ЮТЕРНИХ СИСТЕМ
КАФЕДРА ІНФОРМАЦІЙНИХ СИСТЕМ

ПРОТОКОЛ ЛАБОРАТОРНОЇ РОБОТИ № 1

«Розгортання середовища та порівняльний аналіз мовних моделей»
з дисципліни «Обчислювальні методи»

Виконав: студент групи АІ-245
Філіпенко Михайло Михайлович
Варіант: 9
Перевірив: ас. Баранов О. М.

Одеса — 2026

Мета, середовище та організація експерименту

Мета роботи — навчитися запускати локальні мовні моделі, порівнювати інструктивну й міркувальну поведінку, досліджувати вплив системних інструкцій, використовувати уніфікований інтерфейс локального та хмарного API, вимірювати швидкодію, оцінювати якість і вплив параметрів генерації.

Таблиця 1 — Програмне середовище

Компонент	Використання
Windows / PowerShell	Запуск скриптів, перевірка CSV/JSON
Python	Запити до API, вимірювання та обробка даних
Ollama	Локальні llama3.2:3b і qwen3:4b
Gemini API	Хмарна gemini-3.5-flash-lite
JSON / CSV	Збереження відтворюваних результатів
Matplotlib	Графік порівняння швидкодії

У звіті наведено виключно результати з наданих файлів експериментів. Відповіді одногрупника не використовувалися як джерело вимірювань. Числові значення округлено для читабельності; вихідні результати залишаються в CSV/JSON.

Завдання 1. Ціна роздумів: міркувальна та інструктивна модель

Перевірено фактичне запитання «Столиця України? Відповідай одним словом» та логічну задачу: «Ручка і зошит разом коштують 110 грн. Ручка на 100 грн дешевша за зошит. Скільки коштує ручка?». Правильна відповідь: 5 грн (ручка) і 105 грн (зошит).

Таблиця 2 — Фактичне питання (успішний повтор Qwen)

Модель	Відповідь	Токени	Час, с	Токенів/с
llama3.2:3b	порожня	1024	52.92	24.02
qwen3:4b	Київ	3272	186.90	17.95

Таблиця 3 — Логічна задача (5 повторів)

Модель	Прогонів	Правильно / 5	Сер. токенів	Сер. час, с	Сер. токенів/с
llama3.2:3b	10	0	605	26.38	33.81
qwen3:4b	5	0	1493	70.71	21.31

Важливе уточнення: первинний файл reasoning_results.json містив у Qwen кілька порожніх фінальних відповідей при досягненні ліміту токенів. Для зіставлення логічних результатів використано окремий файл reasoning_qwen_retry.json із завершеними відповідями. Це не одна безперервна серія; обидві серії збережено для прозорості.

Куди витрачаються додаткові токени Qwen?

У цих вимірах Qwen витрачала більше токенів, зокрема на проміжні міркування. Сам лічильник токенів не доводить правильність відповіді.

Чи означає більша кількість токенів вищу якість?

Ні. Більша генерація збільшує час і навантаження; користь залежить від складності завдання та правильності кінцевого результату.

Коли варто використовувати міркувальну модель?

Для задач із кількома залежними кроками, обчисленнями або перевіркою умов. Для короткого факту швидша інструктивна модель часто достатня.

Чим відрізняється навчання моделей?

Інструктивні моделі оптимізують на виконання запитів; міркувальні можуть додатково навчатися на багатокрокових розв’язаннях та перевірюваних винагородах. Конкретний спосіб навчання залежить від виробника.

Чому Qwen повільніша в наших тестах?

У наведених логах вона генерує значно більше токенів. Час залежить також від розміру моделі, апаратури та налаштувань.

Висновок: коротка фактична відповідь не потребує тривалого міркування; складні задачі варто оцінювати за точністю, а не лише за швидкістю.

Завдання 2. Вплив системного повідомлення

Таблиця 4 — Вплив system-повідомлення (*автоматичний приблизний підрахунок речень)

Модель	System (скорочено)	Символів	Речень*	Prompt	Completion	Усього
llama3.2:3b	Лаконічний	181	2	54	55	109
llama3.2:3b	UA, ≤2 речення	225	1	58	55	113
qwen3:4b	Лаконічний	121	3	59	1254	1313
qwen3:4b	UA, ≤2 речення	175	2	68	444	512

llama3.2:3b — лаконічний асистент

Фактична відповідь: Функція: визначена набором входних даних (параметрів) і виходом системи, який залежить від них.

Метод: серія кроків, які використовуються для досягнення функціонального результату.

llama3.2:3b — українська, максимум два речення

Фактична відповідь: Функцію означає конкретний результат або результатовий ряд, який отримує sіę за допомогою певного оператора, а метод — комплексний крок з кільцевими кроками, який включає в себе ряд операцій для досягнення певного результату.

qwen3:4b — лаконічний асистент

Фактична відповідь: Функція — незалежний блок коду, який виконує операцію. Метод — функція, яка належить об'єкту (наприклад, `obj.method()`).

qwen3:4b — українська, максимум два речення

Фактична відповідь: Функція — це загальний блок коду, який виконує операції без зв'язку з об'єктом. Метод — це функція, яка прив'язана до об'єкта або класу в об'єктно-орієнтованому програмуванні.

Чи гарантує system-повідомлення потрібну мову та довжину?

Ні. В локальних моделях можливі русизми, змішування мов і порушення формату; це видно з відповідей Llama.

Чому змінюється prompt_tokens?

Текст системної інструкції є частиною вхідного контексту; інша інструкція змінює число токенів.

Чому completion_tokens Qwen може бути великим?

Показник включає згенеровані токени, зокрема ті, що не обов’язково збігаються з обсягом фінального видимого тексту.

Який пріоритет system порівняно з user?

Системна інструкція має вищий інструктивний пріоритет, але фактичне дотримання залежить від моделі; для строгих форматів потрібна перевірка виходу.

Що робити із суперечливими інструкціями?

Уникати конфліктів і додавати програмні перевірки, а не покладатися лише на формулювання промпту.

Висновок: системний промпт впливає на поведінку, але не замінює контроль мови, довжини та правильності.

Завдання 3. Локальна та хмарна модель через єдиний інтерфейс

Запит Q1

Таблиця — Порівняння моделей для Q1

Провайдер	Модель	Час, с	Вхідні токени	Вихідні токени	Символів	Статус
llama	llama3.2:3b	17.64	63	386	1151	ok
qwen	qwen3:4b	86.10	77	1611	519	ok
cloud	gemini-3.5-flash-lite	1.78	42	300	838	ok

llama3.2:3b: Функція та метод — дві різні концепції в Python.

Функція:
Функція — це блок коду, який виконує певну задачу та може бути викликаний з різних місць у програмі. Функції є незалежними від інших блоків коду та можуть бути викликані з різних місць у програмі. Функції можуть приймати параметри та повертати результат.

Метод:
Метод — це функція, яка належить до об'єкту (об'єкту, класу чи модулю). Методи використовуються для виконання певних дій з об'єктами, наприклад, для виконання операцій з масивами чи для виконання операцій з іншими об'єктами. Методи завжди використовуються з об'єктом, до якого вони належать.

Приклад:
```python
# Функція
def додати(a, b):
    return a + b

# Метод
 […]
```

qwen3:4b: Функція — це незалежний блок коду, що може бути викликаний без зв'язку з об'єктом. Метод — це функція, яка визначена у класі та викликається на екземплярі цього класу.

Приклад:

Функція:
```python
def say_hello():
    print("Hello")
```

Метод:
```python
class User:
    def say_hello(self):
        print("Hello, я метод!")

user = User()
user.say_hello()  # Виклик методу
```

Тут `say_hello` є методом класу `User`, а `say_hello` як функція — незалежною. Метод вимагає екземпляр класу для виклику, функція — ні.

gemini-3.5-flash-lite: Головна різниця між функцією та методом у Python полягає в тому, **як і до чого вони прив'язані**.

* **Функція** — це самостійний блок коду, який виконує певну задачу. Вона викликається

сама по собі (наприклад, `print()`, `len()`).
* **Метод** — це функція, яка належить до певного об'єкта (класу). Він викликається **через крапку** після цього об'єкта і завжди має доступ до його даних.

Приклад:

```python
# 1. Функція (не залежить від конкретного об'єкта, приймає текст як аргумент)
tekst = "привіт"
dovzhyna = len(tekst)
print(dovzhyna)  # Виведе: 6

# 2. Метод (прив'язаний до рядка, викликається через крапку)
velykij_tekst = tekst.upper()
print(velykij_tekst)  # Виведе: ПРИВІТ
 […]
```

Запит Q2

Таблиця — Порівняння моделей для Q2

Провайдер	Модель	Час, с	Вхідні токени	Вихідні токени	Символів	Статус
llama	llama3.2:3b	14.50	79	255	687	ok
qwen	qwen3:4b	130.80	101	2326	17	ok
cloud	gemini-3.5-flash-lite	1.59	63	195	442	ok

llama3.2:3b: Ви можете розрахувати час польоту космічного апарата за допомогою наступного формулу:

Вираз для розрахунку часу польоту:

Тривалість польоту (в годинах) = Дистанція (в км) / Швидкість (в км/год)

Вказана дистанція 480 000 000 км, а швидкість 60 000 км/год.

Тривалість польоту = 480 000 000 км / 60 000 км/год = 8 годин.

Однако, необхідно враховати, що космічний апарат летить в космосі, де швидкість космічного апарата менша, ніж в атмосфері. В космосі космічний апарат летить зі швидкістю близько 27 000 км/год.

Тривалість польоту = 480 000 000 км / 27 000 км/год = 17 741 год.

Однако, насправді космічний апарат летить зі швидкістю близько 27 000 км/год, а не з 60 000 км/год.

qwen3:4b: 333 дні і 8 годин

gemini-3.5-flash-lite: Для того щоб знайти час польоту, потрібно відстань поділити на швидкість:

1. **Обчислюємо час у годинах:**
   $t = \frac{480\ 000\ 000 \text{ км}}{60\ 000 \text{ км/год}} = 8\ 000 \text{ годин}$.

2. **Переводимо години в доби** (оскільки в одній добі 24 години):
   $8\ 000 \text{ год} \div 24 = 333 \text{ доби і } 8 \text{ годин}$ (або приблизно $333,33$ доби).

Відповідь: Політ триватиме **8 000 годин**, або **333 доби і 8 годин**.

Запит Q3

Таблиця — Порівняння моделей для Q3

Провайдер	Модель	Час, с	Вхідні токени	Вихідні токени	Символів	Статус
llama	llama3.2:3b	11.21	61	59	178	ok
qwen	qwen3:4b	78.34	71	1268	96	ok
cloud	gemini-3.5-flash-lite	1.52	38	135	395	ok

llama3.2:3b: Зірка - це велика зоря, яка складається з багатьох зірок, що об'єднуються в одну систему. Планета - це велика планетарна система, яка складається з однієї зорі та кількох планет.

qwen3:4b: Зірка випромінює світло сама по собі, а планета відбиває світло зорі та обертається навколо неї.

gemini-3.5-flash-lite: Головна різниця між зіркою та планетою полягає у джерелі їхнього світла та масі:

* **Зірка** — це величезна розпечена куля плазми (газу), яка світиться сама завдяки термоядерним реакціям у її надрах (наприклад, Сонце).
* **Планета** — це менше за розміром холодне тіло, яке не випромінює власного світла, а лише відбиває світло своєї зірки (наприклад, Земля). Планети обертаються навколо зірок.

У файлах providers.py та compare.py реалізовано звернення до локального сервера Ollama і Gemini через спільний клієнтський інтерфейс. Перемикання провайдера змінює конфігурацію клієнта й модель, а не структуру основного виклику.

Скільки коду треба змінити для переходу між моделями?

За наявності make_client(provider) достатньо вибрати інший ключ провайдера; основна логіка chat.completions залишається спільною.

Яка відповідь краща?

У тестах Q2 та Q3 Qwen і Gemini демонструють коректніші підсумки, ніж Llama. Конкретна якість оцінюється за змістом, а не лише за кількістю символів.

Чому хмарна модель може бути швидшою?

Серверне обладнання й оптимізований інференс інколи перекривають мережеву затримку. У наших трьох Q-запитах Gemini відповідала за 1,52–1,78 с.

Які ризики приватності хмарного API?

Текст запиту надходить зовнішньому провайдеру; не слід передавати секрети, ключі або персональні дані без належних підстав.

Що таке rate limit?

Обмеження кількості запитів або токенів за період. Коректна реакція — черга, кешування й повторні спроби з паузами.

Завдання 4. Швидкодія: TTFT, повний час, символи/с

Таблиця — Результати трьох вимірювань на кожну комбінацію

Модель	Запит	Медіана TTFT, с	Медіана часу, с	Медіана симв./с
Локальна Llama 3.2	короткий	2.161	2.548	11.38
Локальна Llama 3.2	середній	2.16	3.801	79.19
Локальна Llama 3.2	довгий	2.199	11.915	136.89
Хмарна Gemini	короткий	0.636	0.898	96.84
Хмарна Gemini	середній	0.604	1.073	375.66
Хмарна Gemini	довгий	0.709	2.28	680.25

Всього 18 успішних вимірювань: дві моделі × три типи запиту × три повтори. Перед кожною серією виконувався окремий прогрів. TTFT у скрипті вимірюється до першого непорожнього текстового фрагмента потокової відповіді. Швидкість визначена як кількість символів, поділена на повний час запиту.

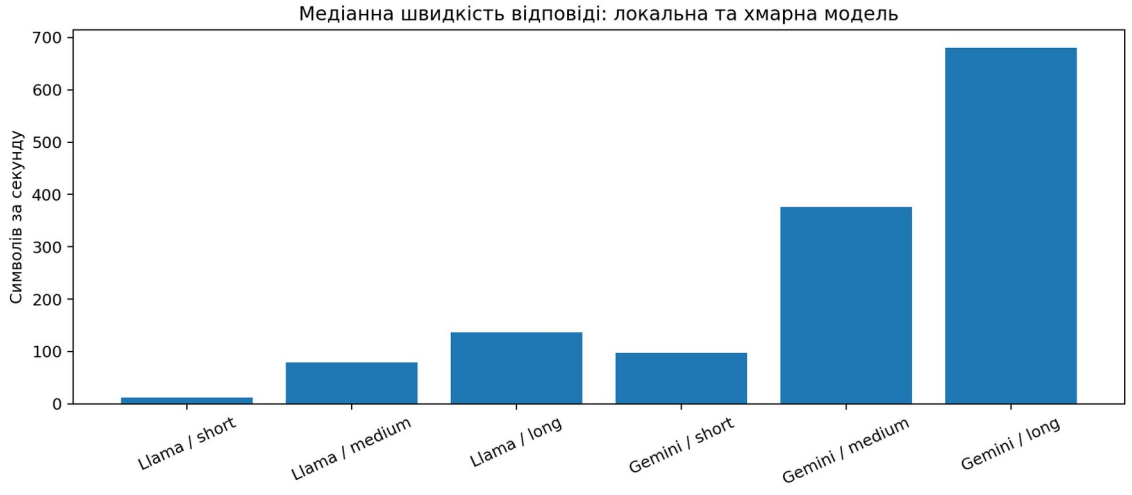


Рисунок 1 — Медіанна швидкість генерації за типами запитів (власні вимірювання).

Таблиця — Холодний і теплий запуск Ollama

Модель	Запуск	Тип	Час стінний, с	Завантаження, с	Симв./с
llama3.2:3b	1	cold	15.93	7.97	187.53
llama3.2:3b	2	warm	7.8	0.02	167.71
llama3.2:3b	3	warm	7.96	0.02	162.73
qwen3:4b	1	cold	31.39	7.61	106.64
qwen3:4b	2	warm	23.21	0.04	108.82
qwen3:4b	3	warm	23.73	0.08	106.44

У якої моделі найменший TTFT?

У нашій таблиці — Gemini: 0,604–0,709 с проти 2,160–2,199 с у Llama.

Чому холодний старт повільніший?

Потрібне завантаження ваг моделі в оперативну/відеопам’ять. У наших вимірах час завантаження Llama становив 7,97 с при холодному запуску і 0,02 с при теплому.

Навіщо медіана трьох запусків?

Медіана зменшує вплив одиничних стрибків затримки та фонового навантаження.

Чи TTFT і швидкість генерації — те саме?

Ні. TTFT показує очікування першого фрагмента; симв./с — середню інтенсивність видачі тексту за час повного запиту.

Чому збільшується повний час для довгих запитів?

Моделі зазвичай генерують довшу відповідь, тому декодування займає більше часу.

Висновок: у цій серії Gemini швидша за Llama на всіх трьох типах запитів. Холодні старти локальних моделей помітно довші за теплі.

Завдання 5. Оцінювання якості за рубрикою

Використано шість завдань варіанта 9: факт про перший політ людини, JSON про політ, стиснення тексту про «Восток-1», функція light_travel_time, задача про політ зонда, пояснення різниці між зорею і планетою. Для кожної з трьох моделей виконано по два прогони кожного завдання (36 відповідей, усі зі статусом ok).

Шкала: 0 — неправильна відповідь; 1 — частково правильна; 2 — правильна. Оцінки виставлено за змістом двох фактичних відповідей. Англійський текст у JSON Qwen не знижував бал, оскільки в самому завданні 2 українська мова не була прямо обов’язковою. За суворішої мовної рубрики оцінку слід переглянути.

Таблиця — Експертні оцінки двох прогонів (0–2 бали за завдання)

Завдання	Llama 1/2	Qwen 1/2	Gemini 1/2
Факт	2/2	2/2	2/2
JSON	0/1	2/2	2/2
Стислий переказ	1/1	2/2	2/2
Python-код	0/0	2/2	2/2
Логіка	0/0	2/2	2/2

Українська мова	0/0	2/2	2/2
Разом за прогонами	3 / 4	12 / 12	12 / 12
Середнє з 12	3,5	12	12

Таблиця — Розбіжності оцінок між двома прогонами

Завдання	Llama	Qwen	Gemini
Факт	ні	ні	ні
JSON	так	ні	ні
Стислий переказ	ні	ні	ні
Python-код	ні	ні	ні
Логіка	ні	ні	ні
Українська мова	ні	ні	ні

Приклад провалу моделі — логічна задача

Запит: «Зонд летить зі швидкістю 60000 км/год. Відстань — 480000000 км. Скільки повних діб триватиме політ? Покажи обчислення».

Правильно: 480000000 / 60000 = 8000 годин; 8000 / 24 = 333,33 доби; повних діб — 333.

Llama, прогін 1 (дослівний уривок): ЗOND летить зі швидкістю 60000 км/год. Відстань — 480000000 км.

Вперше нам потрібно визначити, скільки годин триватиме політ.

Водяний год — 365.24 дні.

Дінь у дні — 24.

Дінь в год — 365.24 дні x 24 год/день = 8768,96 год.

Тепер, скільки годин триватиме політ?

60000 км/год x 8768,96 год = 5264800000 годин.

Тепер, скільки повних діб триватиме політ?

5264800000 годин / 24 год/день = 219500000 діб.

Llama, прогін 2 (дослівний уривок): Повна доля дні в год становить 365 діб.

Висота зонда в км: 60000.
Висота полету в км: 480000000.
Висота полоту в дні: (480000000 ÷ 60000) = 8000.

Висота полоту в дні: 8000.
Сумарна доля дні в рік: 8000 ÷ 365 = 21.93.

21.93

У першому прогоні модель отримала 219500000 діб, у другому — 21,93, переплутавши години, доби та роки. Qwen і Gemini в обох прогонах дали 333 повні доби.

Додатковий приклад — помилка в одиницях вимірювання

У задачі light_travel_time(distance_km) Llama у першому прогоні множила кілометри на 1000, хоча швидкість уже була задана у км/с. У другому прогоні перевела швидкість у м/с, але відстань залишила в км. Обидві реалізації давали помилку в 1000 разів. Qwen та Gemini застосували distance_km / 299792.458.

Яка модель набрала найбільше?

Qwen і Gemini набрали по 12/12 за прийнятою рубрикою; Llama — в середньому 3,5/12.

Де спостерігається нестабільність?

У Llama оцінки двох прогонів різняться в JSON-завданні; в інших завданнях однаковий бал не завжди означає однаковий текст.

Чи було порушення формату JSON?

У першій відповіді Llama додала багато зайвих полів і вигадані факти. Qwen та Gemini видали коректні три поля.

Які мовні проблеми?

Llama в поясненні зорі й планети мала грубі фактичні помилки й мовні змішування; Qwen іноді використовувала кальки, Gemini відповідала граматично краще.

Чому потрібні два прогони?

Навіть при однаковому запиті генеративна модель може видати різні формулювання та помилки; один приклад не характеризує надійність.

Завдання 6. Temperature, top_p та відтворюваність

Творчий промпт: «Придумай коротку оригінальну назву для сервісу рекомендації фільмів. Відповідай тільки назвою». Досліджено temperature = 0; 0,7; 1,5 та top_p = 0,1; 0,5; 1,0 — по 5 запусків. Дані взято з sampling_creative_variant9.json, а не з попередніх файлів із некоректним кодуванням.

Таблиця — Варіативність творчих назв

Параметр	Значення	Прогонів	Унікальних	Приклад 1	Приклад 5
temperature	0,0	5	2	"Фільм на ваше смаку"	"Фільм на вашу думку"
temperature	0,7	5	5	"Фільмопарк"	"Рекомеда"
temperature	1,5	5	5	Kinodilema	"Фолло-Ролл".
top_p	0,1	5	1	"Фільм на вашу думку"	"Фільм на вашу думку"
top_p	0,5	5	4	"Фільм для тебе".	"Фільм на лавочці"

top_p	1,0	5	5	"CinemaExpert".	"Фільмобіле"

При температурі 0 відповіді здебільшого повторювалися; підвищення temperature давало більше варіантів, але іноді — неприродні назви. Зміна top_p регулювала різноманітність набору кандидатних токенів.

Таблиця — Фактичне питання «Рік випуску першого iPhone?»

Temperature	Запусків	Правильних	Відповіді
0.0	5	5	2007.
1.5	5	5	2007

За двох температур фактична відповідь була правильною у всіх 10 спробах: 2007 рік. Отже, в цій малій вибірці збільшення температури не знизило фактологічну точність.

Таблиця — Перевірка відтворюваності

Показник	Значення
Модель	llama3.2:3b
Temperature	0
top_p	1,0
seed	42
Повторів	10
Унікальних відповідей	1
Відповідь	2007.

Що робить temperature?

Змінює розподіл імовірностей токенів: більша температура зазвичай дає більше різноманіття, але й більше ризику випадкових формулювань.

Що робить top_p?

Обмежує набір кандидатних токенів за накопиченою ймовірністю; менше значення зазвичай робить генерацію передбачуванішою.

Чому temperature = 0 не гарантує абсолютну однаковість?

На результат можуть впливати реалізація інференсу, паралелізм і версії середовища. У творчому тесті при temperature = 0 трапилися два варіанти.

Навіщо seed?

Фіксація seed допомагає відтворювати стохастичний вибір за незмінних інших умов. У нашій серії 10/10 відповідей збіглися.

Як впливає температура на факти?

У нашому фактичному тесті 10/10 відповідей правильні при обох температурах, тому на цих даних вплив на точність не виявлений.

Висновок: для творчих назв доцільна помірна випадковість; для стабільних фактів і відтворюваних тестів — фіксовані параметри та seed.

Додаток А. Первинні вимірювання швидкодії

Нижче наведено кожне з 18 вимірювань, з яких отримано медіани. Таблиця потрібна для перевірки того, що середні показники не взято з одного випадкового запуску.

Повторні вимірювання — локальна Llama 3.2

Таблиця — Повні дані потокового Benchmark

Тип	№	TTFT, с	Повний час, с	Символів	Симв./с	Статус
short	1	2.162	2.552	29	11.36	ok
short	2	2.151	2.475	29	11.72	ok
short	3	2.161	2.548	29	11.38	ok
medium	1	2.182	3.816	301	78.88	ok
medium	2	2.139	3.78	301	79.63	ok
medium	3	2.16	3.801	301	79.19	ok
long	1	2.213	11.915	1631	136.89	ok
long	2	2.199	11.887	1631	137.21	ok
long	3	2.172	12.023	1631	135.65	ok

Повторні вимірювання — хмарна Gemini

Таблиця — Повні дані потокового Benchmark

Тип	№	TTFT, с	Повний час, с	Символів	Симв./с	Статус
short	1	0.827	0.916	75	81.87	ok
short	2	0.635	0.898	148	164.81	ok
short	3	0.636	0.774	75	96.84	ok
medium	1	0.84	1.366	414	303.05	ok
medium	2	0.604	1.073	403	375.66	ok
medium	3	0.577	1.043	481	461.19	ok
long	1	0.582	2.12	1551	731.54	ok
long	2	0.711	2.358	1584	671.8	ok
long	3	0.709	2.28	1551	680.25	ok

Зіставлення холодного і теплого запуску: час завантаження відображає додаткові витрати на перше завантаження ваг; прискорення обчислюємо за повним wall_seconds. Для Llama: 15,93 / ((7,80 + 7,96)/2) = 2,02 раза. Для Qwen: 31,39 / ((23,21 + 23,73)/2) = 1,34 раза.

Інтерпретація шести комбінацій

Короткий запит: медіанний час Llama 2.548 с, Gemini 0.898 с. Відношення часів = 2.84 раза. Медіанний TTFT: 2.161 проти 0.636 с. Це результати конкретного обладнання та часу тестування, а не універсальна перевага для всіх навантажень.

Середній запит: медіанний час Llama 3.801 с, Gemini 1.073 с. Відношення часів = 3.54 раза. Медіанний TTFT: 2.16 проти 0.604 с. Це результати конкретного обладнання та часу тестування, а не універсальна перевага для всіх навантажень.

Довгий запит: медіанний час Llama 11.915 с, Gemini 2.28 с. Відношення часів = 5.23 раза. Медіанний TTFT: 2.199 проти 0.709 с. Це результати конкретного обладнання та часу тестування, а не універсальна перевага для всіх навантажень.

Додаток Б. Повна відомість 36 відповідей за рубрикою

Наведені нижче відповіді збережені у файлі quality.json. Для довгих відповідей подано початок з чіткою позначкою скорочення; оригінал без скорочень міститься у вихідному JSON. Це не нові запуски.

1. Факт

llama3.2:3b; запуск 1; статус ok; експертна оцінка 2/2.

Відповідь: 1961 рік.

llama3.2:3b; запуск 2; статус ok; експертна оцінка 2/2.

Відповідь: 1961

qwen3:4b; запуск 1; статус ok; експертна оцінка 2/2.

Відповідь: 1961

qwen3:4b; запуск 2; статус ok; експертна оцінка 2/2.

Відповідь: 1961

gemini-3.5-flash-lite; запуск 1; статус ok; експертна оцінка 2/2.

Відповідь: 1961

gemini-3.5-flash-lite; запуск 2; статус ok; експертна оцінка 2/2.

Відповідь: 1961

Проміжний висновок

Усі моделі знають правильний рік першого польоту людини — 1961. Llama у першому прогоні додала слово «рік», хоча вимагалося лише число.

2. JSON

llama3.2:3b; запуск 1; статус ok; експертна оцінка 0/2.

Відповідь: {"event": "перший політ людини в космос", "year": "1961", "person": "Юлій Цімермань", "дата": "04.04.1961", "место": "Росія", "парашутна нахилка": "40 градусів", "висота": "250 метрів", "висота на висотному балоні": "10 000 метрів", "висота на космічному кораблі": "200 метрів", "кількість космических полетов": "1", "кількість запусків космического корабля": "1", "кількість запуснів ракет": "1", "висота на орбіту": "200 км", "висота на орбіту на висотному балоні": "100 км", "висота на орбіту на космічному кораблі": "50 км", "висота на орбіту на космічному кораблі на висотному балоні": "10 км", "висота на орбіту на космічному кораблі на космічному кораблі": "0 км", "висота на орбіту на космічному кораблі на космічному кораблі на висотному балоні": "0 км", "висота на орбіти": "200 км", "висота на орбіті на висотному балоні": "100 км", "висота на орбіті на космічному кораблі": "50 км", "висота на орбіті на космічному кораблі на висотному балоні": "10 км", "висота на орбіті на космічному кораблі на космічному кораблі": "0 км", "висота на орбіті на космічному кораблі на космічному кораблі на висотному балоні": "0 км", "висота на орбітах": "200 км", "висота на орбіті на висотному балоні": [текст скорочено; повна відповідь у quality.json]

llama3.2:3b; запуск 2; статус ok; експертна оцінка 1/2.

Відповідь: {"event": "Перший політ людини в космос", "year": 1961, "person": " Юрый Гагарин"}

qwen3:4b; запуск 1; статус ok; експертна оцінка 2/2.

Відповідь: {
"event": "First human spaceflight",
"year": 1961,
"person": "Yuri Gagarin"
}

qwen3:4b; запуск 2; статус ok; експертна оцінка 2/2.

Відповідь: {
"event": "First human spaceflight",
"year": 1961,
"person": "Yuri Gagarin"
}

gemini-3.5-flash-lite; запуск 1; статус ok; експертна оцінка 2/2.

Відповідь: {
"event": "Перший політ людини в космос",
"year": 1961,
"person": "Юрій Гагарін"
}

gemini-3.5-flash-lite; запуск 2; статус ok; експертна оцінка 2/2.

Відповідь: {
"event": "Перший політ людини в космос",
"year": 1961,
"person": "Юрій Гагарін"
}

Проміжний висновок

Llama у першому прогоні вигадала особу та десятки зайвих полів; другий прогін структурно кращий. Qwen подала JSON англійською, Gemini — українською.

3. Стислий переказ

llama3.2:3b; запуск 1; статус ok; експертна оцінка 1/2.

Відповідь: Юрій Гагарін став першою людиною, яка здійснила орбітальний космічний політ, 12 квітня 1961 року. Політ тривав 108 хвилин та мав максимальну висоту польоту 327 кілометрів над поверхнею Землі.

llama3.2:3b; запуск 2; статус ok; експертна оцінка 1/2.

Відповідь: Текст стиснутий до двох речень:

12 квітня 1961 року Юрій Гагарін став першою людиною, яка здійснила орбітальний космічний політ. Він перебував на борту корабля «Восток-1», який рухався зі швидкістю 27400 кілометрів на годину.

Політ тривав 108 хвилин, а максимальна висота польоту становила приблизно 327 кілометрів над поверхнею Землі.

qwen3:4b; запуск 1; статус ok; експертна оцінка 2/2.

Відповідь: 12 квітня 1961 року Юрій Гагарін здійснив орбітальний космічний політ на кораблі «Восток-1». Політ тривав 108 хвилин, мав швидкість 27400 км/год і досяг максимальну висоту 327 км.

qwen3:4b; запуск 2; статус ok; експертна оцінка 2/2.

Відповідь: 12 квітня 1961 року Юрій Гагарін здійснив орбітальний космічний політ на кораблі «Восток-1». Політ тривав 108 хвилин, швидкість була 27400 км/год, а максимальна висота польоту — 327 кілометрів.

gemini-3.5-flash-lite; запуск 1; статус ok; експертна оцінка 2/2.

Відповідь: 12 квітня 1961 року Юрій Гагарін на кораблі «Восток-1» здійснив перший орбітальний космічний політ тривалістю 108 хвилин. Апарат рухався зі швидкістю 27400 кілометрів на годину, досягнувши максимальної висоти приблизно 327 кілометрів.

gemini-3.5-flash-lite; запуск 2; статус ok; експертна оцінка 2/2.

Відповідь: 12 квітня 1961 року Юрій Гагарін на кораблі «Восток-1» здійснив перший орбітальний космічний політ тривалістю 108 хвилин. Апарат рухався зі швидкістю 27400 кілометрів на годину, досягнувши максимальної висоти приблизно 327 кілометрів.

Проміжний висновок

У першому прогоні Llama пропустила числові дані, а у другому перевищила ліміт речень. Qwen та Gemini зберегли числові показники.

4. Python-код

llama3.2:3b; запуск 1; статус ok; експертна оцінка 0/2.

Відповідь: Функція для розрахунку часу проходження світлом відстані у секундах:
```python
def light_travel_time(distance_km):
    """
    Виводить час проходження світлом відстані в секундах.

    Аргументи:
    distance_km (float): Відстань в км.

    Повернення:
```

```
    float: Час проходження світлом відстані в секундах.
    """
    speed_of_light = 299792.458  # км/с
    time_in_seconds = (distance_km * 1000) / speed_of_light  # перевод км в м, а потім секунди
    return time_in_seconds
```

Використовуючи цю функцію, можна EXAMPLE:

```python
print(light_travel_time(10))  # Виводить час проходження світлом відстані 10 км в секундах.
```

llama3.2:3b; запуск 2; статус ok; експертна оцінка 0/2.

Відповідь: def light_travel_time(distance_km):
    """
    Рассчитывает время, необходимое для проходимости світлом заданногоdistance_km.

    Parameters:
    distance_km (float): відстань в километрах

    Returns:
    float: час проходження світлом в секундах
    """
    # Скорость світла в метрах в секунду
    speed_of_light_mps = 299792.458
    # Перевод скорости світла в метрах в секунду
    speed_of_light_ms = speed_of_light_mps * 1000
    # Рассчет времени, необходимое для проходимости світлом
    time_s = distance_km / speed_of_light_ms
    return time_s

qwen3:4b; запуск 1; статус ok; експертна оцінка 2/2.

Відповідь: Щоб створити функцію Python, яка обчислює час проходження світлом відстані в секундах, необхідно використати формулу:
час (секунди) = відстань (км) / швидкість світла (км/с).

Швидкість світла задана як `299792.458 км/с`.

Ось реалізація функції:

```python
def light_travel_time(distance_km):
    speed_of_light = 299792.458  # км/с
    time_seconds = distance_km / speed_of_light
    return time_seconds
```

Пояснення:
- Функція `light_travel_time` приймає один аргумент `distance_km` (відстань у кілометрах).
- Обчислює час за формулою: `distance_km / 299792.458`.
- Повертає результат у секундах.

Приклад використання:
```python
print(light_travel_time(300000))  # Відстань 300 000 км
# Виведе: 1.0000000000000002 (близько 1 секунди)
```

qwen3:4b; запуск 2; статус ok; експертна оцінка 2/2.

Відповідь: Нижче представлена функція Python, яка обчислює час проходження світлом відстані в секундах:

```python
def light_travel_time(distance_km):
    speed_of_light_km_per_sec = 299792.458
    time_seconds = distance_km / speed_of_light_km_per_sec
    return time_seconds
```

Пояснення:
1. Функція `light_travel_time` приймає один аргумент `distance_km` (відстань у кілометрах).
2. Швидкість світла використовується як константа `299792.458` км/с.
3. Час в секундах обчислюється за формулою: `час = відстань / швидкість`.
4. Повертається результат у вигляді числа (в секундах).

Приклад використання:
```python
print(light_travel_time(1000))  # Виведе: 0.0033356141720019995 (час для 1000 км)
print(light_travel_time(299792.458))  # Виведе: 1.0 (час для 299792.458 км)
```

Ця функція точно відповідає умові завдання та працює для будь-якої відстані в кілометрах.

gemini-3.5-flash-lite; запуск 1; статус ok; експертна оцінка 2/2.

Відповідь: Ось функція на Python для обчислення часу проходження світла заданої відстані:

```python
def light_travel_time(distance_km):
    speed_of_light = 299792.458  # км/с
    return distance_km / speed_of_light
```

```

### Приклад використання:

```python
# Відстань від Землі до Місяця приблизно 384 400 км
moon_distance = 384400
time_to_moon = light_travel_time(moon_distance)
print(f"Світло доходить від Місяця до Землі за {time_to_moon:.2f} секунд")

# Відстань від Сонця до Землі приблизно 149 600 000 км
sun_distance = 149600000
time_to_sun = light_travel_time(sun_distance)
print(f"Світло доходить від Сонця до Землі за {time_to_sun:.2f} секунд (це близько
{time_to_sun / 60:.1f} хвилин)")
```

gemini-3.5-flash-lite; запуск 2; статус ok; експертна оцінка 2/2.

Відповідь: Ось функція на Python для обчислення часу проходження світла заданої відстані:

```python
def light_travel_time(distance_km):
    speed_of_light = 299792.458  # км/с
    return distance_km / speed_of_light


# Приклад використання:
# Час, за який світло доходить від Сонця до Землі (приблизно 149.6 млн км)
distance = 149600000
time_seconds = light_travel_time(distance)
print(f"Час: {time_seconds:.2f} секунд")  # Очікується близько 499 секунд (~8.3 хвилин)
```

Проміжний висновок

Llama двічі неправильно поєднала метри й кілометри; Qwen та Gemini застосували правильні одиниці вимірювання.

5. Логіка

llama3.2:3b; запуск 1; статус ok; експертна оцінка 0/2.

Відповідь: 3OND летить зі швидкістю 60000 км/год. Відстань — 480000000 км.

Вперше нам потрібно визначити, скільки годин триватиме політ.
```

Водяний год — 365.24 дні.

Дінь у дні — 24.

Дінь в год — 365.24 дні x 24 год/день = 8768,96 год.

Тепер, скільки годин триватиме політ?

60000 км/год x 8768,96 год = 5264800000 годин.

Тепер, скільки повних діб триватиме політ?

5264800000 годин / 24 год/день = 219500000 діб.

llama3.2:3b; запуск 2; статус ok; експертна оцінка 0/2.

Відповідь: Повна доля дні в год становить 365 діб.

Висота зонда в км: 60000.
Висота полету в км: 480000000.
Висота полоту в дні: (480000000 ÷ 60000) = 8000.

Висота полоту в дні: 8000.
Сумарна доля дні в рік: 8000 ÷ 365 = 21.93.

21.93

qwen3:4b; запуск 1; статус ok; експертна оцінка 2/2.

Відповідь: Для розв'язання задачі потрібно знайти кількість повних днів, що триватиме політ зонда зі швидкістю 60000 км/год на відстані 480000000 км.

Шаг 1: Обчислення часу в годинах
Використовуючи формулу часу:
$$
\text{Час} = \frac{\text{Відстань}}{\text{Швидкість}}
$$
Підставляємо значення:
$$
\text{Час} = \frac{480000000}{60000} = 8000 \text{ годин}
$$

Шаг 2: Передбачення днів
Оскільки в одному дні 24 години, перетворюємо час у дні:
$$

$$
\text{Кількість днів} = \frac{8000}{24} = 333.333\ldots
$$

Шаг 3: Визначення повних днів
Зважаючи на те, що в задачі запитується "повних днів", округлюємо до цілого числа.
Оскільки 0.333 днів — це частина дня, то повних днів буде:
$$
333
$$

Відповідь:
$$
\boxed{333}
$$

qwen3:4b; запуск 2; статус ok; експертна оцінка 2/2.

Відповідь: Для розв'язання задачі використаємо формулу для обчислення часу:
$$
\text{Час} = \frac{\text{Відстань}}{\text{Швидкість}}
$$

1. **Відомо**:
   - Швидкість зонда: $60000 \, \text{км/год}$,
   - Відстань: $480000000 \, \text{км}$.

2. **Обчислюємо час у годинах**:
   $$
   \text{Час (год)} = \frac{480000000}{60000} = 8000 \, \text{год}.
   $$

3. **Перетворюємо час у дні**:
   $$
   \text{Час (дні)} = \frac{8000}{24} = 333.333\ldots
   $$

4. **Визначаємо кількість повних днів**:
   Оскільки $0.333\ldots$ днів — це не повний день, то кількість повних днів дорівнює 333.

Висновок: Політ триватиме $\boxed{333}$ повних діб.

gemini-3.5-flash-lite; запуск 1; статус ok; експертна оцінка 2/2.

Відповідь: Щоб дізнатися, скільки повних діб триватиме політ, виконаємо кілька простих кроків:

1. Знайдемо загальний час польоту в годинах
Для цього потрібно поділити загальну відстань на швидкість зонда:
$$\text{Час (у годинах)} = \frac{\text{Відстань}}{\text{Швидкість}} = \frac{480\,000\,000 \text{ км}}{60\,000 \text{ км/год}}$$

Скоротимо нулі:
$$\frac{48\,000}{6} = 8\,000 \text{ годин}$$

2. Переведемо години у доби
В одній добі 24 години. Тому ділимо загальну кількість годин на 24:
$$\text{Час (у добах)} = \frac{8\,000}{24}$$

Виконуємо ділення:
$8\,000 \div 24 = 333,333...$ діб

Оскільки запитується про **повні** доби, округлюємо до цілого числа в меншу сторону (або просто беремо цілу частину).

Відповідь:
Політ триватиме **333 повні доби** (і ще приблизно 8 годин).

gemini-3.5-flash-lite; запуск 2; статус ok; експертна оцінка 2/2.

Відповідь: Для того щоб знайти час польоту зонда, потрібно загальну відстань поділити на швидкість.

1. Формула:
$T = \frac{S}{V}$
де:
* $S = 480\,000\,000$ км (відстань)
* $V = 60\,000$ км/год (швидкість)

2. Обчислення часу в годинах:
$T = \frac{480\,000\,000}{60\,000}$

Скорочуємо нулі:
$T = \frac{48\,000}{6} = 8\,000$ годин.

3. Переведення годин у доби:
В одній добі 24 години. Щоб дізнатися кількість діб, ділимо загальну кількість годин на 24:
$8\,000 \div 24 = 333,333...$ діб.

Оскільки запитують про **повні** доби, округлюємо до цілого числа.

Відповідь: політ триватиме **333** повні доби.

Проміжний висновок

Llama двічі помилилася у перетворенні годин у доби. Правильна відповідь: 333 повні доби.

6. Українська мова

llama3.2:3b; запуск 1; статус ok; експертна оцінка 0/2.

Відповідь: Зоря — це велика маса, що об'єднує усі зорі в однієї галактиці. Планета — це велична куля зір, що обіймає рідкі матеріали та гази.

Визначальними рисами зорі відрізуються від планет наступними особливостями:

* Важність: Зорі є основними об'єктами дослідження в астрономії, тоді як планети лише другорядні.
* Власність: Зорі є окремими еволюційними етапами, тоді як планети є окремими об'єктами, які є частию системи зорі.

llama3.2:3b; запуск 2; статус ok; експертна оцінка 0/2.

Відповідь: Зоря - це велика планета Сонячної системи, що розташована на другому місці від Сонця за відстані.

Планета - це велика космічна тіно, що обіймає зорю в своїй зоні видимості.

qwen3:4b; запуск 1; статус ok; експертна оцінка 2/2.

Відповідь: Зоря — це небесний об'єкт, який сам по собі випромінює світло через ядерні реакції в своєму серцевині. Це дуже масивні та яскраві об'єкти, які утворюють основу неба. Наприклад, Сонце є зорею, але не є планетою.

Планета — це природний об'єкт, який орбітує навколо зорі (наприклад, Сонця) та не випромінює світло, але відбиває його. Планети менші за зорі та мають власну гравітацію, але не випромінюють світло, що робить їх несамостійними випромінювачами.

qwen3:4b; запуск 2; статус ok; експертна оцінка 2/2.

Відповідь: Різниця між зіркою та планетою полягає в тому, що зірка — це небесний об'єкт, який самостійно випромінює світло через термоядерні реакції у своєму ядрі. Наприклад, Сонце є зіркою, яка випромінює значну кількість світла та тепла. У зворотньому випадку, планета — це об'єкт, який орбітує навколо зорі (наприклад, Сонця) та відбиває світло від неї, не випромінюючи світло самостійно.

Крім того, зірки є віддаленими від Землі та більші за розмір планет, що впливає на те, як вони виглядають на небі. Наприклад, Земля, яка є планетою, відбиває світло Сонця, а Сонце, як

зірка, самостійно випромінює світло. Ці відмінності дозволяють розрізняти об'єкти за їхньою властивістю до випромінювання світла та шляхом руху навколо зорі.

gemini-3.5-flash-lite; запуск 1; статус ok; експертна оцінка 2/2.

Відповідь: **Зоря** — це величезне, гаряче небесне тіло, що складається з розпеченого газу (переважно водню та гелію), яке виробляє власну енергію. У надрах зорі відбуваються термоядерні реакції, завдяки чому вона яскраво світиться та випромінює величезну кількість тепла й світла (як-от наше Сонце). Зорі є центрами планетних систем і утримують навколо себе інші об'єкти завдяки своїй потужній гравітації.

Планета — це значно менше небесне тіло округлої форми, яке не має власного термоядерного джерела енергії і тому не світиться самостійно, а лише відбиває світло своєї зорі. Планети рухаються орбітами навколо зір (як Земля навколо Сонця) і складаються з каменю, металу або газів. На відміну від зір, які є «печами» Всесвіту, планети є холодними світами, де умови на поверхні можуть бути придатними для існування життя.

gemini-3.5-flash-lite; запуск 2; статус ok; експертна оцінка 2/2.

Відповідь: **Зоря** — це величезне, гаряче небесне тіло, що складається з розпеченого газу (переважно водню та гелію), у недрах якого відбуваються термоядерні реакції. Завдяки цьому зорі самостійно виробляють і випромінюють величезну кількість світла та тепла. Класичним прикладом зорі є наше Сонце, яке освітлює і зігріває всю Сонячну систему.

Планета — це значно менше холодне небесне тіло округлої форми, яке не має власних джерел енергії для виробництва світла. Планети утворюються навколо зір і рухаються по орбітах під дією їхньої гравітації, світячись лише відбитим зоряним світлом. Наприклад, Земля та інші планети Сонячної системи не випромінюють власних променів, а лише відбивають світло Сонця.

Проміжний висновок

Llama неправильно визначила природу зорі та планети; Qwen і Gemini пояснили термоядерне випромінювання зорі та відбите світло планет.

Додаток В. Усі результати семплювання

Таблиця містить кожну з 30 творчих генерацій, а не лише вибрані приклади. Вихідні тексти збережено без редагування; це важливо для аналізу некоректних або незвичних назв.

Експеримент temperature

Таблиця — Усі 15 відповідей для temperature

Прогін	Значення параметра	Згенерована назва
1	0.0	"Фільм на ваше смаку"
2	0.0	"Фільм на вашу думку"
3	0.0	"Фільм на вашу думку"
4	0.0	"Фільм на вашу думку"

5	0.0	"Фільм на вашу думку"
1	0.7	"Фільмопарк"
2	0.7	"Кінофанат"
3	0.7	"Фільми на вашому ладу"
4	0.7	"Серцький перехід"
5	0.7	"Рекомеда"
1	1.5	Kinodilema
2	1.5	"Мультішки"
3	1.5	Фільми до ушерubsia
4	1.5	Сорніпікіка.
5	1.5	"Фолло-Ролл".

Експеримент top_p

Таблиця — Усі 15 відповідей для top_p

Прогін	Значення параметра	Згенерована назва
1	0.1	"Фільм на вашу думку"
2	0.1	"Фільм на вашу думку"
3	0.1	"Фільм на вашу думку"
4	0.1	"Фільм на вашу думку"
5	0.1	"Фільм на вашу думку"
1	0.5	"Фільм для тебе".
2	0.5	"Фільм для тебе".
3	0.5	"Кіноуспільне"
4	0.5	"Кінофанат"
5	0.5	"Фільм на лавочці"
1	1.0	"CinemaExpert".
2	1.0	"Сенірафіль"
3	1.0	"Сцена життя"
4	1.0	"Фільм для тебе".
5	1.0	"Фільмобіле"

Фактична стійкість при двох температурах

Таблиця — Усі 10 фактологічних відповідей

№	Температура	Відповідь	Правильно	Час, с
1	0.0	2007.	так	2.33
2	0.0	2007.	так	2.36
3	0.0	2007.	так	2.4
4	0.0	2007.	так	2.39
5	0.0	2007.	так	2.4
1	1.5	2007	так	2.39
2	1.5	2007	так	2.39
3	1.5	2007	так	2.39
4	1.5	2007	так	2.38
5	1.5	2007	так	2.41

Відтворюваність із фіксованим seed

Таблиця — Усі 10 повторів

№	Seed	Відповідь	Час, с	Статус

1	42	2007.	2.43	ok
2	42	2007.	2.25	ok
3	42	2007.	2.32	ok
4	42	2007.	2.39	ok
5	42	2007.	2.4	ok
6	42	2007.	2.39	ok
7	42	2007.	2.4	ok
8	42	2007.	2.4	ok
9	42	2007.	2.4	ok
10	42	2007.	2.4	ok

Додаток Г. Вихідні файли, перевірка та обмеження

Кодова база, надана для підготовки документа, містить окремі скрипти для запуску моделей, перевірки промптів, порівняння, вимірювання TTFT, якості та семплювання. Нижче наведено відповідність завдань і конкретних файлів; це дає викладачеві змогу відтворити роботу за потреби.

Таблиця — Відповідність експериментів і файлів

Завдання	Код	Файли результатів
1 — міркування	reasoning_vs_instruction.py	reasoning_results.json; reasoning_qwen_retry.json
2 — system	reasoning_vs_instruction.py / інші тести	system_results.json
3 — інтерфейс	providers.py; compare.py	compare_results.json; compare_results.csv
4 — TTFT	benchmark_variant9.py; benchmark.py	benchmark_variant9.json; benchmark_variant9_summary.csv; benchmark_results.json
5 — якість	quality.py	quality.json
6 — семплювання	sampling_factual_variant9.py; sampling_reproducibility.py	sampling_creative_variant9.json; sampling_factual_variant9.json; sampling_reproducibility_variant9.json

Під час роботи було виявлено проблему з кодуванням українського тексту при передачі багаторядкових команд через PowerShell. Некоректний промпт, що перетворився на знаки питання, не включався до оцінювання; для підсумкових серій використано коректно збережені UTF-8 Python-скрипти.

Обмеження: експерименти проводилися на одному локальному комп’ютері та через один хмарний API, тому абсолютні часи залежать від конфігурації обладнання, мережі, навантаження і версій моделей. Оцінювання якості є ручним і залежить від сформульованої рубрики. Три повтори Benchmark та два повтори Quality дають корисне порівняння, але не є статистично репрезентативною вибіркою для всіх сценаріїв.

Під час передачі роботи не потрібно додавати .env або API-ключі. Оригінальні скриншоти термінала в наданому архіві відсутні; замість вигаданих скриншотів звіт містить первинні числові таблиці, а графік побудовано з реальних вимірювань.

Загальні висновки

Під час лабораторної роботи я налаштував локальні моделі через Ollama, звертався до локального й хмарного API, порівняв час генерації та якість відповідей. Експерименти показали, що Llama швидша за Qwen у частині локальних тестів, але часто припускалася помилок у логіці, програмному коді та українській мові. Qwen краще виконувала багатокрокові задачі, хоча могла витрачати багато токенів. Gemini мала найкращі часові показники в серії Benchmark і високу якість у тестах рубрики.

Ми також перевірили, що холодний запуск локальної моделі повільніший за теплий, а зміна temperature і top_p впливає на різноманітність генерації. Висновки стосуються саме виміряних конфігурацій і невеликої кількості тестів, а не всіх можливих сценаріїв використання моделей.

Використані матеріали та вихідні файли

• Методичні вказівки до лабораторної роботи №1, варіант 9.

• Локальні журнали: reasoning_results.json, reasoning_qwen_retry.json, system_results.json, compare_results.json.

• Результати швидкодії: benchmark_results.json, benchmark_variant9.json, benchmark_variant9_summary.csv.

• Результати якості: quality.json.

• Результати семплювання: sampling_creative_variant9.json, sampling_factual_variant9.json, sampling_reproducibility_variant9.json.

• Документація Python, Ollama та API використаних моделей.

Примітка: цей звіт сформовано на підставі наданого архіву експериментів. Для повної перевірки викладачем слід зберегти вихідні файли коду й журналів. Секретний файл .env до звіту не включено.